

DLS

Diffusion Reasoning

Путь от рассуждений в LLM к диффузиям

Karpukhin Sergey, junior researcher @ FusionBrain, AIRI & HSE Bayes Center

Содержание

01 Введение

02 Reasoning в LLM

03 Reasoning в диффузиях

04 Больше ризонинга в диффузиях

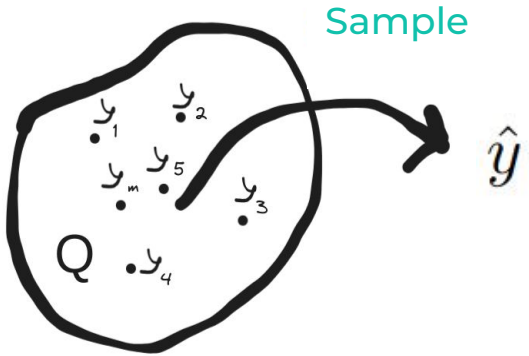
01

Модели и reasoning

Общая постановка

Исходная задача обучения модели

Сегодня мы будем говорить только про **генеративные модели.** Цель генеративной модели по набору наблюдений $Y = \{y_1, y_2, \dots y_m\}$ из неизвестного распределения Q научиться сэмплировать новые примеры $\hat{y}$ (ранее не встречающиеся в выборке).



Где мы видим генеративные модели?

- **AR Language Models** - авторегрессионные модели, генерирующие естественный язык
- **Diffusion Models** - синтез картинок по текстовому или более сложному условию
- Любая задача, где нужны сэмплы, соответствующие каким-то ограничениям/свойствам (белки, материалы, т.д.)

Кратко про LLM

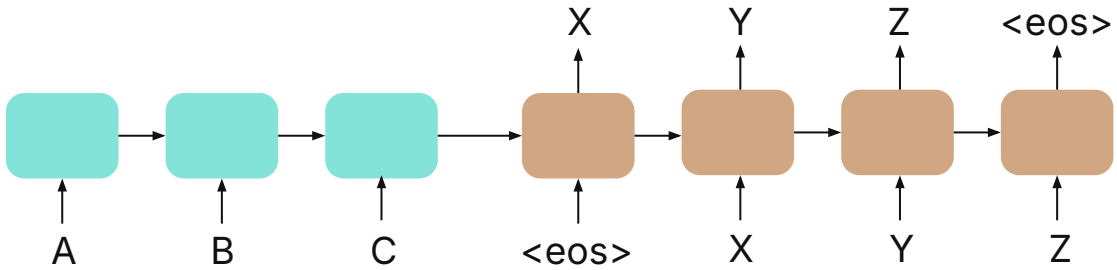
LLM - Large Language Models

LLM тоже обучаются именно генерации. Их цель - максимизировать правдодобие наблюдаемых токенов* в тексте. Ключевые факты про LLM:

- **дискретный** домен данных
- видят **контекст** только **до текущего токена**
- генерируют токены **последовательно**, один за другим

Важно - в LLM правдоподобие данных моделируется **с некоторым окном контекста.**

$$p(x_t|x_1, \ldots, x_{t-1}) = p(x_t|x_{t-n+1}, \ldots, x_{t-1})$$



*токены - атомарные единицы текста, можно думать как про слова в словаре

Кратко про диффузии

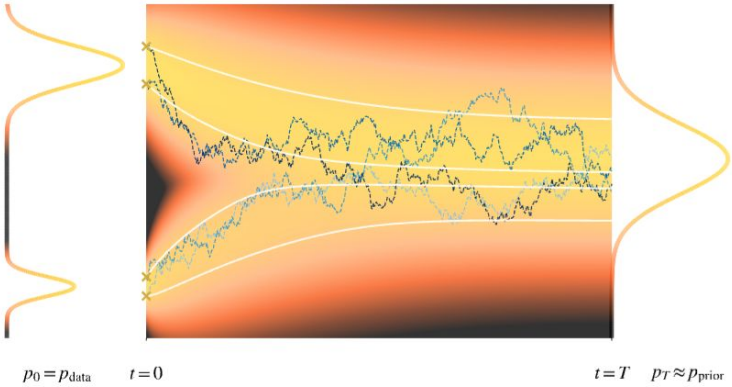
Diffusion Models (in images)

В диффузионных моделях учатся генерировать через **преобразование шума** в сэмпл **данных** - модель вызывается много раз, и ее выход постепенно трансформирует оценку сэмпла.

Аналогичные пункты:

- → **непрерывный** домен данных (хотя в **дискретном** тоже можно применять)
- → модель на вход получает **шумный сэмпл**
- → генерируют весь сэмпл **сразу**

$$\mathrm{d}\mathbf{x}(t) = \mathbf{f}(\mathbf{x}(t), t)\,\mathrm{d}t + g(t)\,\mathrm{d}\mathbf{w}(t), \quad \mathbf{x}(0) \sim p_{\text{data}}$$



$$\mathrm{d}\bar{\mathbf{x}}(t) = \left[\mathbf{f}(\bar{\mathbf{x}}(t), t) - g^2(t)\nabla_{\mathbf{x}} \log p_t(\bar{\mathbf{x}}(t))\right]\mathrm{d}t + g(t)\,\mathrm{d}\bar{\mathbf{w}}(t),$$
$$\bar{\mathbf{x}}(T) \sim p_{\text{prior}} \approx p_T.$$

Lai C. H. et al. The principles of diffusion models //arXiv preprint arXiv:2510.21890. – 2025.

AIRI

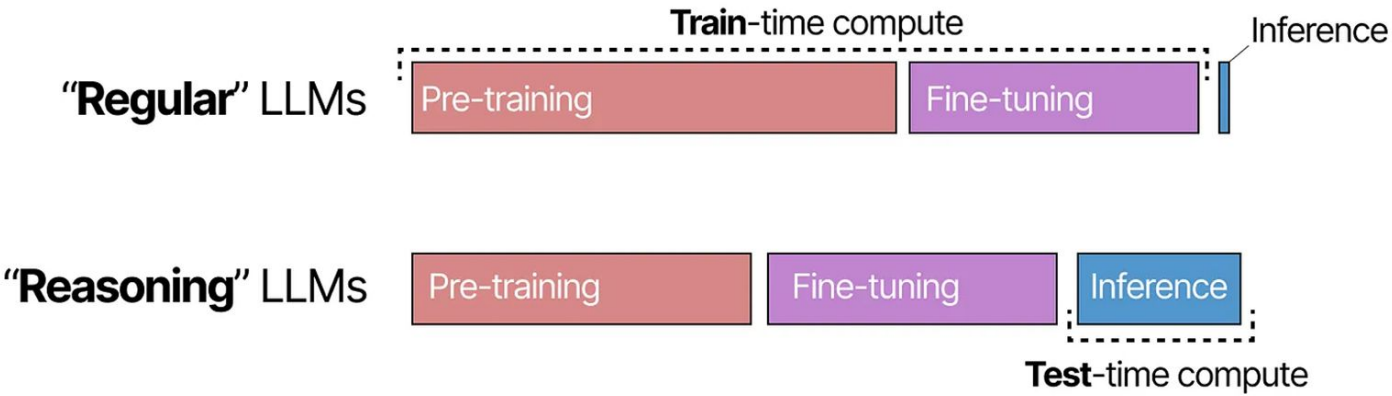
Ограничения обучения моделей

Проблема: мы тратим много ресурсов на обучение модели - но во время инференса упираемся в потолок качества...



Ограничения обучения моделей

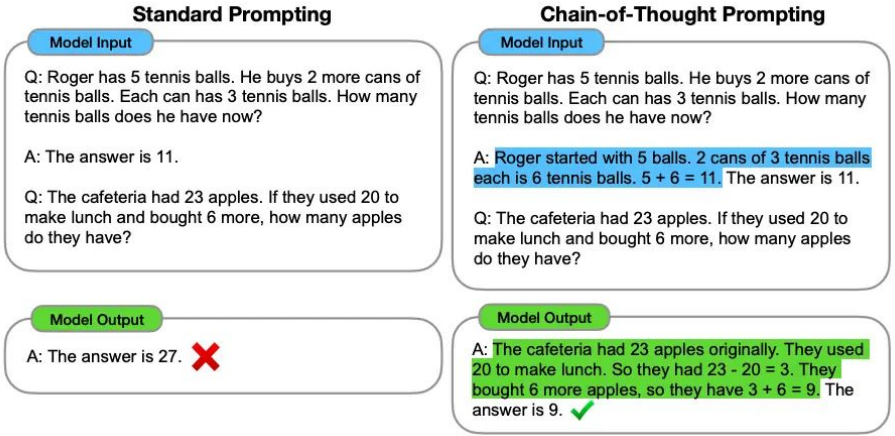
Проблема: мы тратим много ресурсов на обучение модели - но во время инференса упираемся в потолок качества...



Цель - во время **инференса** тратить **больше вычислений** для лучшего результата

Почему “reasoning”?

- Свойство улучшать результат за счет больших вычислений началось именно с LLM
- Один из первых примеров - Chain-of-through (COT) в 2022
- Так как выход LLM - естественной язык, дополнительные вычисления формируются в виде текста, напоминающего рассуждение/reasoning



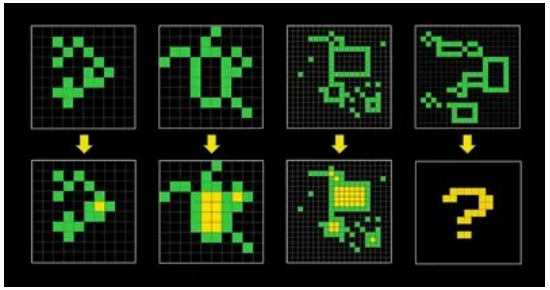
- пример CoT - добавление рассуждений перед ответом как пример в контексте

Где reasoning нужен

Возможное определение: reasoning в модели = способность решать **сложные задачи**, требующие рассуждений

В домене языка

- **Программирование** - HumanEval, SWEBench, DeepSWE, etc.
- **Математика** - MATH-500, олимпиадные задачи
- **Специальные** - графы (GraphWalk), планирование (PlanBench), извлечение правил из контекста (ARC-AGI)



В мультимодальных средах

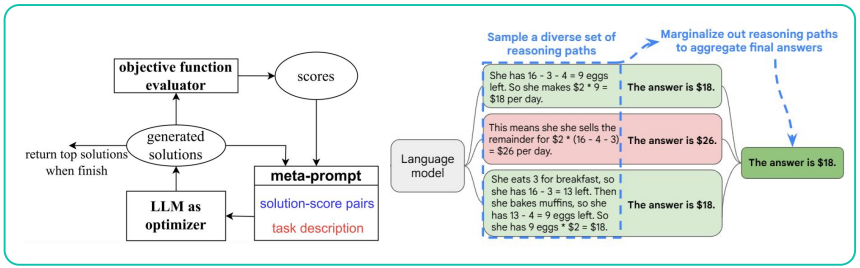
- **Робототехника** - планирование и манипуляции в пространстве
- **Визуальные задачи** - геометрия, пазлы, извлечение информации из изображений/видео
- **Физика -** физическая корректность генерации/интерпретация наблюдаемого явления в видео

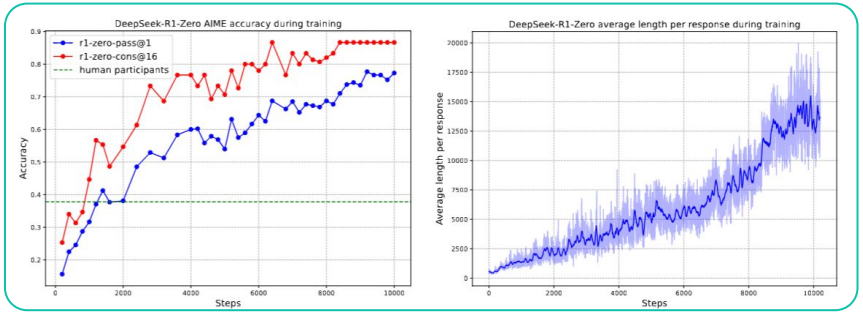


02

Reasoning в LLM

Два типа подходов





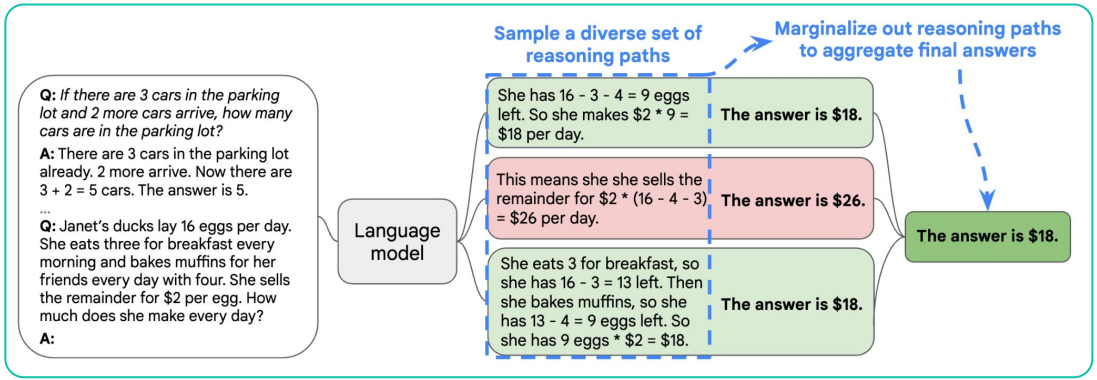
Ручные методы - мы можем улучшать инференс за счет ручной инженерии контекста, параллелизации, поиска и использования внешних моделей

Emergent/train-based - обучение модели, приводящее к “рассуждениям” во время сэмплирования (более длинные цепочки, лучше качество) - Deepseek R1 / GRPO / any new model release

Примеры параллельных ручных методов

Self-Consistency

Модель генерирует несколько вариантов рассуждений - выбираем вариант, который выбран большинством



Best-of-N

Используя внешнюю ревард модель (ORM), выбираем наилучшего кандидата решение.

Models	Verifiers	GSM8K	MATH500
LLaMA2-70B: MetaMATH	Self-Consistency	88.0	39.4
	ORM	91.8	40.4
	Self-Consistency + ORM	92.0	42.0
	MATH-SHEPHERD (Ours)	93.2	44.5
	Self-Consistency + MATH-SHEPHERD (Ours)	92.4	45.2
LLemma-34B: MetaMATH	Self-Consistency	82.6	44.2
	ORM	90.0	43.7
	Self-Consistency + ORM	89.6	45.4
	MATH-SHEPHERD (Ours)	90.9	46.0
	Self-Consistency + MATH-SHEPHERD (Ours)	89.7	47.3

Li Y. et al. Making language models better reasoners with step-aware verifier //Proceedings of the 61st annual meeting of the association for computational linguistics (volume 1: long papers). – 2023. – С. 5315-5333.
Wang P. et al. Math-shepherd: Verify and reinforce llms step-by-step without human annotations //Proceedings of the 62nd Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers). – 2024. – С. 9426-9439.

AIRI

Depth-based методы

Другой подход - модель постепенно улучшает свое итоговое предсказание.

В **2023** в работе **Self-Refine** авторы предложили замкнутый пайплайн - одна модель выступает как а) генератор решения б) генератор фидбека в) генератор улучшения

Algorithm 1 SELF-REFINE algorithm

Require: input x, model $\mathcal{M}$, prompts $\{p_{\text{gen}}, p_{\text{fb}}, p_{\text{refine}}\}$, stop condition $\text{stop}(\cdot)$

1: $y_0 = \mathcal{M}(p_{\text{gen}} \| x)$ ▷ Initial generation (Eqn. 1)
2: **for** iteration t $\in 0, 1, \ldots$ **do**
3: $fb_t = \mathcal{M}(p_{\text{fb}} \| x \| y_t)$ ▷ Feedback (Eqn. 2)
4: **if** $\text{stop}(fb_t, t)$ **then** ▷ Stop condition
5: **break**
6: **else**
7: $y_{t+1} = \mathcal{M}(p_{\text{refine}} \| x \| y_0 \| fb_0 \| \ldots \| y_t \| fb_t)$ ▷ Refine (Eqn. 4)
8: **end if**
9: **end for**
10: **return** y_t

(d) Code optimization: x, y_t

```
Generate sum of 1, ..., N
def sum(n):
    res = 0
    for i in range(n+1):
        res += i
    return res
```

(c) FEEDBACK fb

```
This code is slow as
it uses brute force.
A better approach is
to use the formula
... (n(n+1))/2.
```

(f) REFINE y_{t+1}

```
Code (refined)

def sum_faster(n):
  return (n*(n+1))//2
```

Task	GPT-3.5 Base	GPT-3.5 +SELF-REFINE	ChatGPT Base	ChatGPT +SELF-REFINE	GPT-4 Base	GPT-4 +SELF-REFINE
Sentiment Reversal	8.8	**30.4** (↑21.6)	11.4	**43.2** (↑31.8)	3.8	**36.2** (↑32.4)
Dialogue Response	36.4	**63.6** (↑27.2)	40.1	**59.9** (↑19.8)	25.4	**74.6** (↑49.2)
Code Optimization	14.8	**23.0** (↑8.2)	23.9	**27.5** (↑3.6)	27.3	**36.0** (↑8.7)
Code Readability	37.4	**51.3** (↑13.9)	27.7	**63.1** (↑35.4)	27.4	**56.2** (↑28.8)
Math Reasoning	**64.1**	**64.1** (0)	74.8	**75.0** (↑0.2)	92.9	**93.1** (↑0.2)
Acronym Generation	41.6	**56.4** (↑14.8)	27.2	**37.2** (↑10.0)	30.4	**56.0** (↑25.6)
Constrained Generation	28.0	**37.0** (↑9.0)	44.0	**67.0** (↑23.0)	15.0	**45.0** (↑30.0)

Table 1: SELF-REFINE results on various tasks using GPT-3.5, ChatGPT, and GPT-4 as base LLM. SELF-REFINE consistently improves LLM. Metrics used for these tasks are defined in Section 3.2.

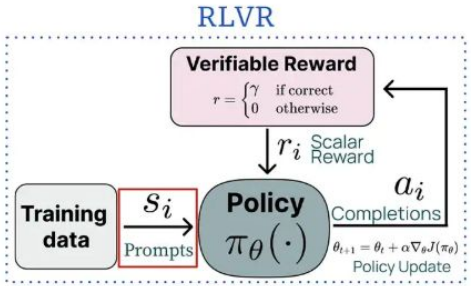
Madaan A. et al. Self-refine: Iterative refinement with self-feedback //Advances in neural information processing systems. – 2023. – Т. 36. – С. 46534-46594.

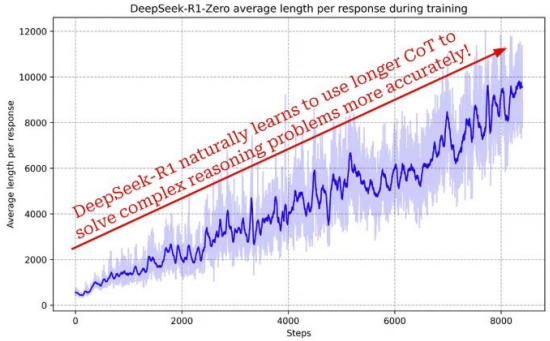
AIRI

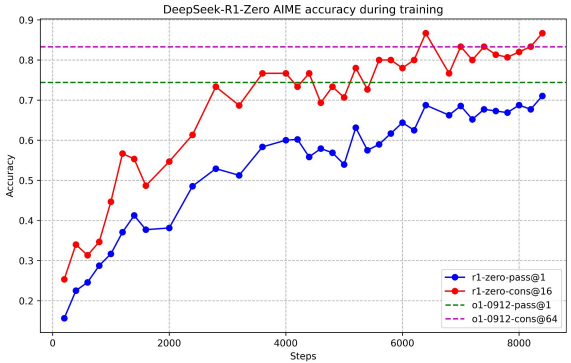
Train-based Reasoning / GRPO

Релиз **Deepseek-R1** показал, что обучения с подкреплением приводит к рассуждениям во время сэмплирования из модели.

- Start with a dataset of diverse prompts
- Iteratively do the following:
  - **Sample a mini-batch of prompts for training**
  - Generate on-policy completions for the prompts
  - Compute the reward for each completion
  - Use rewards to compute a policy update





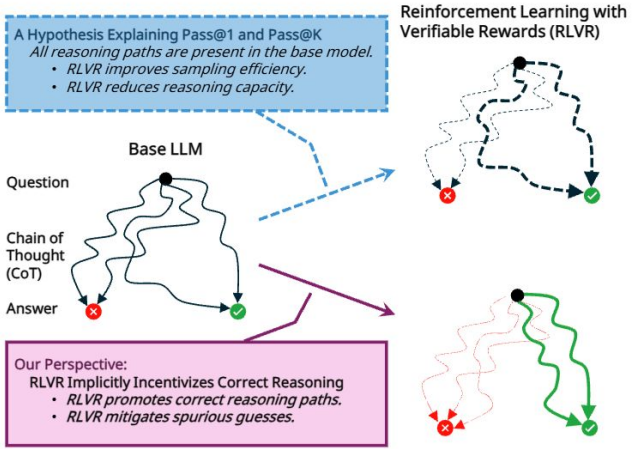


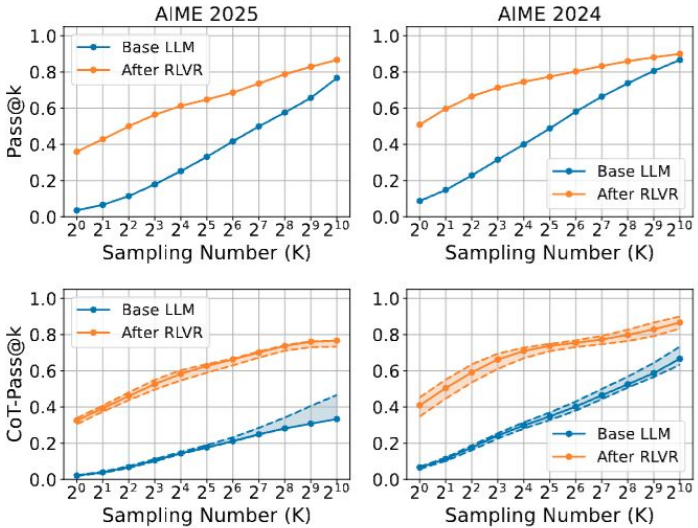
Guo D. et al. Deepseek-r1: Incentivizing reasoning capability in llms via reinforcement learning //arXiv preprint arXiv:2501.12948. – 2025.
Wen X. et al. Reinforcement learning with verifiable rewards implicitly incentivizes correct reasoning in base llms //International Conference on Learning Representations. – 2026. – Т. 2026. – С. 49450-49483.

Train-based Reasoning / GRPO

Интерпретируемость - что именно сигнал от наград позволяет модели выучить?

Ответ: Сигнал от наград позволяет модели прийти к **качественно новым цепочкам рассуждений, ведущим к правильным ответам**





Pass@k - correct ans out of k rollouts
CoT-Pass@k - correct ans + correct trace

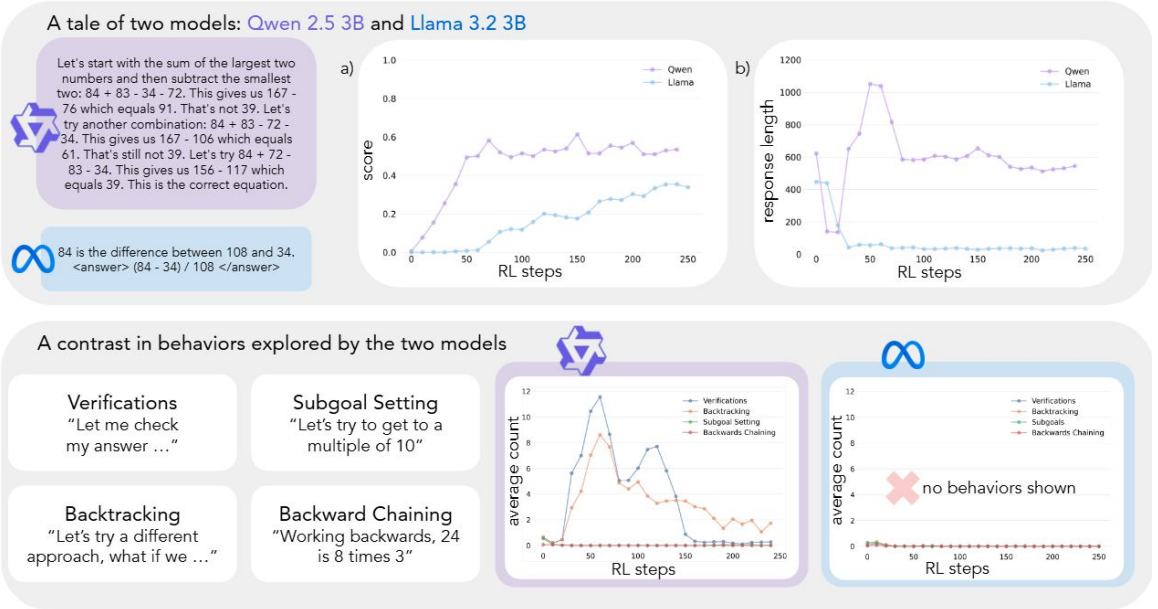
Guo D. et al. Deepseek-r1: Incentivizing reasoning capability in llms via reinforcement learning //arXiv preprint arXiv:2501.12948. – 2025.
Wen X. et al. Reinforcement learning with verifiable rewards implicitly incentivizes correct reasoning in base llms //International Conference on Learning Representations. – 2026. – Т. 2026. – С. 49450-49483.

Как ведет себя reasoning в LLM?

На уровне трейсов можно выделять следующие поведения модели:

- верификация
- подцели
- откат решения
- обратные рассуждения

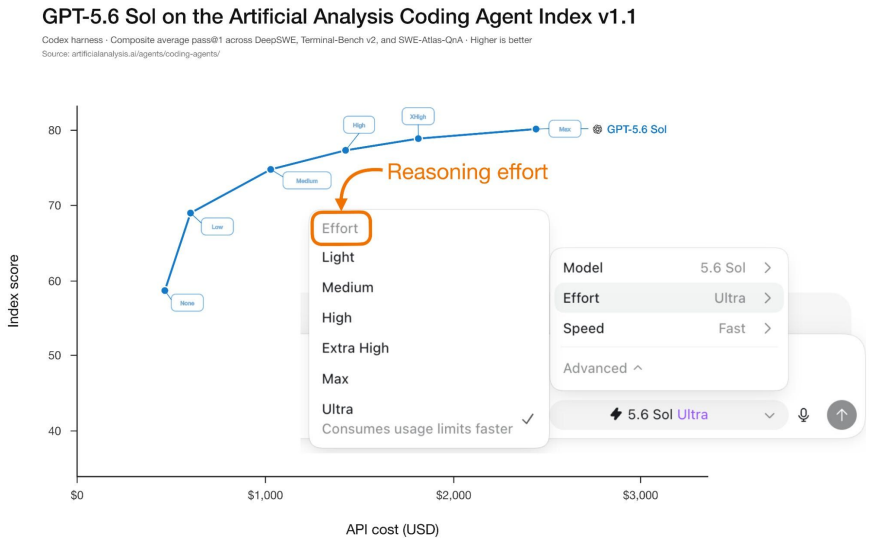
Обнаружение таких паттернов сильно коррелирует с качеством рассуждений + их форсирование существенно улучшать качество RL.



Gandhi K. et al. Cognitive behaviors that enable self-improving reasoners, or, four habits of highly effective stars //arXiv preprint arXiv:2503.01307. – 2025.

Reasoning effort на практике

User POV - у модели есть различные уровни “reasoning effort”.
Больше reasoning ⇒ длиннее цепочки/дороже инференс ⇒ лучше качество
Современные релизы добавляют для этого явный контроль



$$R(e) = R_{\text{task}} - \lambda(e) N_{\text{tokens}}$$

2.5.2 Variable Effort Reasoning Training

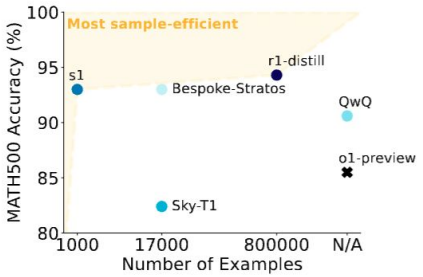
We train the models to support three reasoning levels: `low`, `medium`, and `high`. These levels are configured in the system prompt by inserting keywords such as "Reasoning: low". Increasing the reasoning level will cause the model's average CoT length to increase.

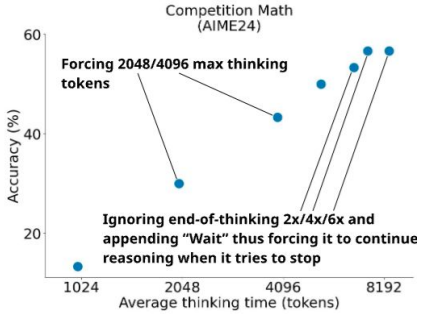
Agarwal S. et al. gpt-oss-120b & gpt-oss-20b model card //arXiv preprint arXiv:2508.10925. – 2025.

SFT vs RL?

Не смотря на RL как важный подход к reasoning-у, SFT тоже может быть использован как инструмент дистилляции способности к рассуждениям.

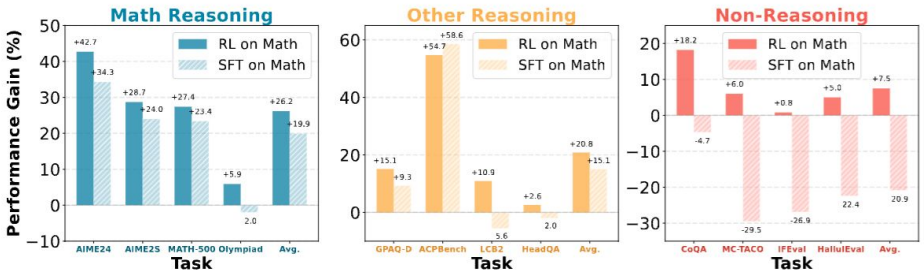
В **s1** [1] - sft на трейсах рассуждений из RL обученных моделей. Результат - многократный выигрыш по эффективности и возможность depth scaling-а.





В [2] - похожий результат, но SFT проигрывает на не reasoning задачах.

Причина: SFT значительно меняет распределение токенов модели, разрушая ее prior знания.



Muennighoff N. et al. s1: Simple test-time scaling //Proceedings of the 2025 Conference on Empirical Methods in Natural Language Processing. – 2025. – С. 20286-20332.
Huan M. et al. Does math reasoning improve general llm capabilities? understanding transferability of llm reasoning //arXiv preprint arXiv:2507.00432. – 2025.

Подводя по итогам в ЛЛМ

- можно инженерить пайплайны с голосованием/поиском/отбора правильного ответа
- можно обучать, используя сигнал от наград правильности ответа ⇒ получать модель с цепочками рассуждениями
- уровень рассуждений можно контролировать
- sft можно использовать вместо rl, но у этого есть ограничения (модель тупеет)
- если модель умеет рассуждать, обвязка ее усиляет еще сильнее

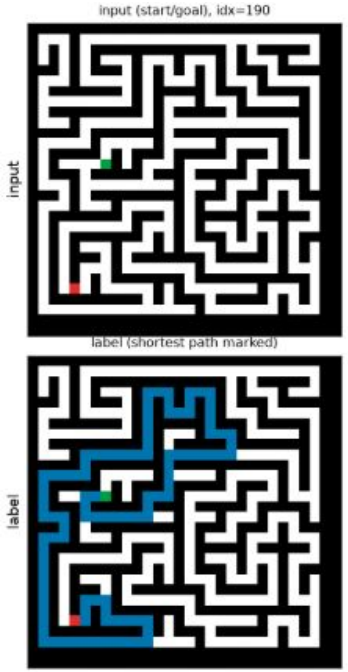
03

Reasoning в диффузиях

Примеры задач с рассуждениями

Обычно диффузионные модели работают в непрерывном визуальном домене (картинки). Примеры задач, где рассуждения могут быть необходимы (в картинках):

- → Alignment картинки и промпта, интерпретация сложных инструкций
- → Решение визуальных пазлов (Sudoku, Maze, etc.)
- → Просто качество генерации





Draw what it will look like after being hit by a baseball.



где на картинке “giant leaf”?

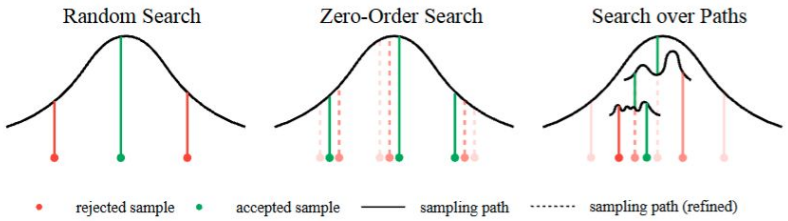
Scaling Inference Time Compute

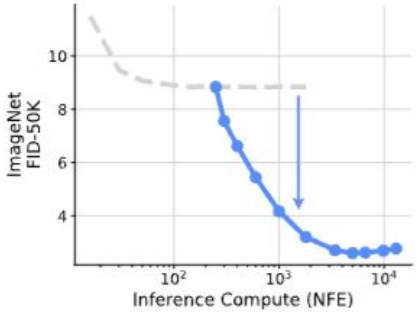
В первой такой работе авторы показали возможность скейлинга **диффузии** с использованием **внешних verifier-ов**.

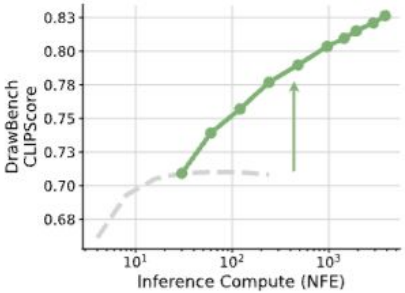
В работе оценивается работа двух типов verifer-ов:

1) **oracle** - имеющие доступ к тестовой выборке (e.g. FiD)
2) **supervised/self-supervised** - оценивающие сэмплы сами по себе (e.g. CLIP, DINO)









[Ma N. et al. Inference-time scaling for diffusion models beyond scaling denoising steps //arXiv preprint arXiv:2501.09732. – 2025.

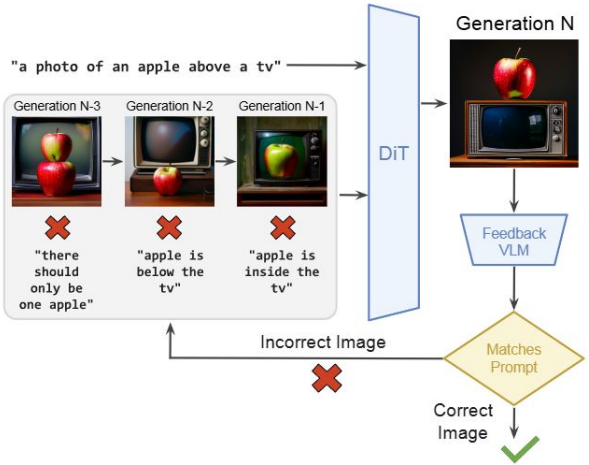
Reflect-DiT

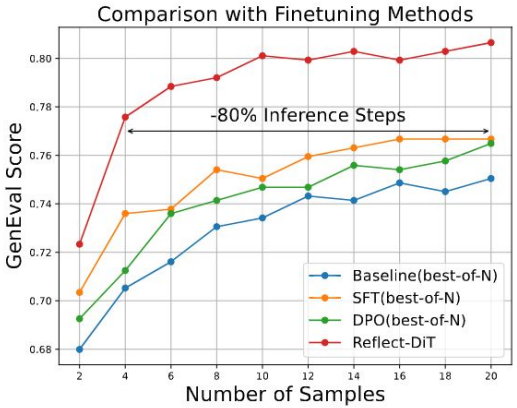
Идея улучшения генерации в глубину:

→ обучаем feedback VLM описывать результат генерации

→ обучаем модель принимать цепочку из генераций и фидбеков

→ модель за несколько итераций исправляет свои ошибки





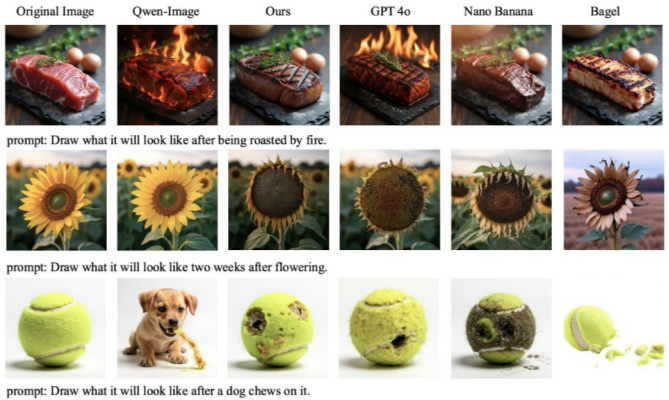


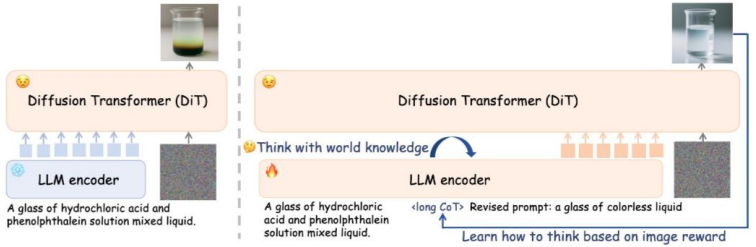
Li S. et al. Reflect-dit: Inference-time scaling for text-to-image diffusion transformers via in-context reflection //2025 IEEE/CVF International Conference on Computer Vision (ICCV). – IEEE, 2025. – С. 15657-15668.

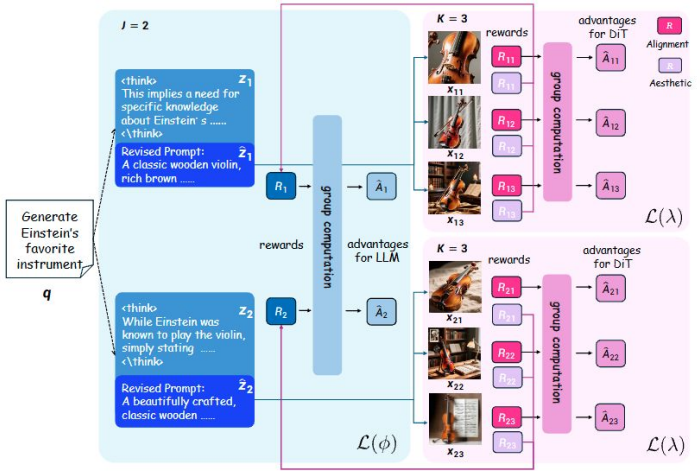
Think-Then-Generate

Используем LLM-энкодер, про который знаем, что можно дообучить с GRPO - и будет рассуждать.

Идея: GRPO обучим совместно и LLM, и диффузию.







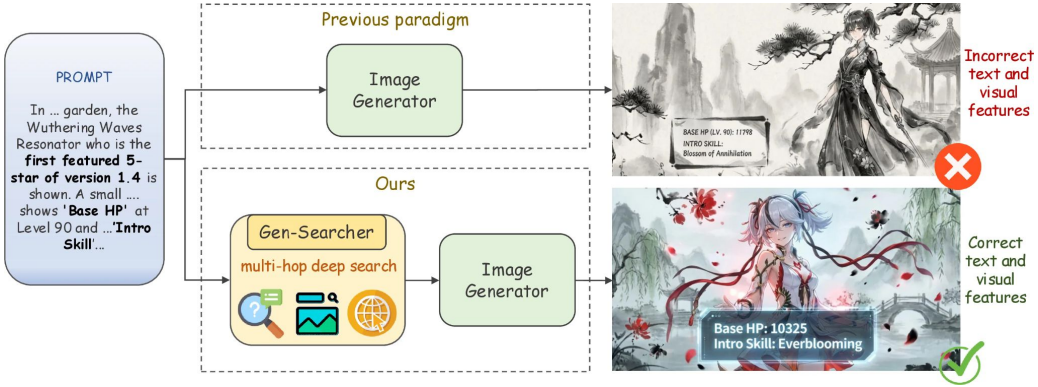
Li S. et al. Reflect-dit: Inference-time scaling for text-to-image diffusion transformers via in-context reflection //2025 IEEE/CVF International Conference on Computer Vision (ICCV). – IEEE, 2025. – С. 15657-15668.

Обогащение контекста агентом

Вместо картиночной модели давайте максимально полезно обогатим контекст.

Для этого обучим агента, специализирующегося в поиске информации под уточнение пользовательского промпта, награждаем за правильность картинки.

Адекватный подход для граундинга модели в фактах о реальном мире.



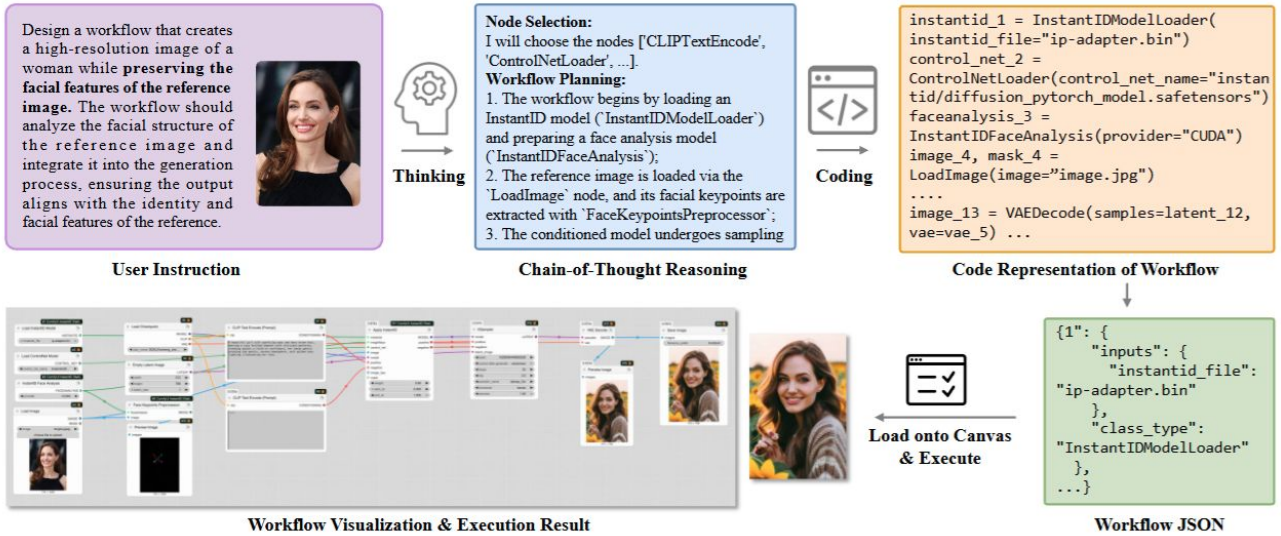
Methods	KnowGen
Qwen-Image	14.98
Qwen-Image + workflow	22.91
Qwen-Image + Gen-Searcher-SFT	28.15
Qwen-Image + Gen-Searcher w.o. text reward	29.59
Qwen-Image + Gen-Searcher w.o. image reward	29.36
Qwen-Image + Gen-Searcher	31.52

Feng K. et al. Gen-searcher: Reinforcing agentic search for image generation //arXiv preprint arXiv:2603.28767. – 2026.

Генерация диффузией = текстовый пайплайн

ComfyUI (и аналоги) - популярная в индустрии среда для реализации пайплайнов с диффузией в виде визуальных DAG-ов.

Тк весь пайплайн это просто код, есть множество работ [1,2], автоматизирующих поиск и модификацию пайплайнов ЛЛМ-кой под запрос пользователя - декомпозиция задачи, сборка пайплайнов, подбор параметров.



https://github.com/comfy-org/comfyui

1 - Xu Z. et al. Comfyui-r1: Exploring reasoning models for workflow generation //Findings of the Association for Computational Linguistics: ACL 2026. – 2026. – С. 2999-3013.
2 - Su J. et al. ComfySearch: Autonomous Exploration and Reasoning for ComfyUI Workflows //arXiv preprint arXiv:2601.04060. – 2026.

AIRI

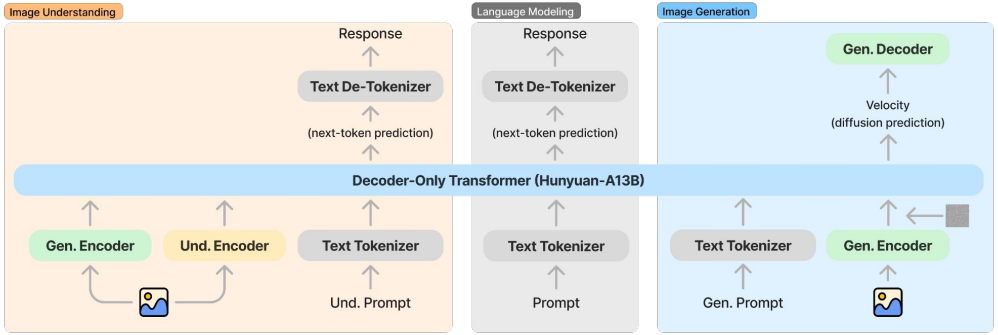
04

Больше ризонинга в диффузиях

Диффузия как часть мультимодальной модели

Последние годы все чаще появляются модели, обучающиеся совместно на несколько задач - один трансформер объединяет несколько модальностей.

Преимущество: на инференсе генерации картинки можно синтезировать мультимодальные цепочки рассуждений

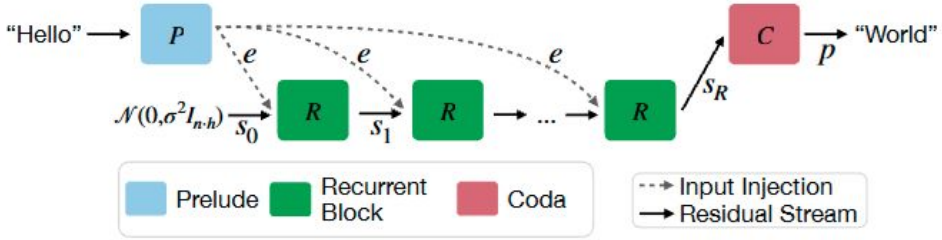




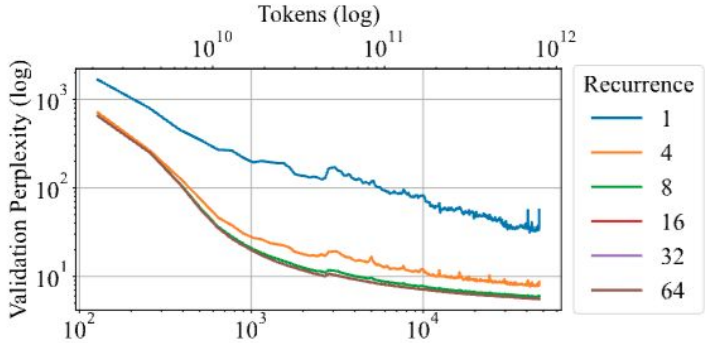
Team T. H. F. M. HunyuanImage 3.0 Technical Report //arXiv preprint arXiv:2509.23951. – 2025.
Qin L. et al. Uni-cot: Towards unified chain-of-thought reasoning across text and vision //International Conference on Learning Representations. – 2026. – Т. 2026. – С. 15999-16028.

Looped Трансформеры

Класс моделей, развивающийся с 2018 года. Идея - для задач, требующих итеративных рассуждений, внутрь трансформера добавить рекурсию.



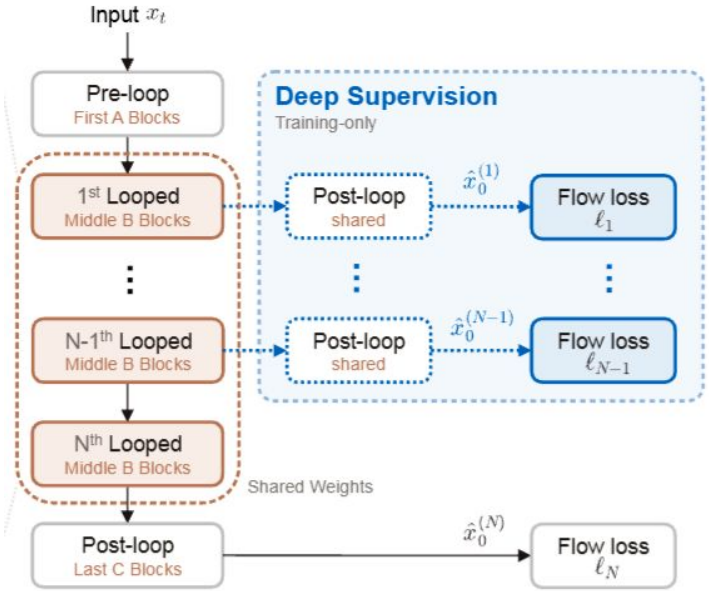
Т.к. рекурсия происходит на скрытых представлениях, "рассуждения" нельзя явно наблюдать, но все еще можно интерпретировать через зависимость качества от вычислений на инференсе.

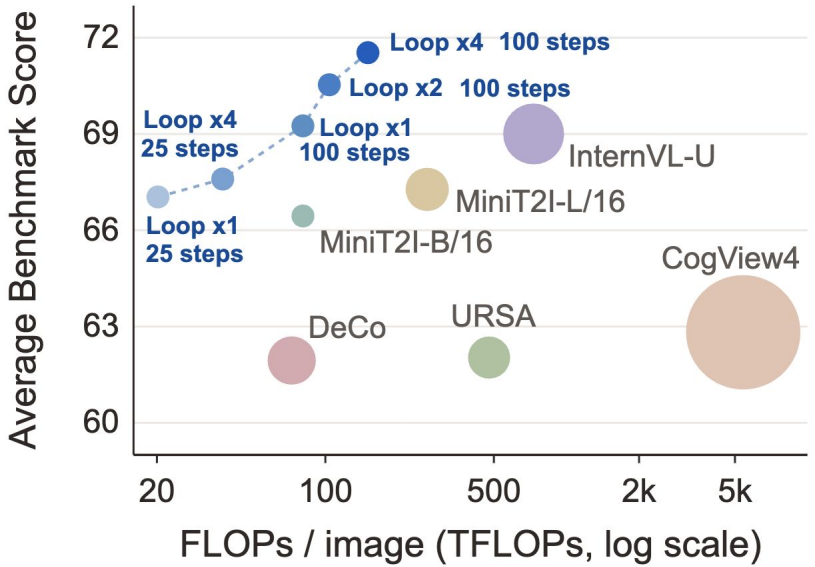


Dehghani M. et al. Universal transformers //arXiv preprint arXiv:1807.03819. – 2018
Geiping J. et al. Scaling up test-time compute with latent reasoning: A recurrent depth approach //Advances in Neural Information Processing Systems. – 2026. – Т. 38. – С. 41340-41391.

Looped Трансформеры + Диффузия

Подход успешно адаптировали для задачи text2image, показав существенные выигрыши по качеству, адаптивному улучшению и эффективности компьюта.





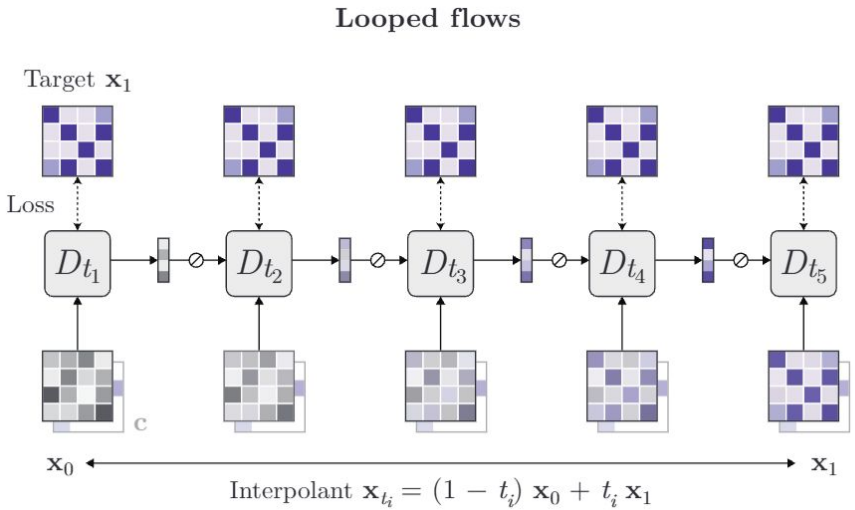
Chng Y. X. et al. Looped Diffusion Transformer //arXiv preprint arXiv:2609.40305. – 2026.

Looped Flows

Аналогичный виток развития, но уже в Flow Language Models - обучении flow модели на дискретном домене.

Адаптируют подход к обучению из TRM, согласуя цепочку улучшения с памятью поверх интерполяций шум ↔ данные.

Достигают SOTA качества в задачах визуальных пазлов и ARC-AGI.



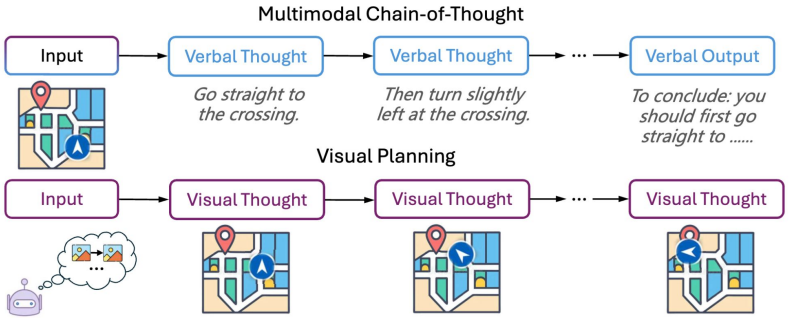
Method	# Params	Sudoku-Extreme	Maze-Hard	ARC-AGI-1
Direct prediction (Wang et al., 2025)	27M	0.0	0.0	21.0
Looped transformer (Back et al., 2026)	7M	61.3	–	–
HRM (Wang et al., 2025)	27M	55.0	74.5	40.3
TRM (Jolicoeur-Martineau, 2025)	5–7M	87.4	85.3	44.6
FPRM (Movahedi et al., 2026)	7M	94.2	**87.0**	47.5
GRAM (Back et al., 2026)	10M	–	–	52.0
Looped flows	5–7M	**97.9 ± 0.4**	86.7 ± 1.1	**58.8 ± 1.8**

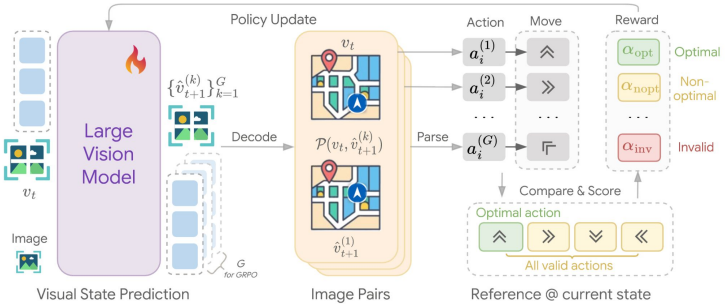
Chng Y. X. et al. Looped Diffusion Transformer //arXiv preprint arXiv:2609.40305. – 2026.

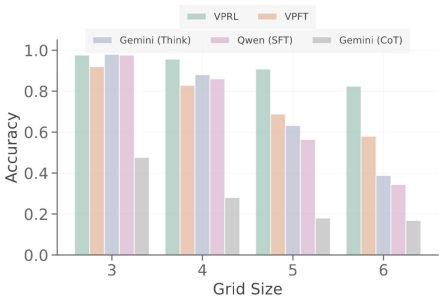
Visual Planning

Идея - обучить vision sequence модель под задачу планирования. Противопоставляется сетапам где VLM используется для аналогичной задачи

Учатся в две стадии - претрейн для сэмплирования валидных планов, GRPO с положительной наградой за эффективные решения и отрицательной за галлюцинации.





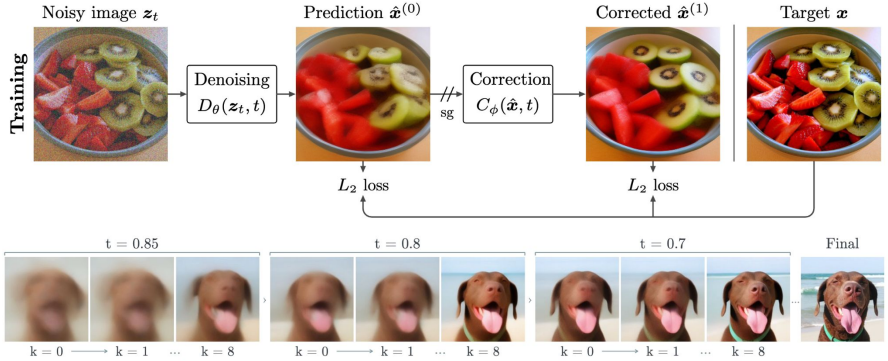


Xu Y. et al. Visual Planning: Let's Think Only with Images //International Conference on Learning Representations. – 2026. – Т. 2026. – С. 36706-36739.

Diffusion + Correction

В статье авторы предлагают дообучить модель Corrector, которую на каждом шаге можно вызывать в цикле.

Цель модели - на фиксированном t улучшать предсказание. На инференсе можно выбирать кол-во применений такой модели и получать эффективный трейд-офф компьюта/качества.



Model	Params (M)	Sampling	Steps	Layer evals	FID@8K↓
Matched parameters					
D_{28}	675	Unguided	240	6,720	8.93
D_{28}	675	CFG ($w = 5$)	120	6,720	6.17
$D_{14} + C_{14}$	681	$K = 1$	240	6,720	8.74
$D_{14} + C_{14}$	681	$K = 3$	120	6,720	5.66
$D_{14} + C_{14}$	681	$K = 4$	96	6,720	**5.56**
Matched effective depth					
D_{28}	675	Unguided	240	6,720	8.19
$D_7 + C_7$	346	$K = 3$	240	6,720	**7.51**

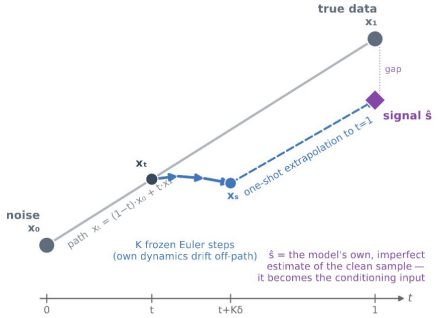
Ahn D. et al. Correction Training for Diffusion Models //arXiv preprint arXiv:2610.14136. – 2026.

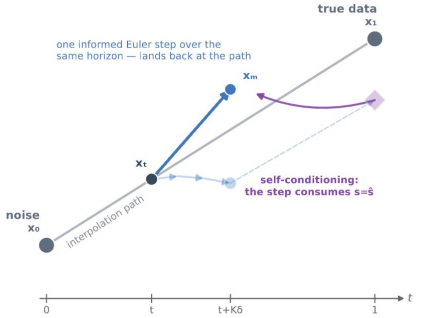
SRC (ours)

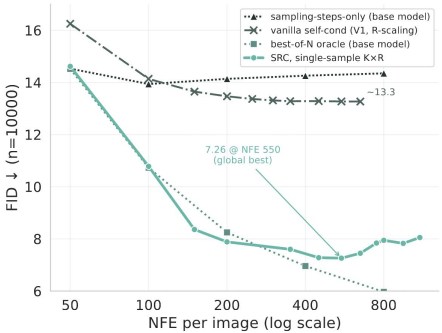
В нашей работе scout-correct-refine мы придумали, как использовать таргет обучения исправления предсказаний для скейлинга во время инференса.

По итогу модель делает роллауты ближе к данным, получает оценку генерируемой оценки, и подает в себя же как условие.

Проверяли на сырой задаче генерации картинок, подняли качество бейзлайна в ~2 раза без внешних ревардов, при этом совместимо с BoN.









preprint - https://arxiv.org/abs/2610.41598

AIRI

Вот и все!

Сейчас мы работаем сразу по нескольким направлениям с целью добавления ризонинга и применения таких моделей:

- → адаптация коррекции к планированию
- → looped модели в визуальной генерации и пазлах
- → рассуждения через генерацию по слоям
- → рассуждения через адаптацию расписания сэмплирования

Если у вас есть **задача/идеи**, где интересно **применить** диффузионную модель с **ризонингом** - пишите нам!



AIRI