ПЕРСОНАЛИЗИРОВАННАЯ ГЕНЕРАЦИЯ

в эпоху in-context моделей

Вера Соболева

Научный сотрудник FusionBrain Lab, AIRI

Один субъект — множество новых сцен

- Вход: несколько фотографий конкретного субъекта
- Выход: новые ракурсы, позы, окружение и композиция
- Цель: сохранить identity без потери качества

люди



объекты



Как развивалась область

01

Subject tuning

Учимся на каждом субъекте

→

02

Image adapters

Подключаем image features

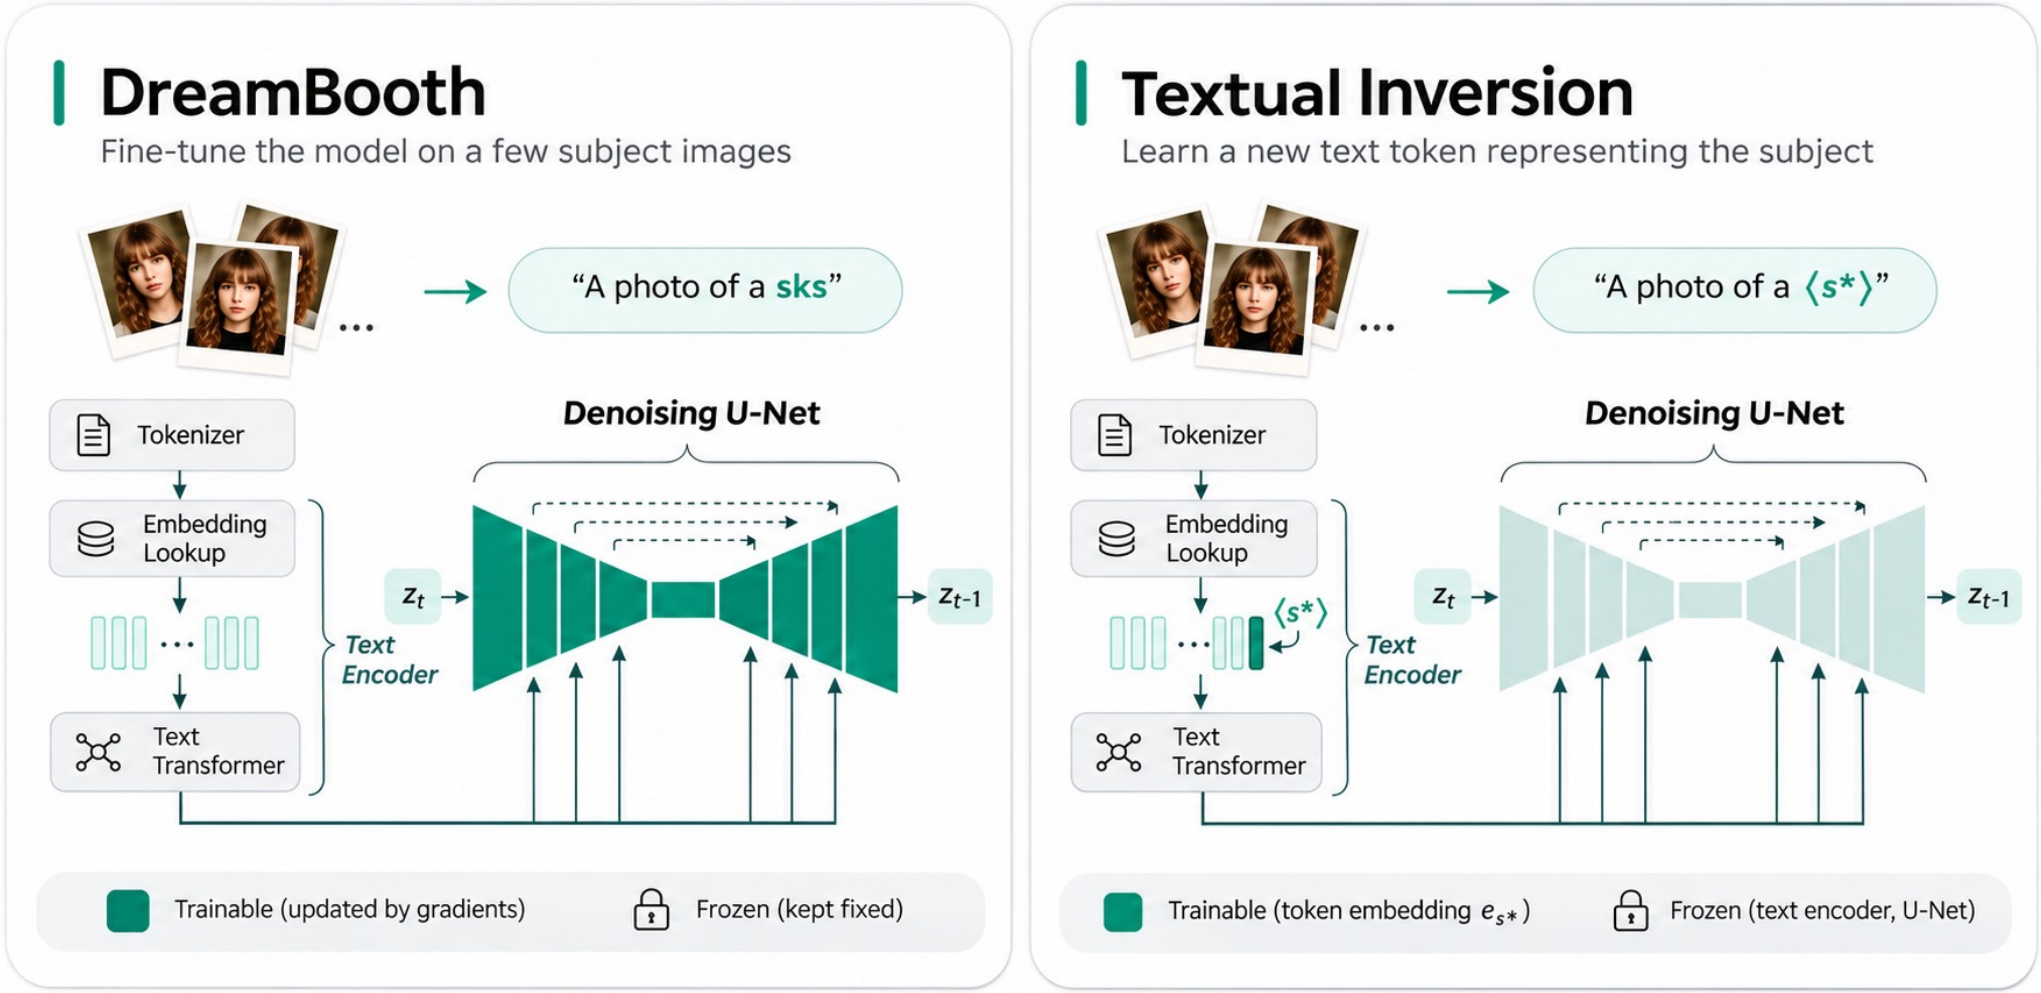
→

03

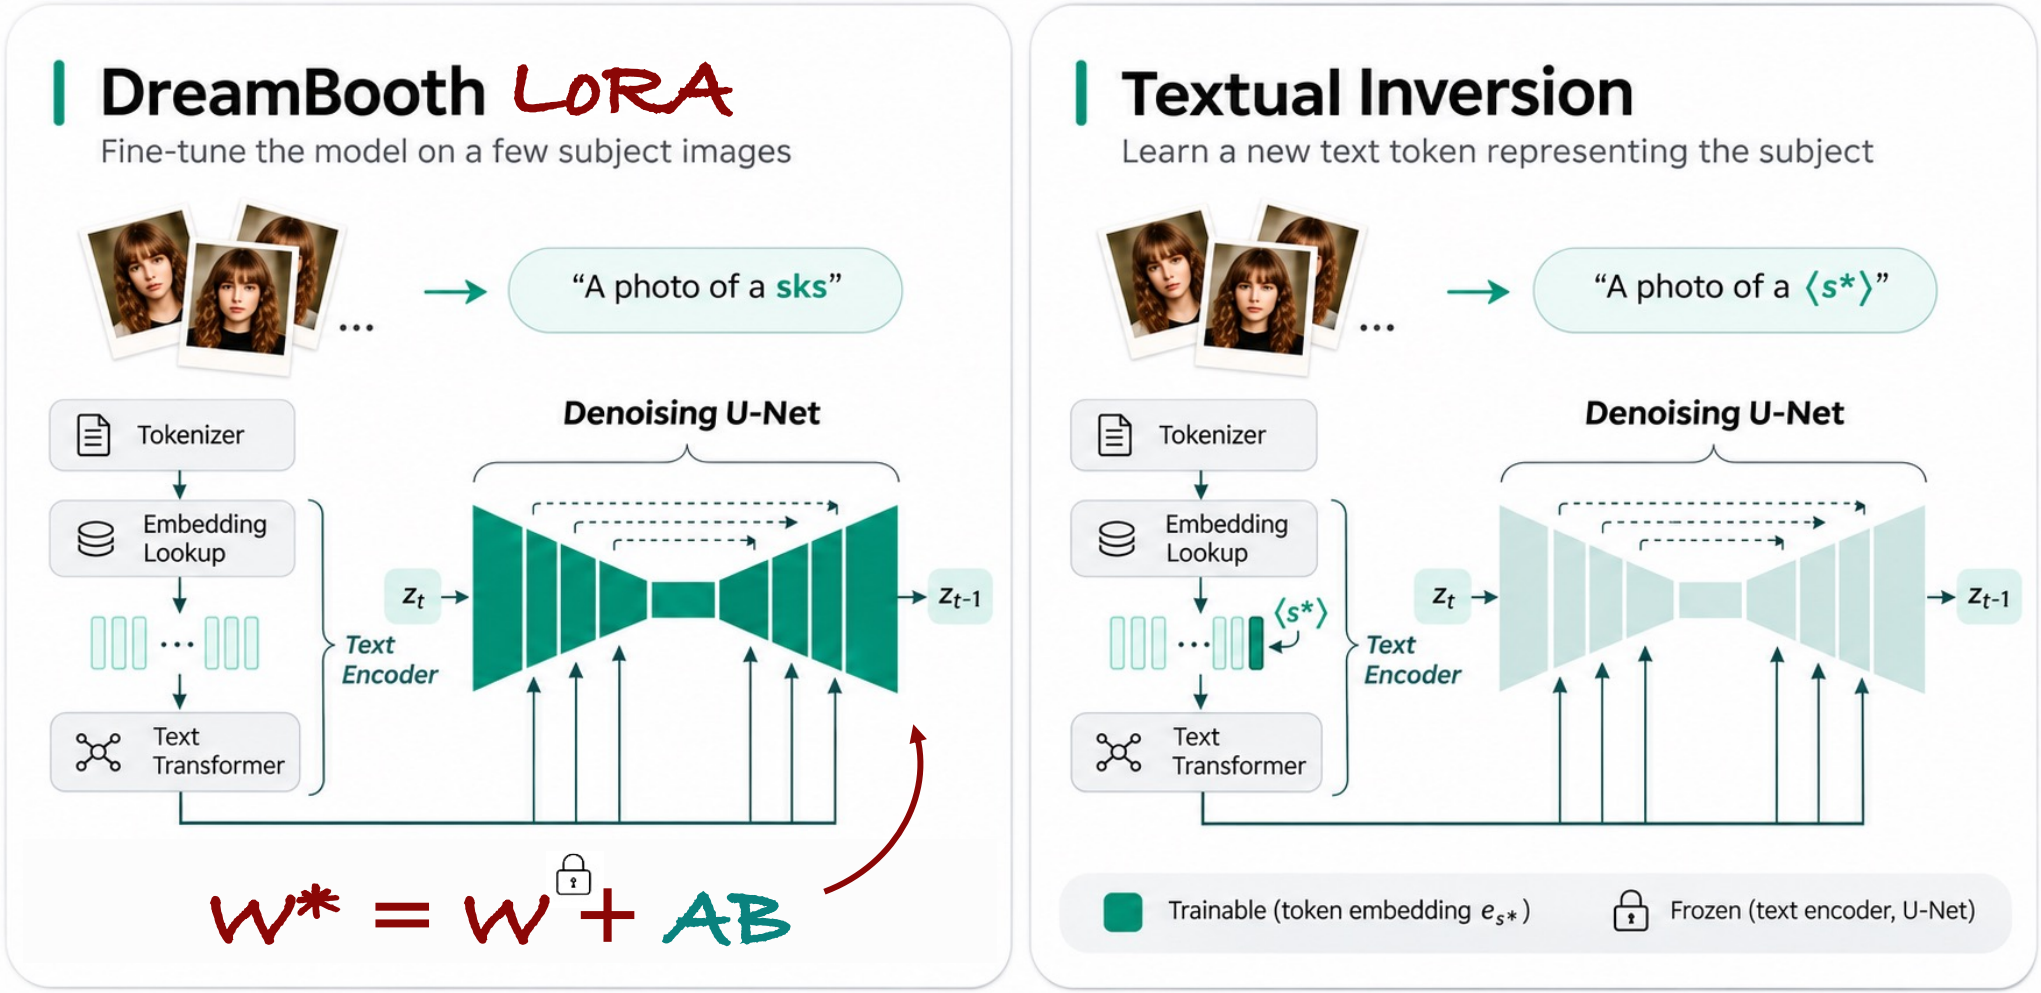
In-context generation

Референсы — часть общего входа модели

Персонализация через дообучение



Персонализация через дообучение



Персонализация через дообучение

DreamBooth /DB LoRA

Fine-tune the model on a few subject images

Concept





...running on a treadmill



...riding a bike



...in a wizard's robe in a forest at midnight, purples and sparkling silver tones



...wearing a space helmet, among stars in a cosmic landscape during a starry night

Textual Inversion

Learn a new text token representing the subject



Что можно обучать?

DreamBooth	Textual Inversion	LoRA
Учим весь Unet/DiT	Новый embedding токена	Низкоранговые обновления
Выразительная адаптация	Минимум параметров	Дешевле хранить и обучать
Переобучается	Ограниченная ёмкость	Также склонна к переобучению

LoRA - основной метод генерации людей до 2026 года

Основной способ борьбы с переобучением – разнообразный датасет.



Оригинал

Flux 1
fine-tuning
~5 min



Сгенерированные картинки

Генерация объектов с LoRA

Не редко у объектов мало данных, сложные формы и большой объем типографии.



проблема с текстом



проблема с формой

Генерация объектов с LoRA

Борьба с переобучением:

- Маскированный лосс
- Аугментации
- Использование ControlNet при генерации
- Балансировка – используем ControlNet не на всех шагах семплинга, а только на первых N где создаются формы, чтобы уменьшить блюр на фоне
- Используем адаптеры, менее склонные к переобучению, например T-LoRA



Считаем лосс только внутри маски





Предварительно создадим Canny Edges объекта и подадим ее в Control Net

Как отказаться от долгого обучения?



А давайте один раз обучим feature extractor для картинок и будем подмешивать фичи в генерацию?

Как отказаться от долгого обучения?



1. Учим на одном домене
2. Во все слои подмешиваем одни и те же фичи
3. Слабые внутренние представления

Новая парадигма

Текст + изображения → новое изображение

Одна модель может делать генерацию, редактирование и перенос субъекта.

Text-to-image

Editing

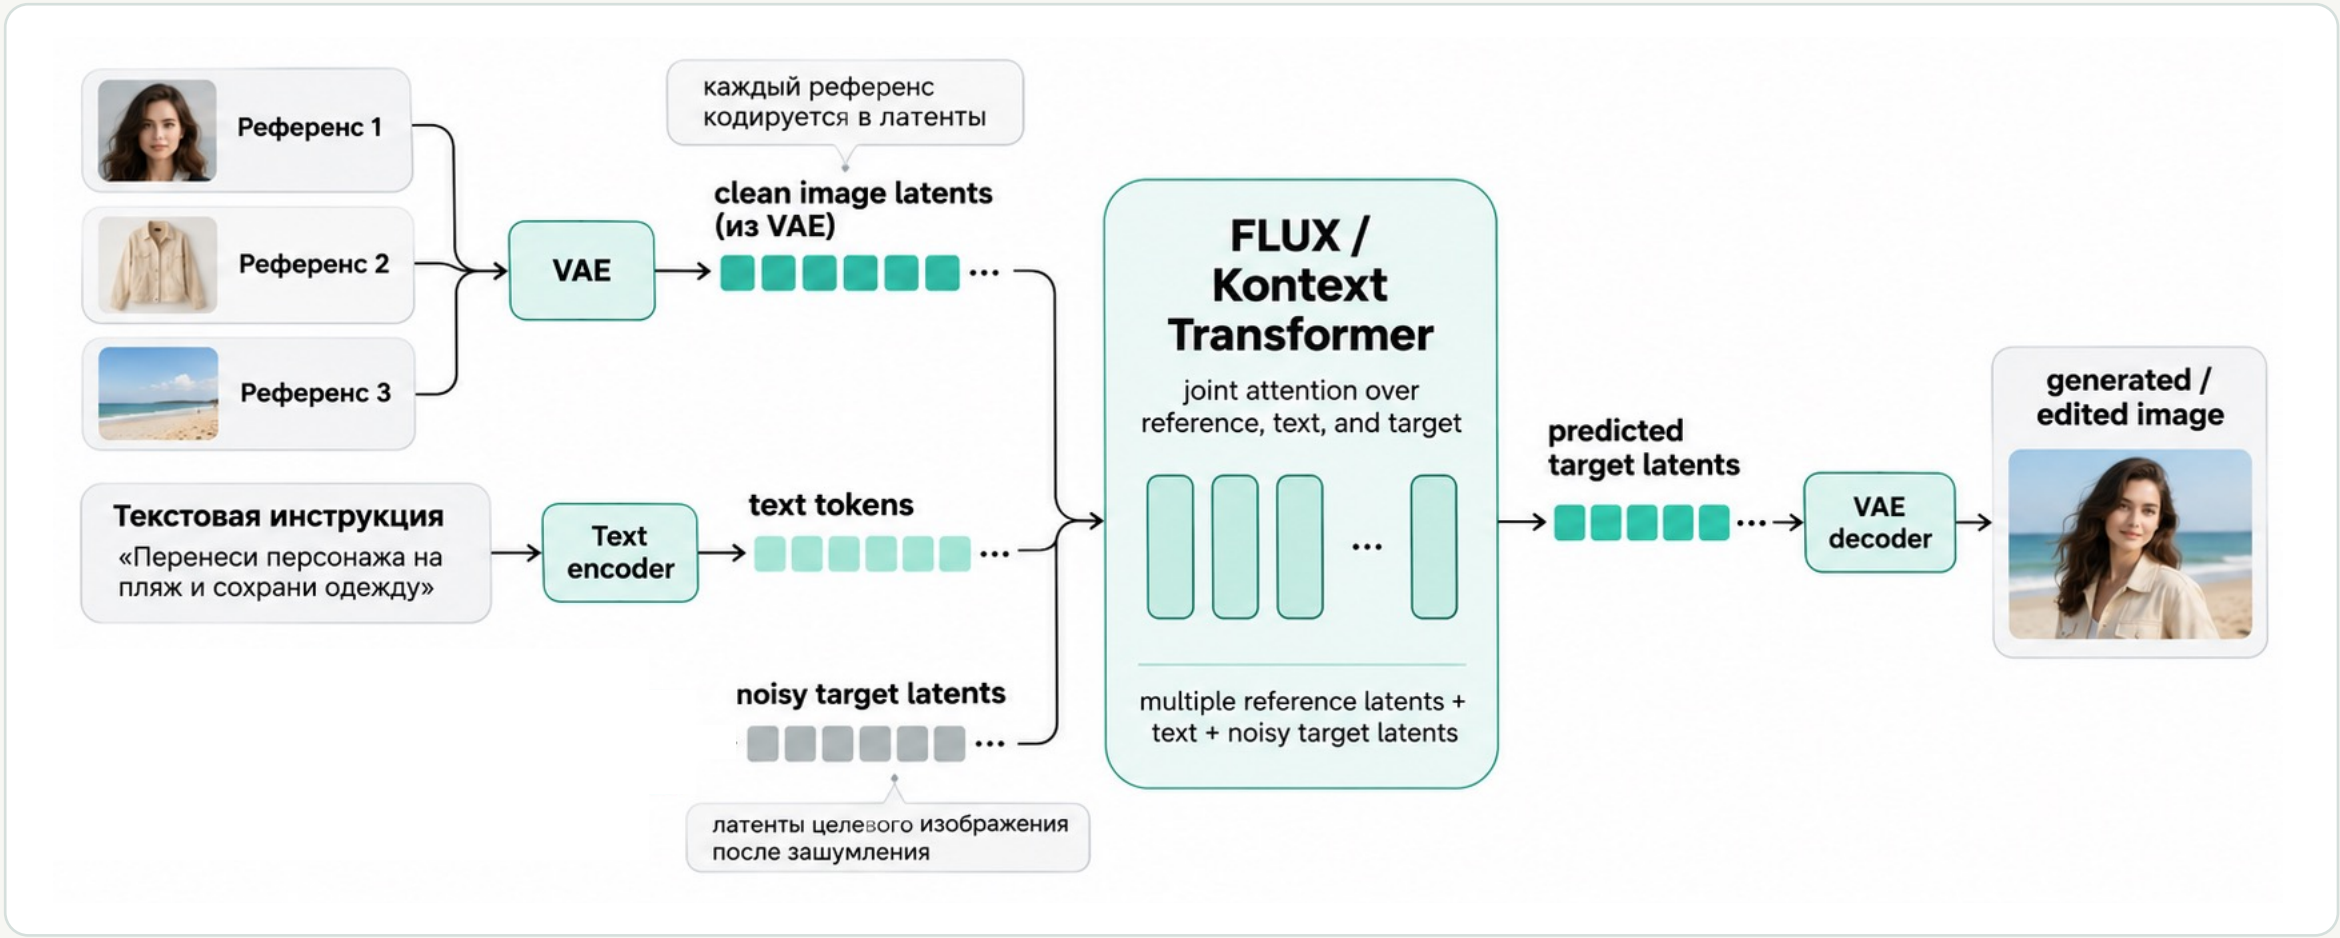
Multi-reference

Image adapter ≠ in-context модель

1. Работа с изображениями стала нативной способностью самой генеративной модели, а не дополнительной функцией, прикрученной к text-to-image backbone.

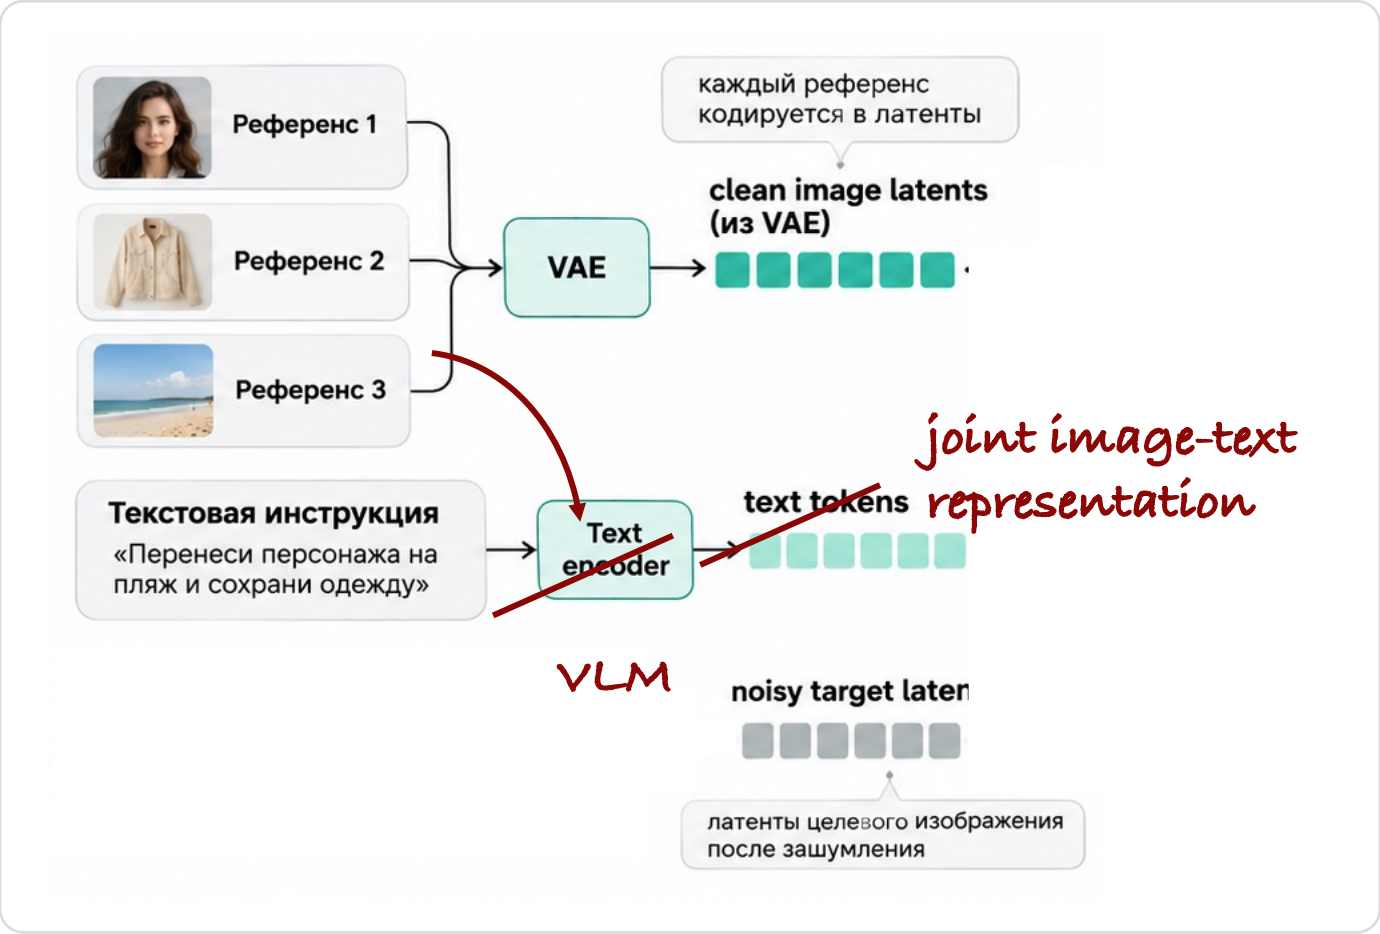
2. Изменились обучающие данные и задачи, на которых обучалась модель:
   - Один и тот же человек в разных позах, ракурсах и условиях освещения.
   - Один объект в разных сценах, но с неизменной геометрией.
   - Локальные изменения, при которых остальные части изображения должны оставаться прежними.
   - Несколько референсов, из которых нужно правильно перенести разные сущности.
   - Последовательности редактирований, где идентичность должна сохраняться на протяжении нескольких шагов.

FLUX.1 Kontext: общая архитектура



Источник: FLUX Kontext.pdf, Batifol et al., 2025

Qwen Image Edit: VLM как text encoder

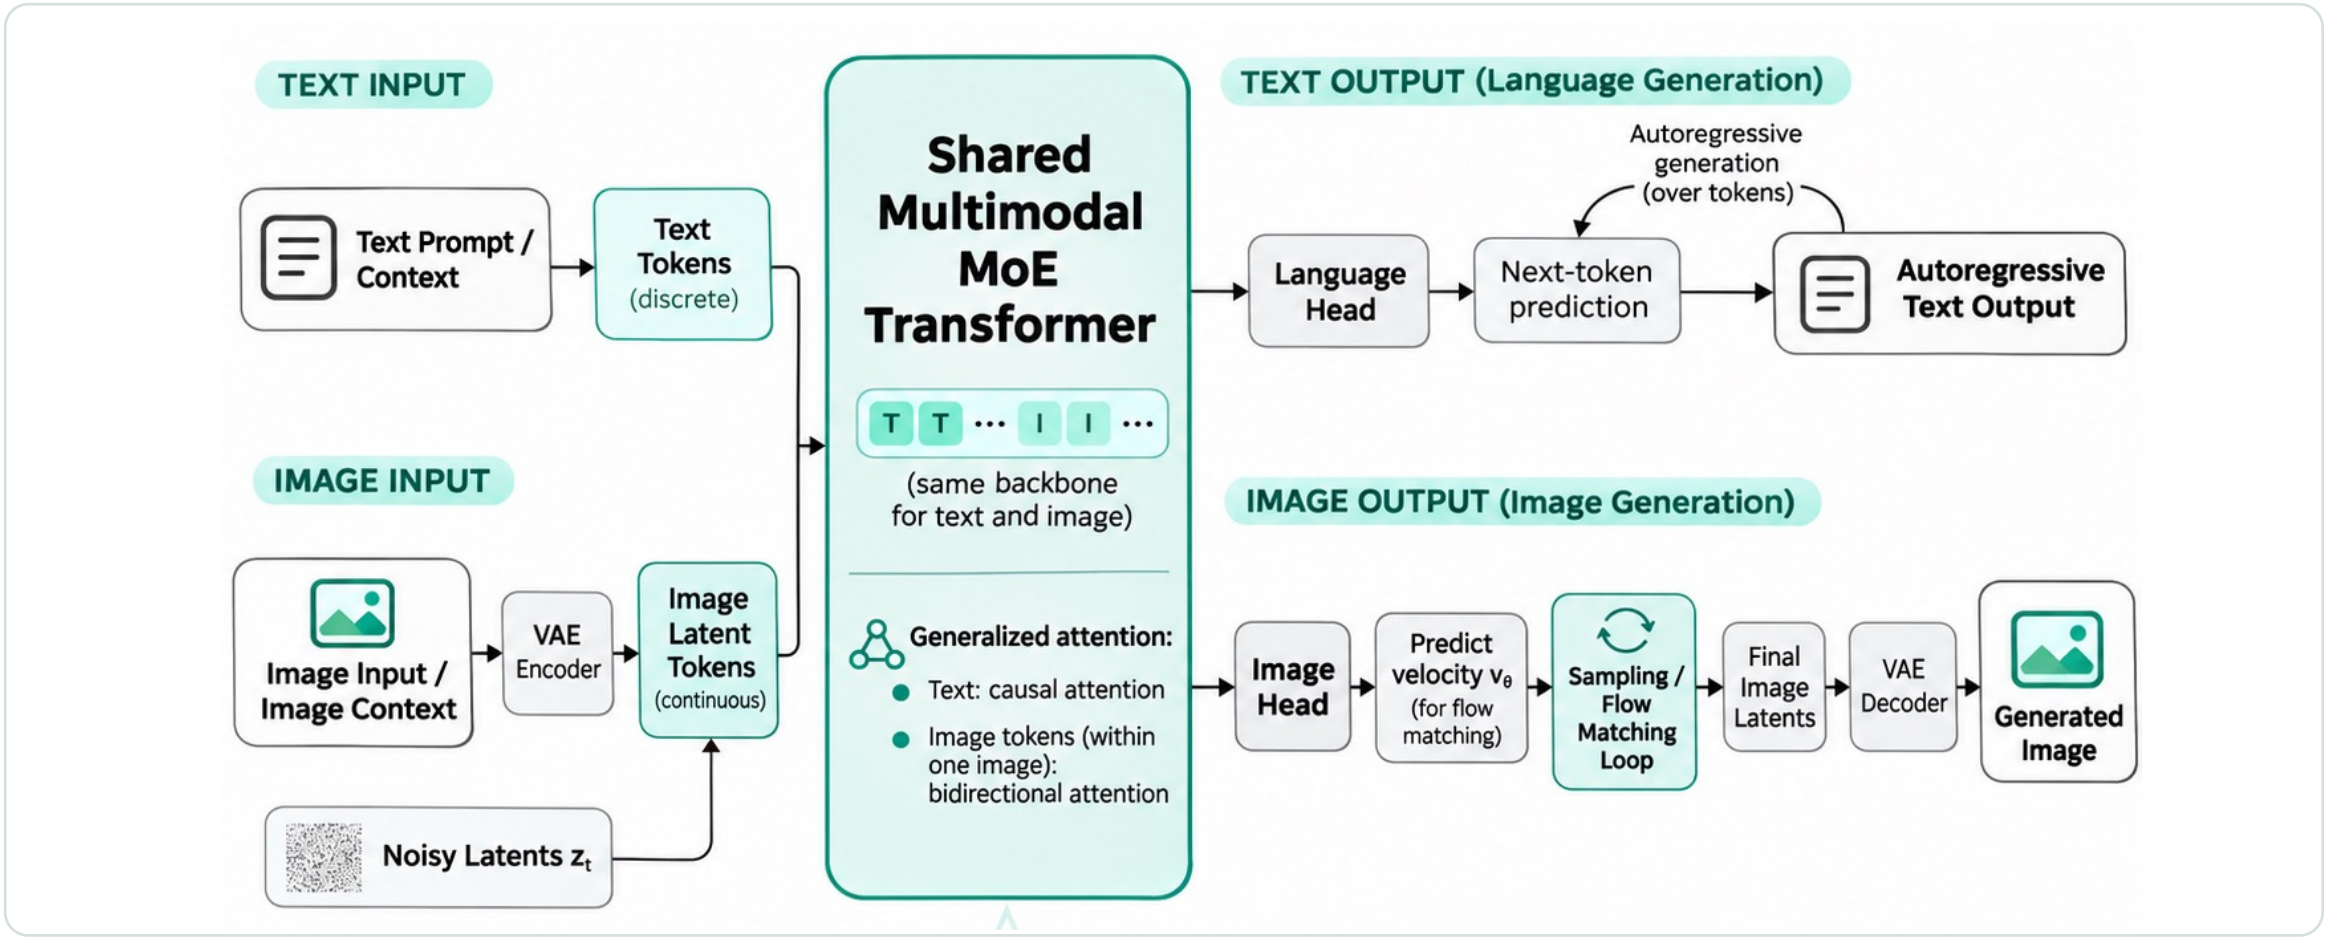


Получаем совместное представление картинок и текста,

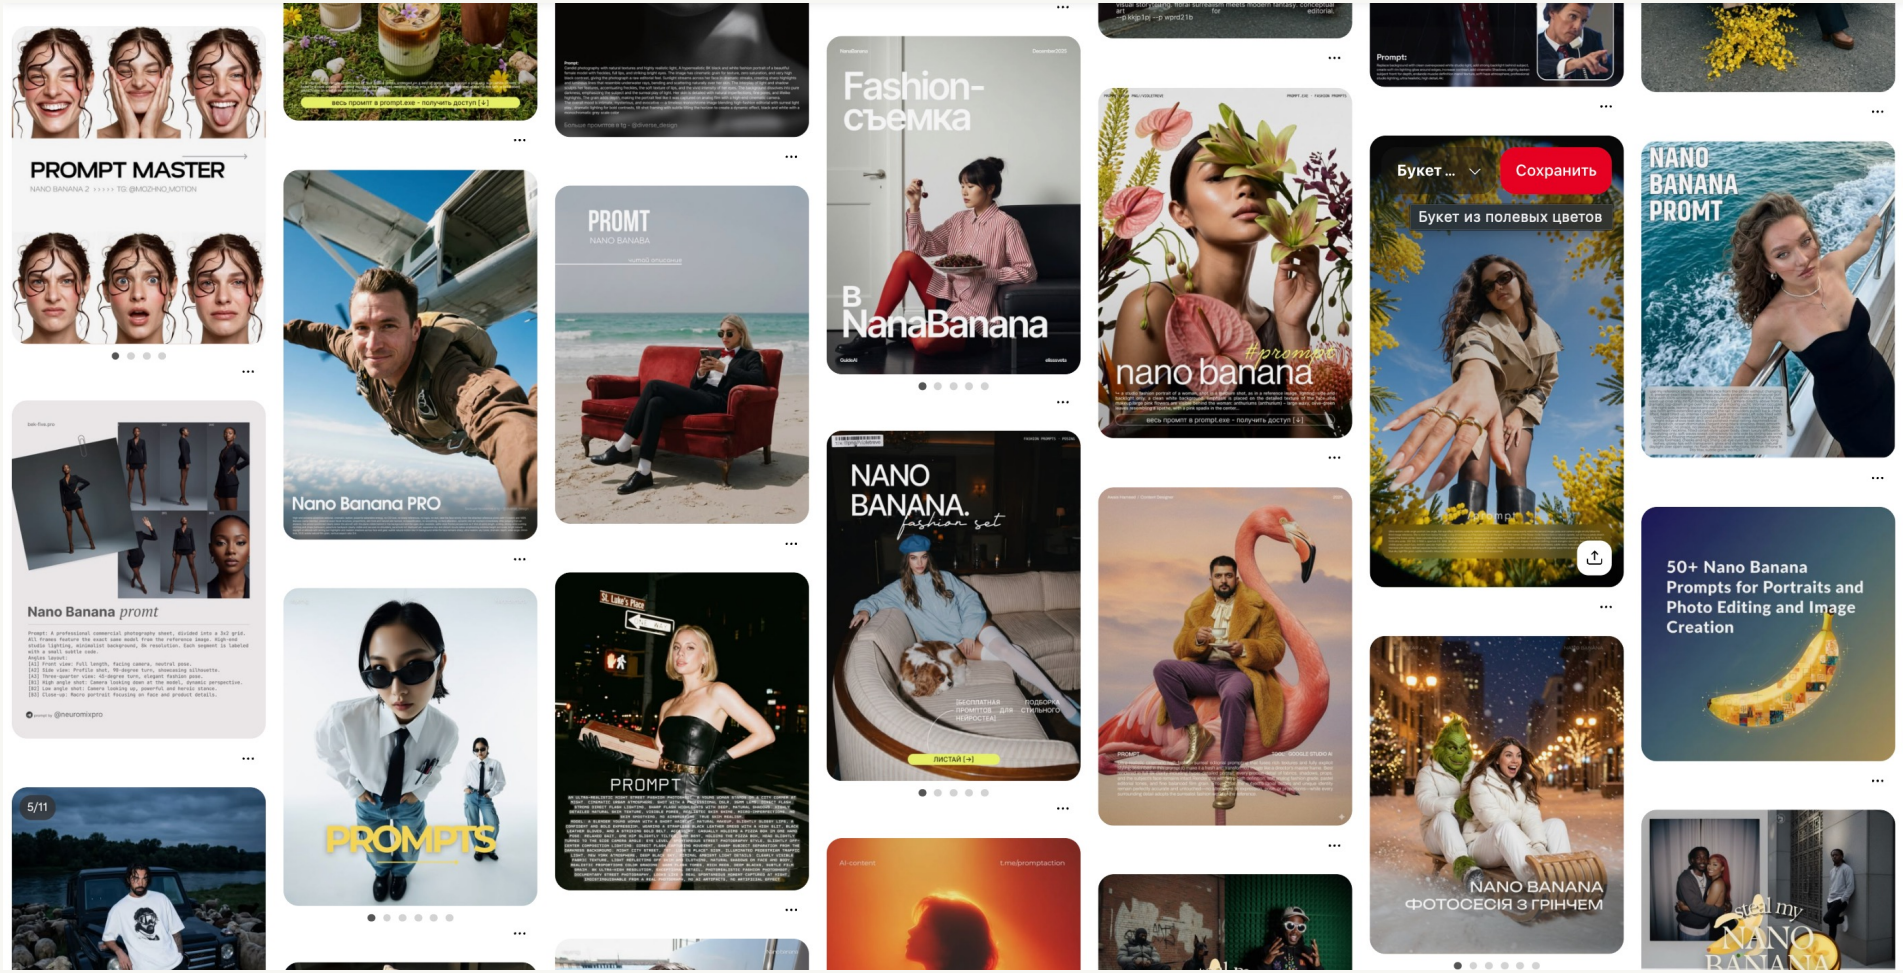
Появляется новая возможность:

Можем включить ризонинг для формирования более точных инструкций.

HunyanImage: один backbone и для текста и для картинок



Куда нас всех это привело?



Но есть одно ”НО”















Генерировать заново или исправлять?

01

Generate

Сильная базовая модель создаёт сцену

→

02

Verify

Найдены локальные identity errors

→

03

Correct

Локальная коррекция без смены композиции

KandiShop: как исправить уже сгенерированное изображение?

За один проход модель решает сразу две задачи, которые тянут в разные стороны:

- **творческую** — поставить человека в новую позу, перерисовать свет под сцену, вписать его в композицию;
- **копировальную** — перенести каждую родинку и каждую букву с точностью до пикселя.



KandiShop: как исправить уже сгенерированное изображение?

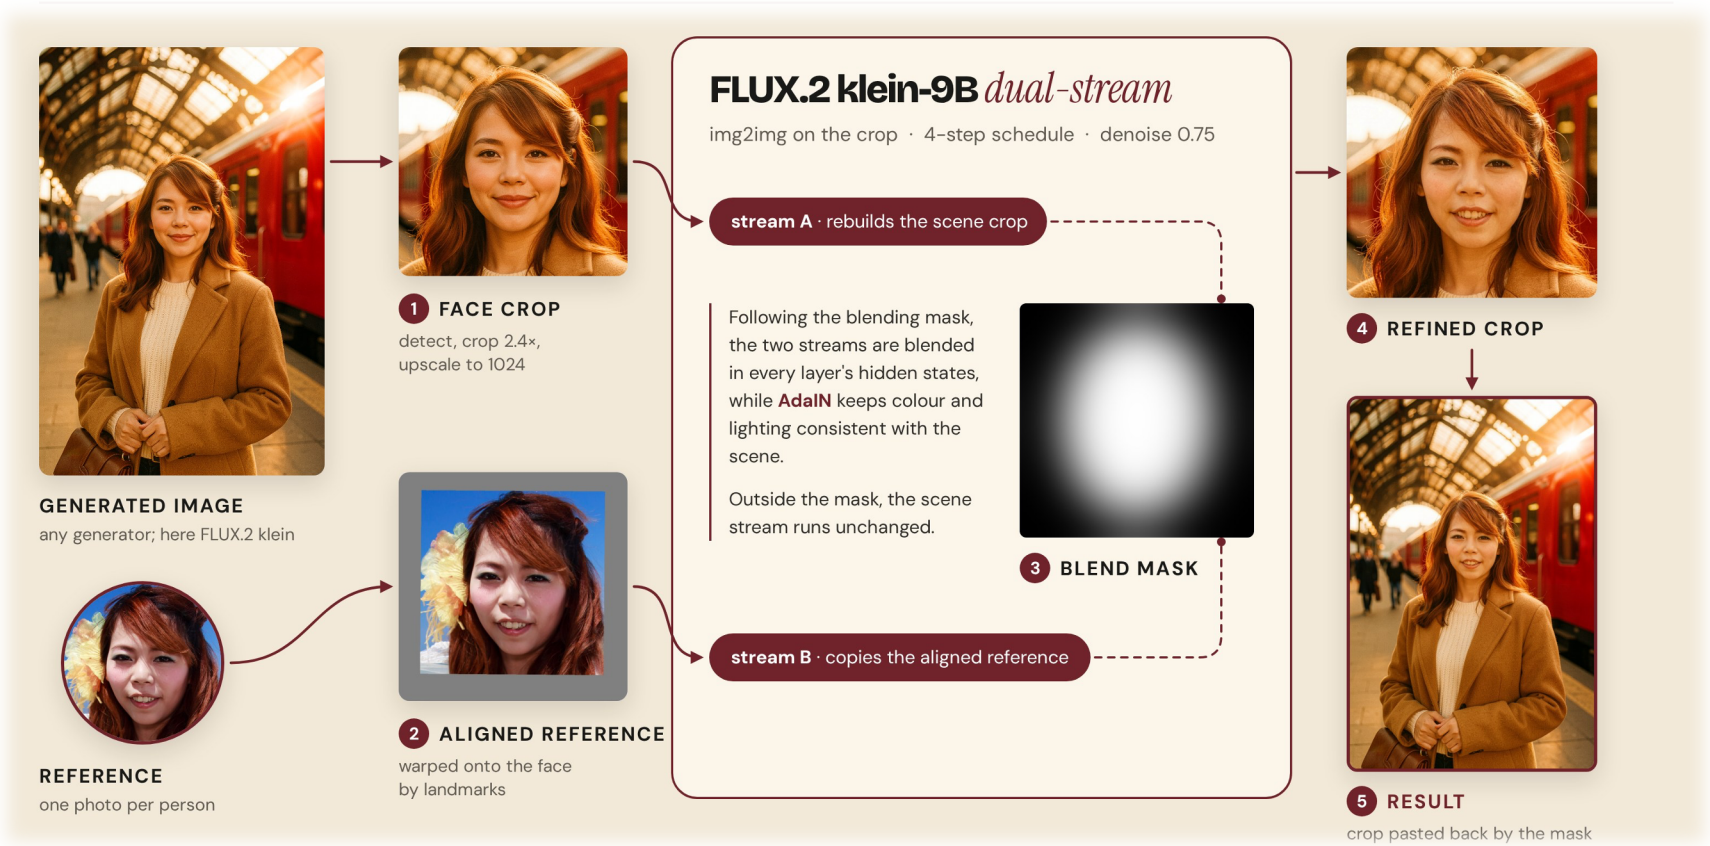
За один проход модель решает сразу две задачи, которые тянут в разные стороны:

- **творческую** — поставить человека в новую позу, перерисовать свет под сцену, вписать его в композицию;
- **копировальную** — перенести каждую родинку и каждую букву с точностью до пикселя.



Идея: два потока генерации

Задачи можно развести: пусть один процесс отвечает за сцену, другой — за точное копирование, и при этом оба работают над одной и той же картинкой.



Идея: два потока генерации

Зашумим сцену на N таймстепов назад и расшумим их обратно следующим форвардом:

$$\tilde{\mathbf{z}}^{(i)}_{\text{crop}}, \mathbf{u}^{(i)}_{\text{crop}}, \mathbf{c}^{(i)}_{\text{crop}} = \mathcal{B}_i\left(\mathbf{z}^{(i-1)}, \mathbf{u}^{(i-1)}_{\text{crop}}, \mathbf{c}^{(i-1)}_{\text{crop}}; t\right),$$
$$\tilde{\mathbf{z}}^{(i)}_{\text{ref}}, \mathbf{u}^{(i)}_{\text{ref}}, \mathbf{c}^{(i)}_{\text{ref}} = \mathcal{B}_i\left(\mathbf{z}^{(i-1)}, \mathbf{u}^{(i-1)}_{\text{ref}}, \mathbf{c}^{(i-1)}_{\text{ref}}; t\right).$$

Получаем 2 выхода блока из одного латента – один делающий копию референсного лица, второй – копию сцены

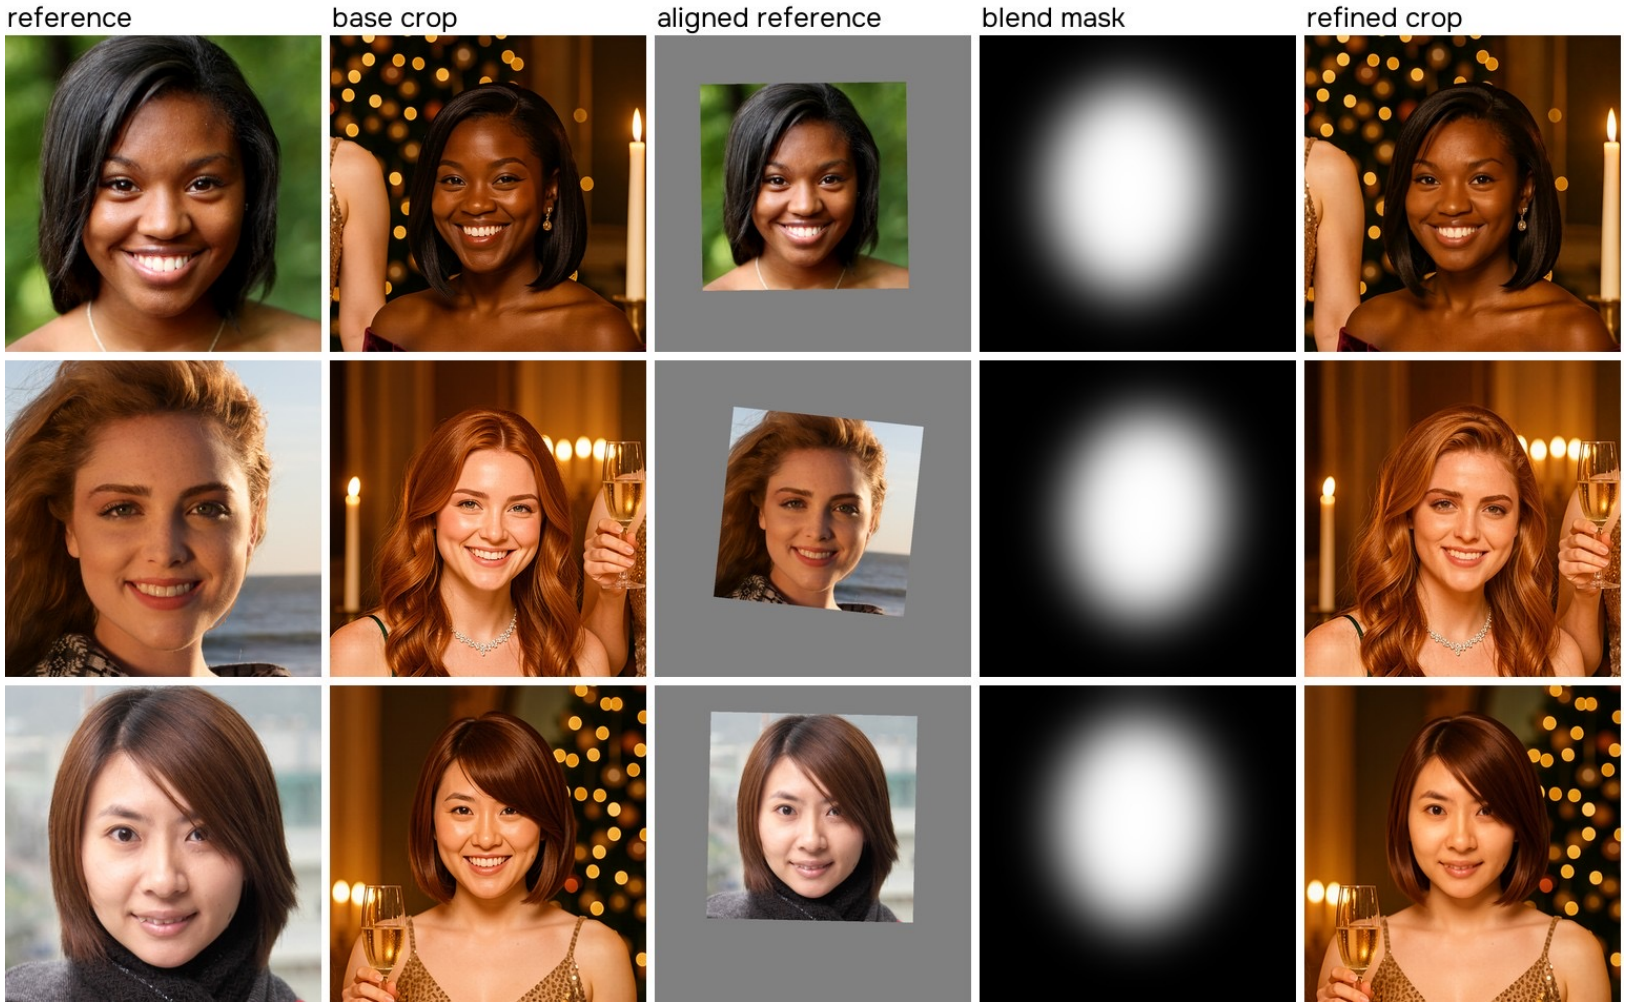
$$\hat{\mathbf{z}}^{(i)}_{\text{ref}} = \sigma\left(\tilde{\mathbf{z}}^{(i)}_{\text{crop}}\right)_{\mathbf{M}} \left(\frac{\tilde{\mathbf{z}}^{(i)}_{\text{ref}} - \mu\left(\tilde{\mathbf{z}}^{(i)}_{\text{ref}}\right)_{\mathbf{M}}}{\sigma\left(\tilde{\mathbf{z}}^{(i)}_{\text{ref}}\right)_{\mathbf{M}} + \epsilon} \right) + \mu\left(\tilde{\mathbf{z}}^{(i)}_{\text{crop}}\right)_{\mathbf{M}}$$

AdaIN для выравнивания света внутри маски

$$\mathbf{z}^{(i)} = \hat{\mathbf{z}}^{(i)}_{\text{ref}} \odot \mathbf{M} + \tilde{\mathbf{z}}^{(i)}_{\text{crop}} \odot (1 - \mathbf{M})$$

Внутри маски берем результат от референса, снаружи – от сцены

Выравнивание референса и таргета

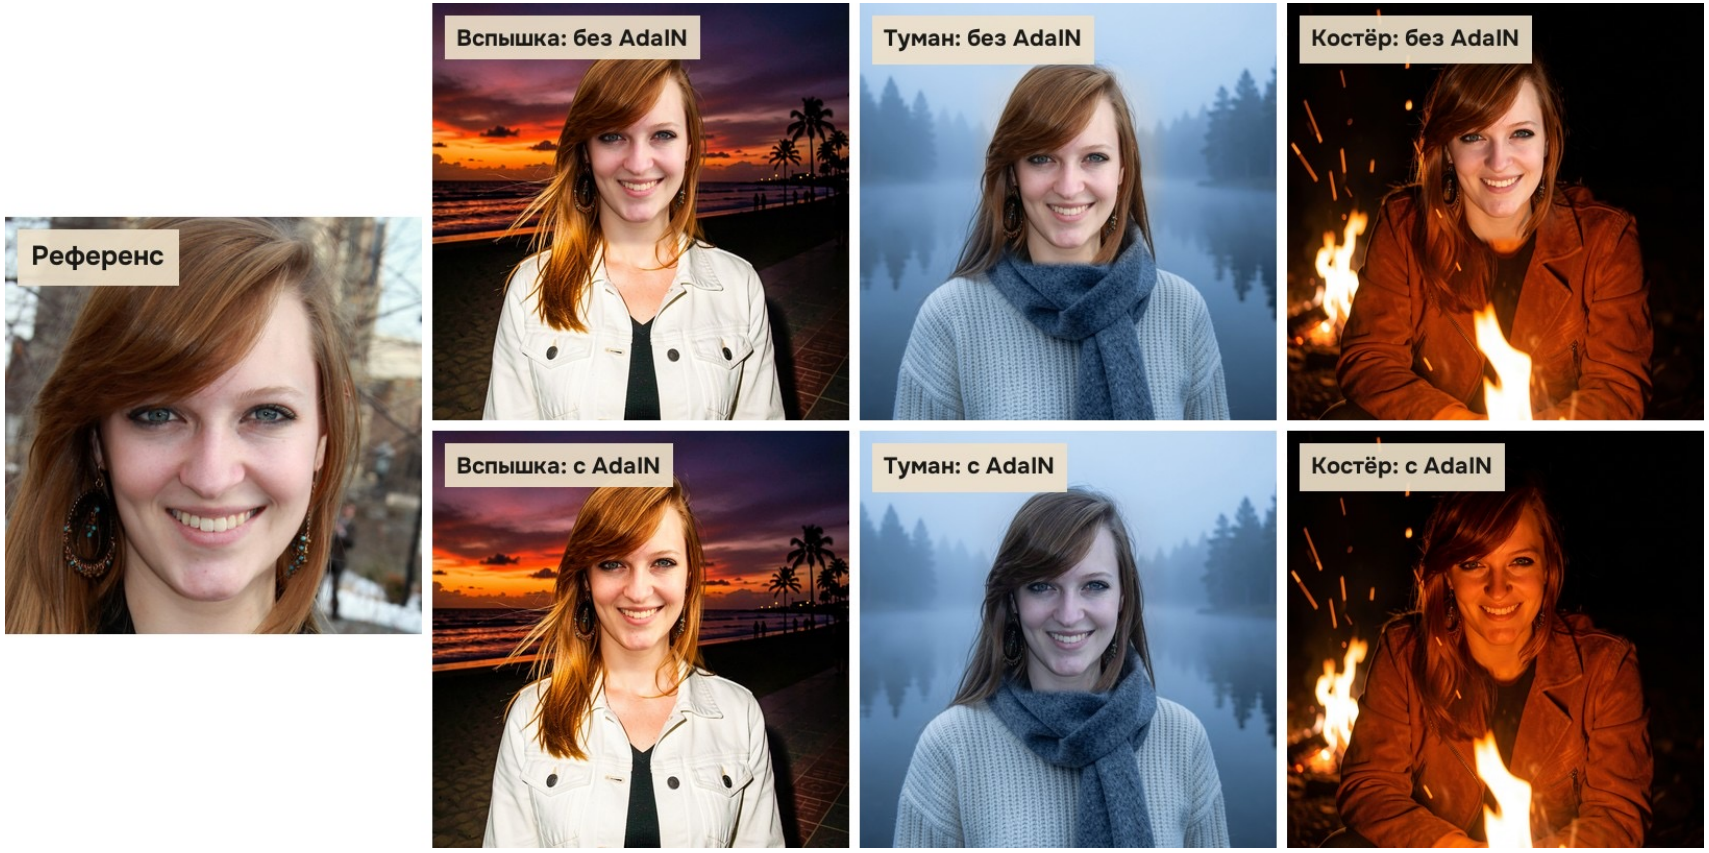


1) находим самого похожего человека на фото
2) рефайним его лицо
3) вставляем обратно
4) переходим к следующему

Результат до/после

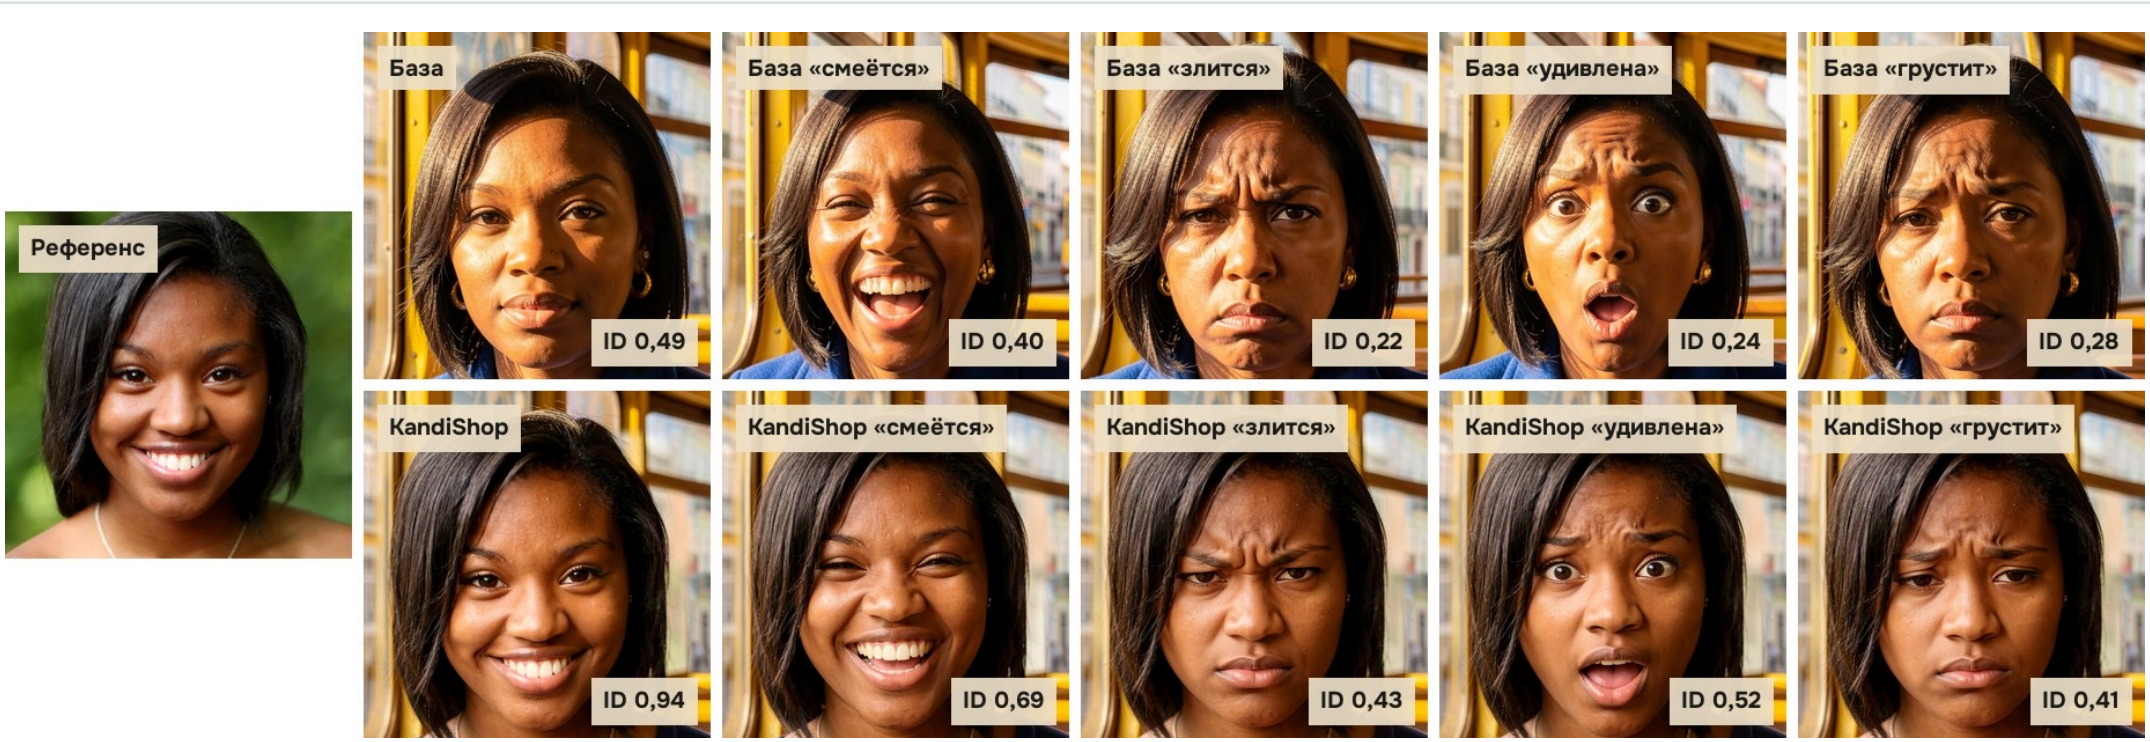


Роль AdaIN: выравнивание освещения



Добавляем эмоции

Просто поменять копирующий промпт на промпт с изменением эмоции – "сделай копию, но теперь человек злится" – можно добавить эмоцию сохранив узнаваемость и не потерять сцену.



А что на счет объектов?

reference



base crop



aligned reference



blend mask



refined crop



BEFORE



AFTER



BEFORE (zoom)



AFTER (zoom)



Метрики

Люди

Модель	ID ↑: без → с KandiShop	HPSv3 ↑: без → с KandiShop
FLUX.2 klein 9B	0,519 → 0,748	11,36 → 11,37
FLUX.2-dev	0,504 → 0,752	10,42 → 10,35
Qwen-Image-Edit-2511	0,239 → 0,655	10,48 → 10,32
HunyuanImage 3.0 Instruct-Distil	0,492 → 0,842	11,41 → 11,08
Nano Banana Pro	0,571	11,09
GPT Image 2 High	0,861	10,59

Объекты

Модель	OCR F1 ↑	CER ↓	LPIPS ↓	HPSv3 ↑
FLUX.2 klein 9B	0,762 → 0,841	0,654 → 0,506	0,152 → 0,139	12,04 → 12,05
FLUX.2-dev	0,725 → 0,821	0,653 → 0,518	0,166 → 0,137	11,55 → 11,55
Qwen-Image-Edit-2511	0,635 → 0,721	0,710 → 0,552	0,167 → 0,158	11,34 → 11,29
HunyuanImage 3.0 Instruct-Distil	0,744 → 0,870	0,566 → 0,296	0,142 → 0,094	12,31 → 12,22
Nano Banana Pro	0,777	0,710	0,142	12,26
GPT Image 2 High	0,819	0,579	0,118	11,79

Можно ли редактировать картинку из другого генератора?

Результаты редактирования выходов Nano Banana методом реализованным на Flux-klein-9B

Метрика	Nano Banana Pro	+ KandiShop	Разница
Лица: ID ↑	0,571	0,761	+0,190
Лица: HPSv3 ↑	11,09	11,09	0,00
Товары: OCR F1 ↑	0,777	0,825	+0,048
Товары: CER ↓	0,710	0,580	−0,130
Товары: HPSv3 ↑	12,26	12,18	−0,08

Swap объектов и лица

Если расшумлять с нуля а не с промежуточного латента – легко перейти к полному свопу.



Swap объектов и лица

Если расшумлять с нуля а не с промежуточного латента – легко перейти к полному свопу.



Итоги

- Позволяет редактировать лица и сложную типографику, делать полный head/object swap с точным сохранением черт субъекта и идеальным сохранением фона.

- Не имеет значения какой моделью сгенерирована оригинальная картинка, которую хотим редактировать.

- На дистиллированном FLUX-klein-9B (4 шага) метод работает на 1 H100 за ~7 секунд

- Попробовать:



https://v-gen-ai.github.io/KandiShop/

Три главных вывода

01 **Персонализация стала in-context задачей**

Вместо отдельного обучения под субъекта — визуальные референсы в общем контексте.

02 **Проблемы в деталях**

Черты лица, сложная типографика, лейблы – сложные кейсы, особенно для open-source моделей.

03 **Детали можно восстанавливать меняя лишь инференс**

Ответы во внутренних представлениях моделей.

Спасибо за внимание!



@ONLYGENSAI

Вера Соболева
FusionBrain Lab, AIRI