DLS

Модели Мира, Physical AI, и конечно же Kandinsky

Андрей Иванюта, к.ф.-м.н.,
рук-ль Kandinsky World Model,
Kandinsky Lab, Sber.

Интро

Это последняя лекция.

Давайте вынырнем из технических глубин и...
немного подумаем.

---

*Рассказать шутейку про ученика Резерфорда

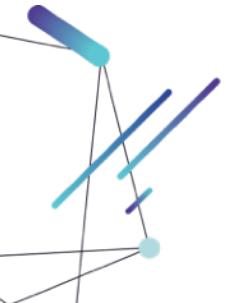

План

01 Введение. Разговор о Physical AI

02 Что такое Модель Мира и зачем это?

03 Примеры и проблемы

04 А как это всё измерить и сравнить?

05 Что мы делаем в Kandinsky?

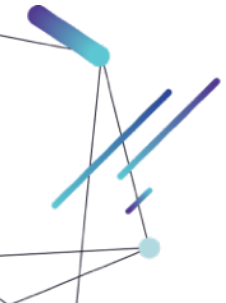

DLS

Разговор о Physical AI

Тест Возняка

Незнакомый дом.
Задача: «Приготовь кофе»

01 найти кухню

02 разобраться с предметами

03 собрать план

04 ничего не разбить

Стив Возняк
сооснователь Apple

Почему нам это кажется простым

Все вычисления происходят бессознательно, автоматически

Мозг оценивает положение и вес чашки выбирает силу захвата и непрерывно корректирует движение руки.

«Просто» - значит доведено до автоматизма

**Мы учимся этому с рождения.
Плюс, у нас хороший претрейн**

Парадокс Моравека

Ханс Моравек – робототехник, Carnegie Mellon

1997: Deep Blue побеждает Каспарова, чемпиона мира

1997: первый RoboCup.
Цель: обыграть чемпионов к 2050

В физическом мире естественный интеллект пока сильнее

Движение, ориентация, работа с предметами, адаптация к новому.

Что случится раньше?

Победа (

ДАНИИЛ КВЯТ ПРОИГРАЛ БЕСПИЛОТНОМУ АВТОМОБИЛЮ В ГОНКЕ НА ЯС-МАРИНЕ

16 ноября 2025 в 11:21

Фото: Соцсети

Российский пилот, трёхкратный призёр Гран При Формулы 1 Даниил Квят в третий раз в карьере принял участие в соревновании с беспилотным автомобилем. И если в прошлом году на Яс-Марине и Сузуке он превзошёл конкурента в лице искусственного интеллекта, то в этот раз проиграл.

к поедет в школу самостоятельно?

Навье—Стокс

Новая модель OpenAI 8 сентября 2026 года решила одну из задач тысячелетия

Уравнения описывают движение жидкостей и газов *

≈90 лет

вопрос оставался открытым

88 часов

около 10 000 ИИ-агентов

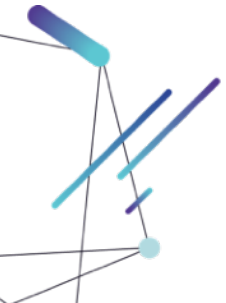

***Но налить воду в чашку на незнакомой кухне роботу всё ещё трудно**

Про сложные взаимодействия

1. Кажется, мы серьёзно переоцениваем когнитивные способности, а сложность на самом деле не там где мы думали.

2. Робота надо бы учить именно взаимодействовать. А можно ли дать ему такой же претрейн как у человека?

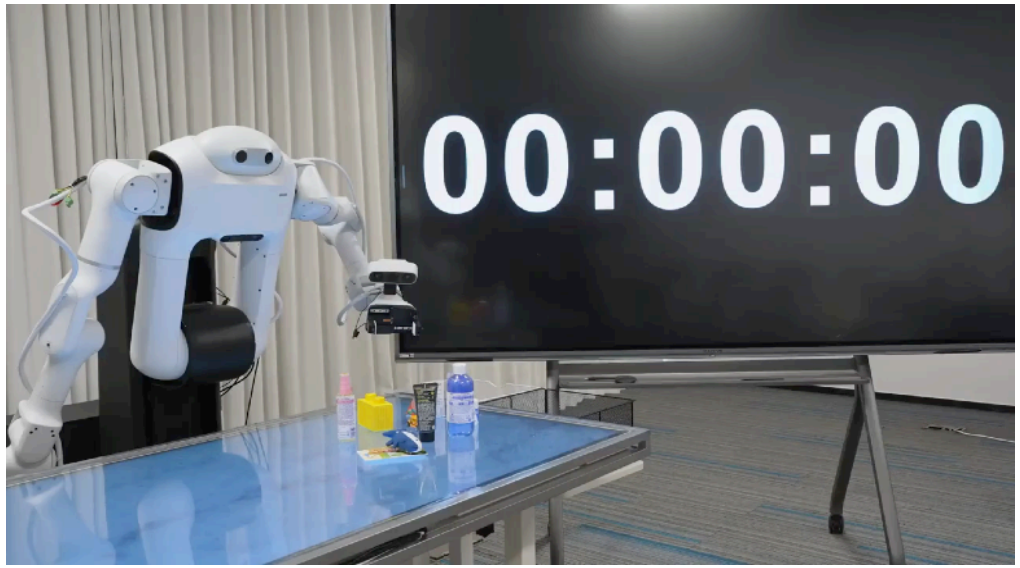

Результат Sudo R1:
Обучался только на синтезированных видео и достиг ~98% успешности в перекладывании предметов

Требования к данным

Для обучения роботов требуются видео данные, с повышенным требованием к следованию управлению и физичности. Мягкое должно быть мягким, твёрдое твёрдым, тяжелое тяжелым, жидкое должно правильно наливаться и т.д.

Примеры видео, которые нужно было сгенерить для AGIBOT WORLD challenge 2026

Наша ниша в Physical AI

Есть класс агентов с ИИ на борту, которые в физическом мире полагаются на компьютерное зрение (беспилотный авто, робот и тд).

Их надо как-то научить правильному пониманию и взаимодействию.

Есть разные пути этого добиться:

- LLM/VLM + физ движок + FT действия
- **WAM** (WM с модальностью действия)
- ...

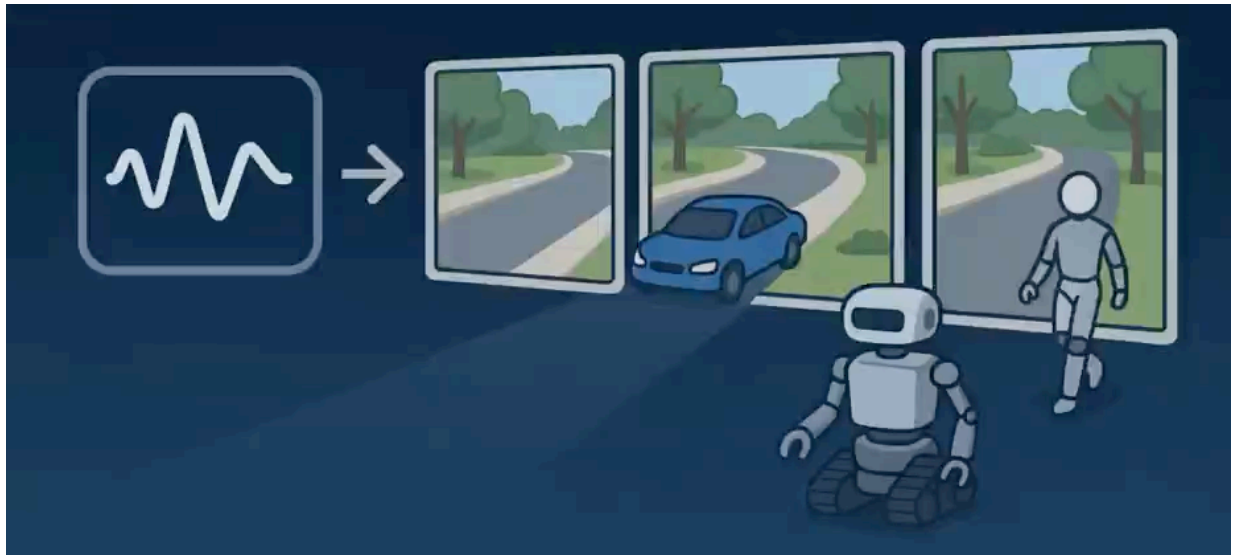

DLS

Что такое Модель Мира?

А что такое мир?

Мир — часть физической среды, подчиняющейся определенным законам, на которую мы можем воздействовать и получать наблюдения (меняя эту среду).

Хотим научиться строить модель этого мира, чтобы иметь возможность решать разные задачи (в том числе предсказывать будущие состояния мира).

Формализация

Мир — это пространство троек $(S,\ A,\ O)$ и динамика, которая связывает их во времени.
Динамика — это переход $P(s_{t+1},\ |\ s_t,\ a_t)$: как состояние мира меняется под воздействием агента.
Именно её (вместе с моделью наблюдений) мы и хотим выучить и предсказывать.
Назовём это «модель мира».

S — Состояния

полное описание мира в момент t — скрыто от агента

A — Действия

что агент может сделать в мире

O — Наблюдения

то, что агент видит — частичная проекция S

h — История

$h_t = (o_0, a_0, \ldots, a_{t-1}, o_t)$

всё, что агент видел и делал к моменту t

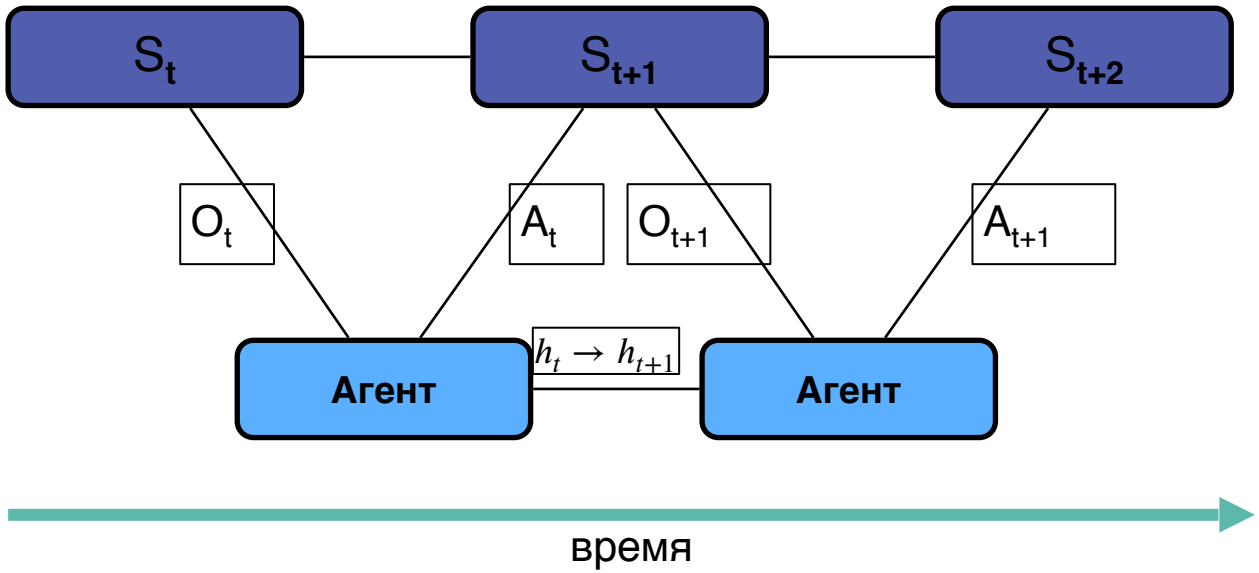

Таксономия моделей мира

Renderer
что видно — пиксели → O — Наблюдения

Simulator
честное состояние мира → S — Состояния

Planner
что делать дальше → A — Действия

Таксономия моделей мира

Renderer
выдаёт O

$$\approx \quad P(o_t \mid s_t)$$

Simulator
выдаёт S

$$\approx \quad P(s_{\{t+1\}} \mid s_t,\ a_t)$$

Planner
выдаёт A

$$\approx \quad P(a_t \mid h_t)$$

Renderer O

$P(o \mid s)$

Sora · Veo · Kandinsky
видео-модели

Genie 3 · RTFM
интерактивные

Nano Banana
изображения

Simulator S

$P(s' \mid s, a)$

MuJoCo · Isaac Sim
физ-движки

NVIDIA Omniverse
цифровые двойники

Marble (World Labs)
генеративные 3D-сцены

Planner A

$P(a \mid h)$

RT-2 · OpenVLA · π0
Vision-Language-Action

Gemini Robotics
World Action Models

Dreamer · MuZero
model-based RL

А где же JEPA?

Проблемы в робототехнике

Сбор данных для обучения робота:

- Медленно
- Дорого
- Кастомно

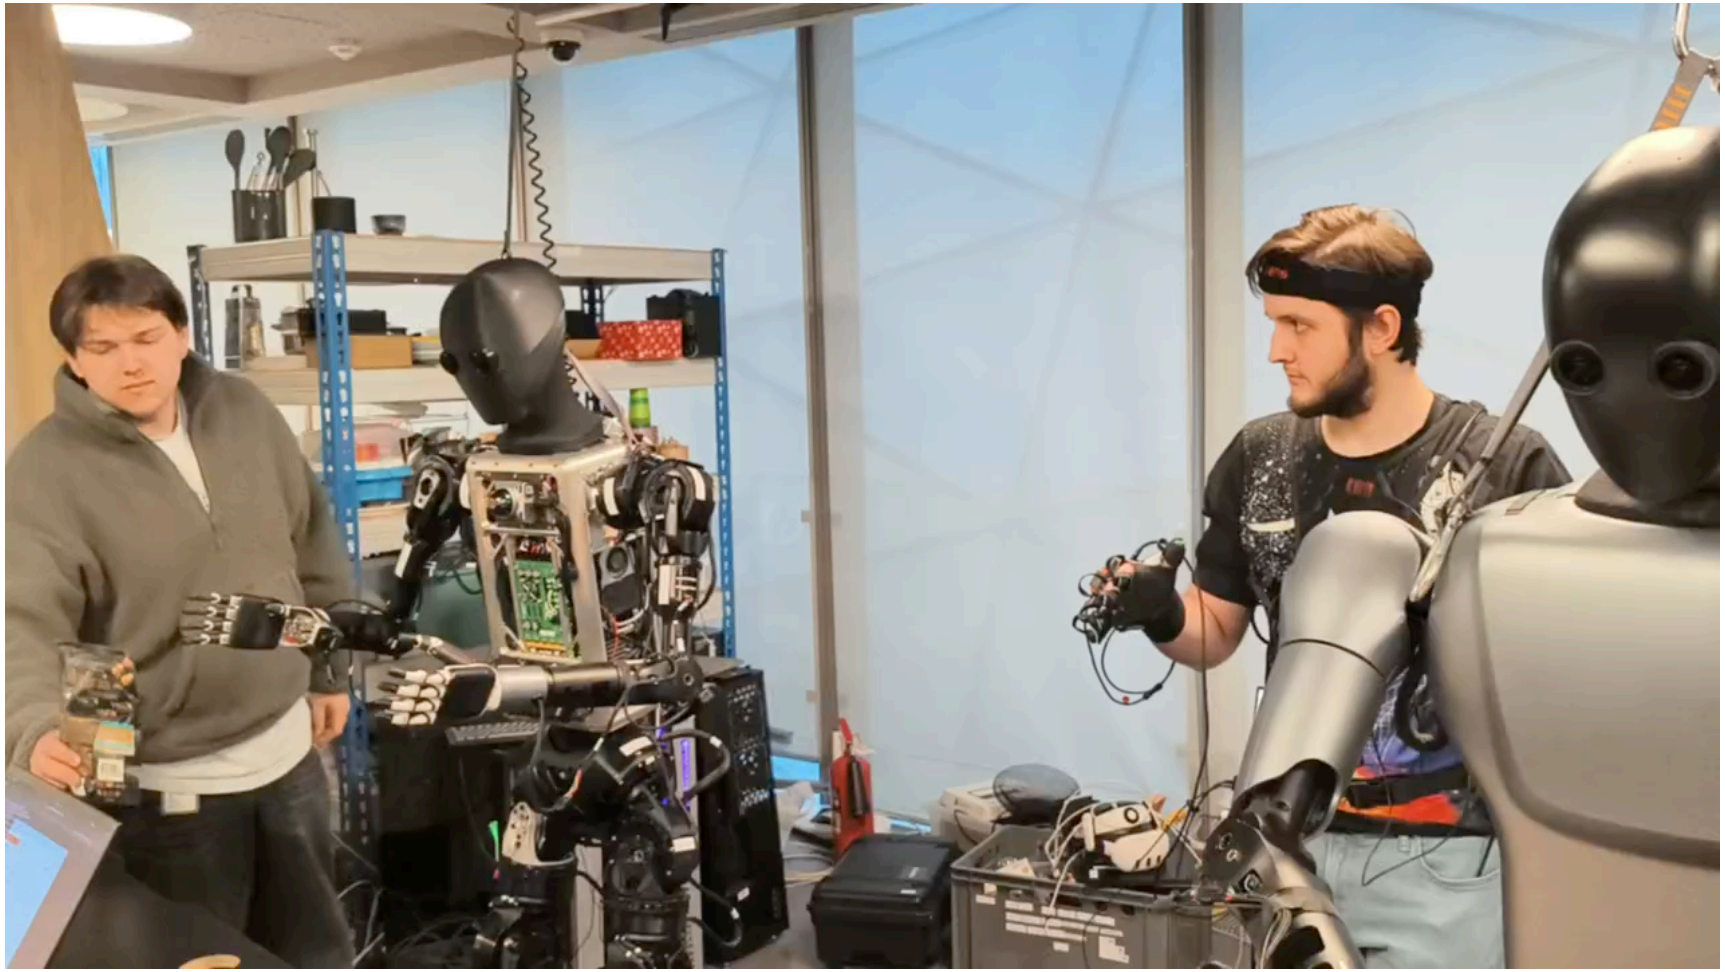

Проблемы в авто

Есть дорожные сценарии, которые сложно и дорого отснять.

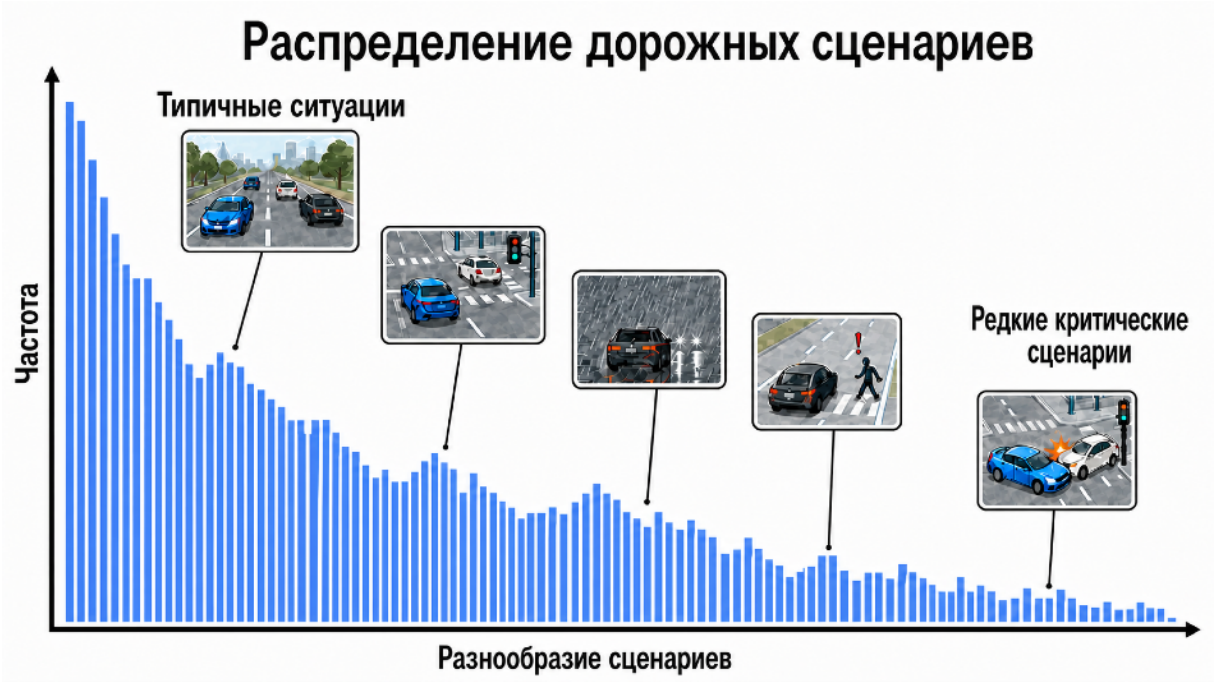

Сценарий: генерация синты

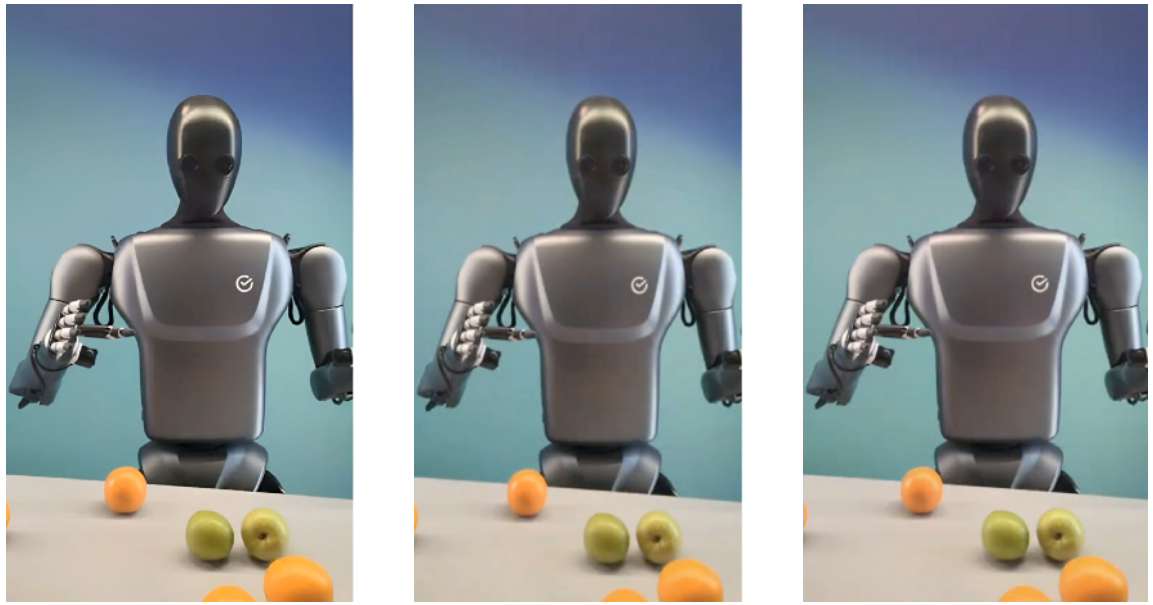

А почему это вообще возможно?
За счёт большой обобщающей способности претрейна.

Сценарий: обучение

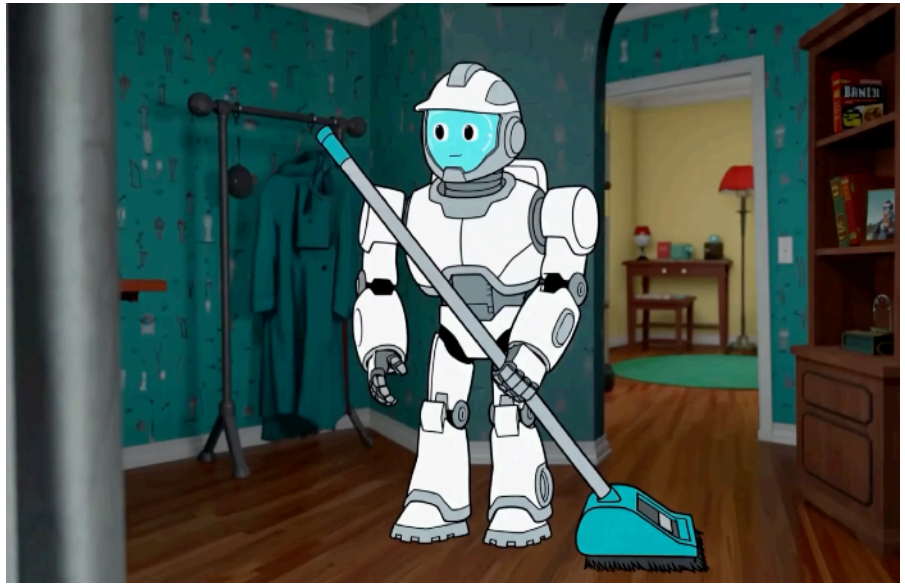

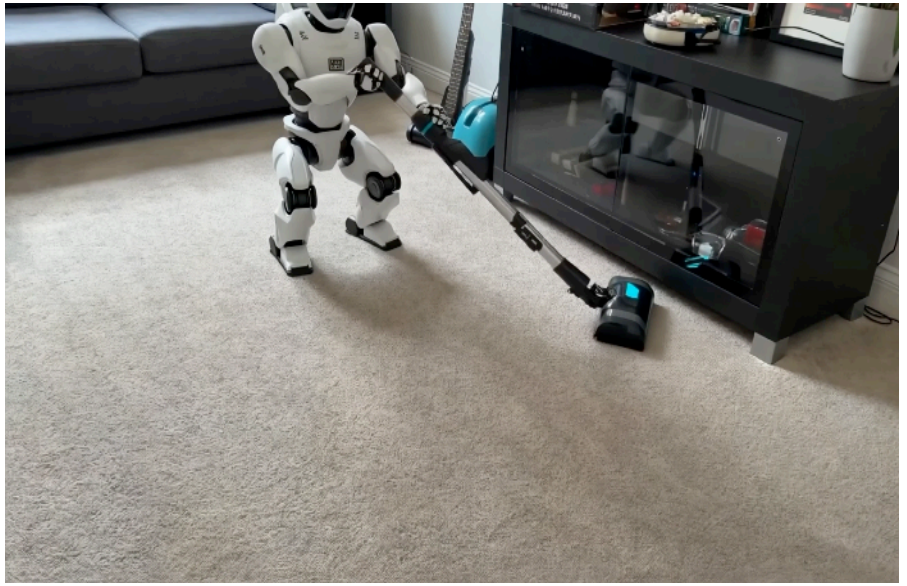

Подключим робо-VLA напрямую в нашу сцену
и пусть там само что-то делает и учится.

Сценарий: Планировщик

В сложной ситуации:

- Развернуть Мир
- Проиграть варианты
- Выбрать лучший
- Выполнить

Сценарий: планировщик

При возникновении сложной ситуации (сильно отличается от трейна):

- Разворачиваем интерактивную сцену
- Проигрываем разные варианты
- Выбираем который привел к наилучшему успеху
- Повторяем этот набор действий в реальном мире

Nvidia Cosmos

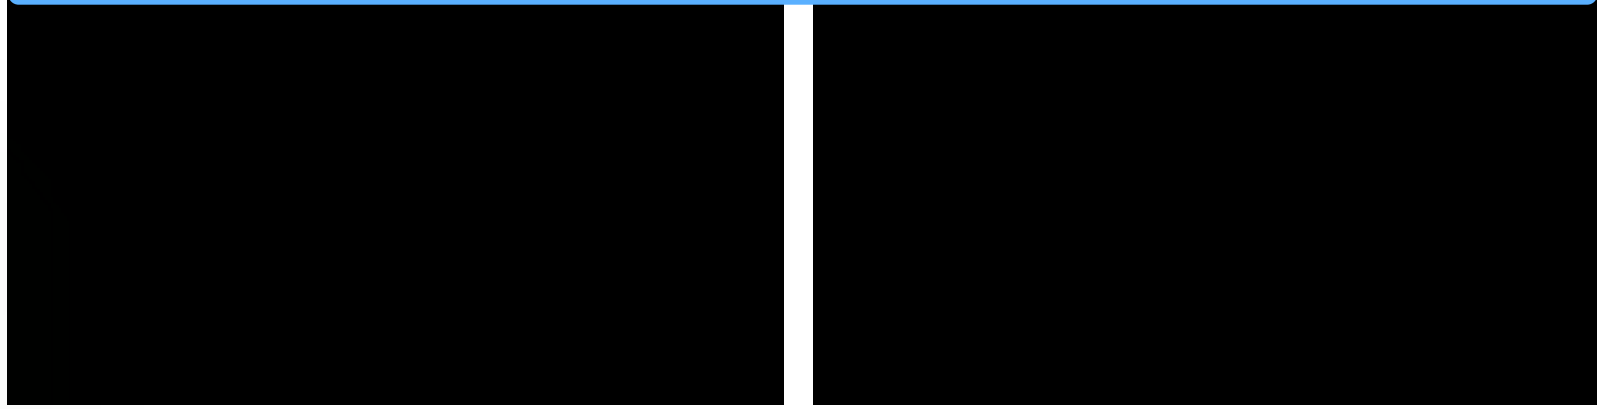

1XWM

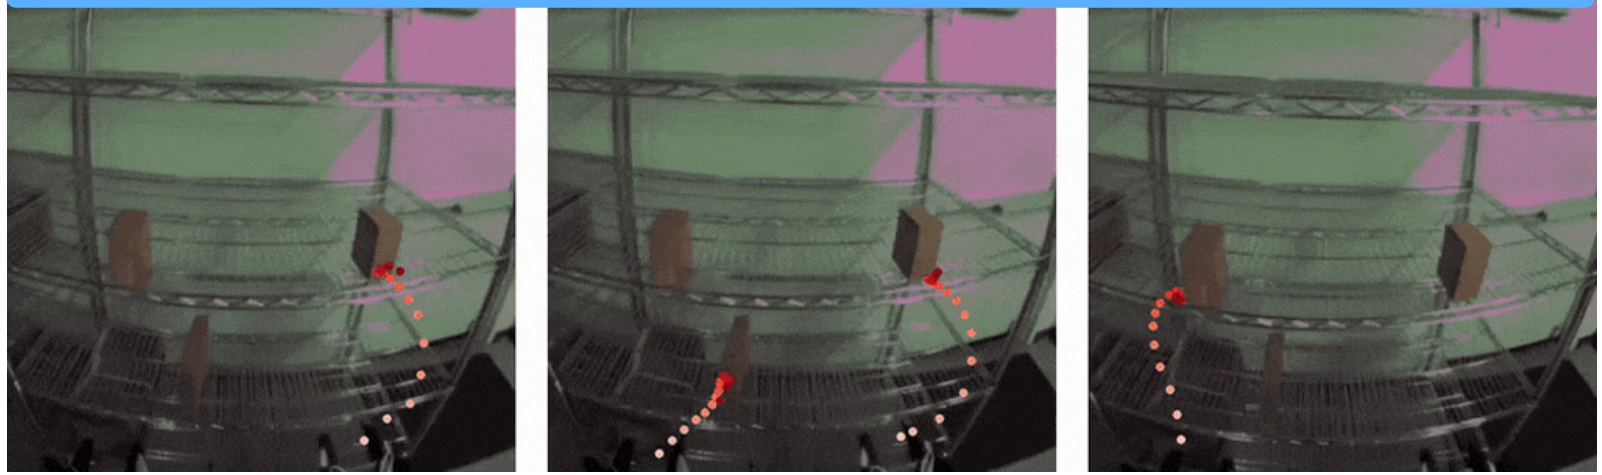

DLS

Примеры и проблемы

Nvidia Cosmos-3

Генерация со звуком

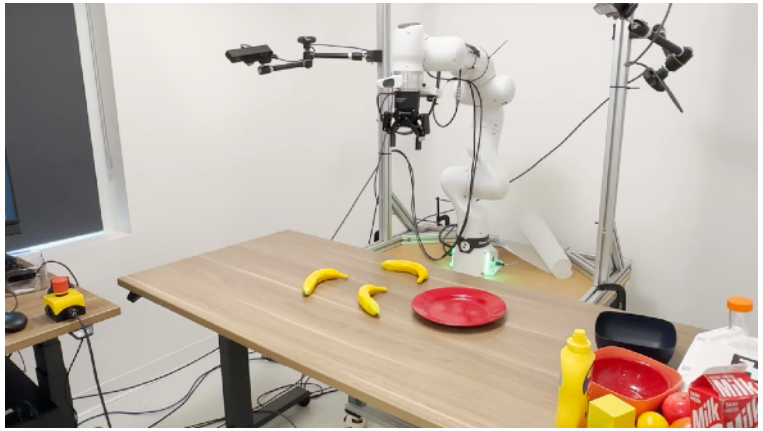

Put all bananas on the plate

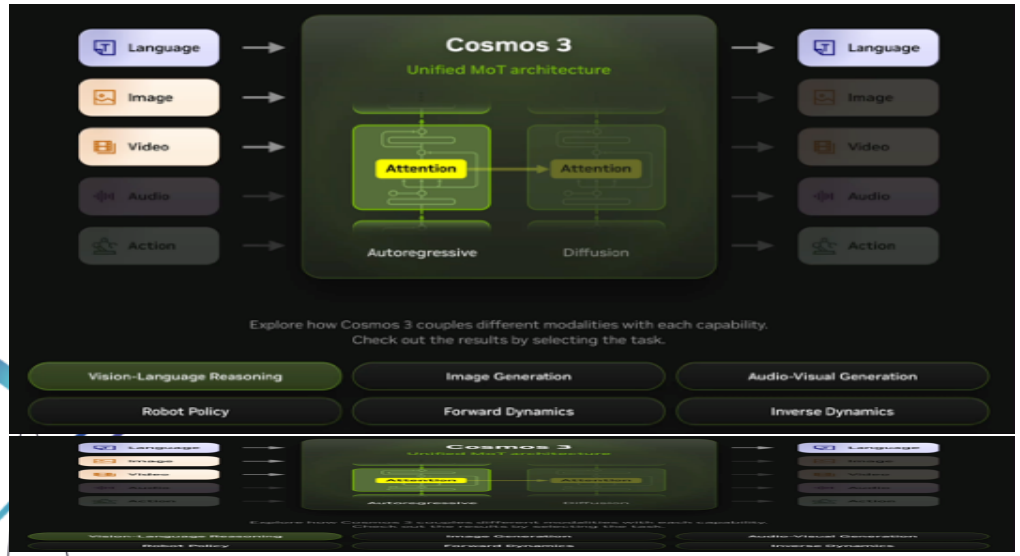

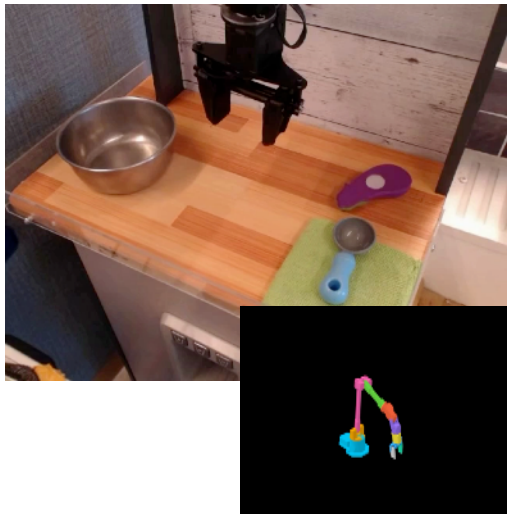

Восстановление действия

Физичность

Оригинал

Nvidia Cosmos

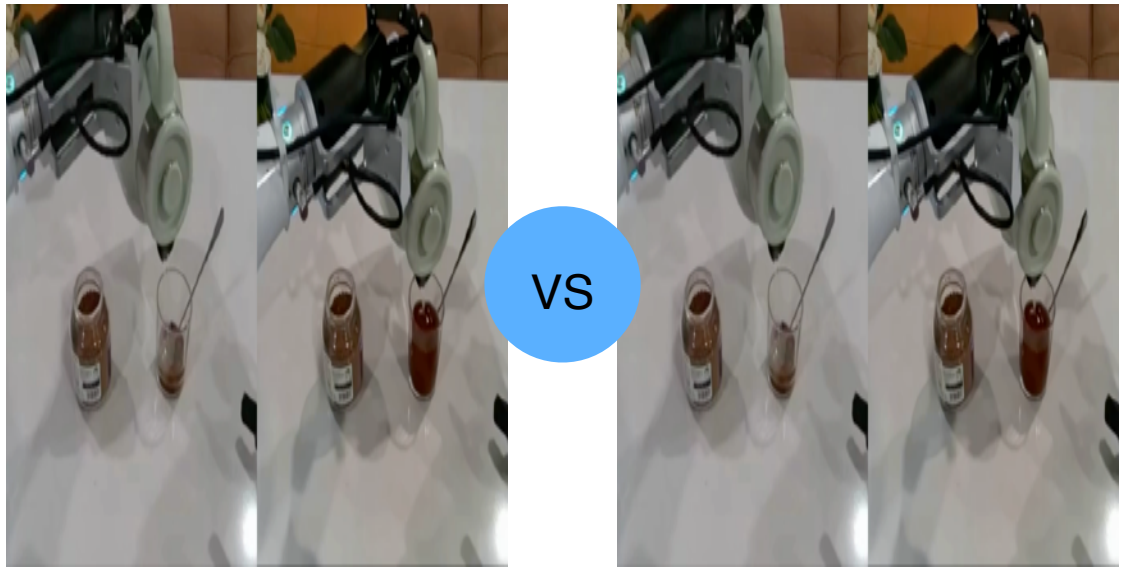

Чему же мы научим робота?

Человек пропал
машины мёрджатся

Авария

Красный и зелёный
одновременно

Genie-3

На базе Genie-3 построен автосимулятор Waymo

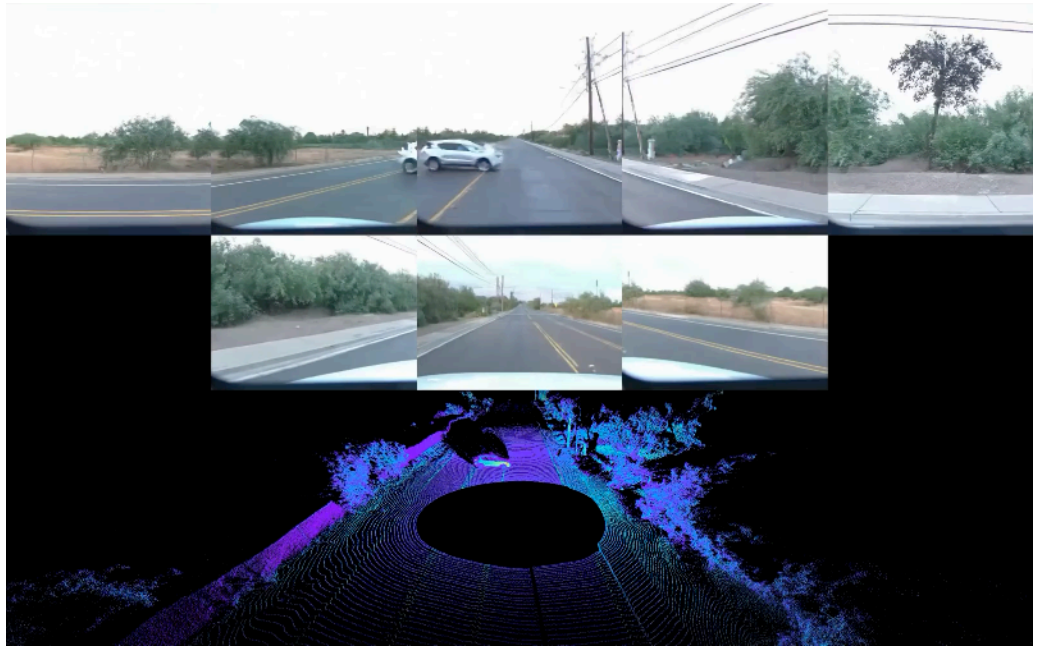

Память, консистентность

В процессе генерации мы хотим чтобы наш мир:
- Помнил объекты и стиль
- Всё оставалось собой с течением времени

Для этого требуется механизм долгосрочной памяти
- Хранение кадров / латентов
- Memory block (Transformer memory, RNN state, etc)
- 3D сцена (3D latent space, Gaussian Splatting, etc)

Google DeepMind Genie-3

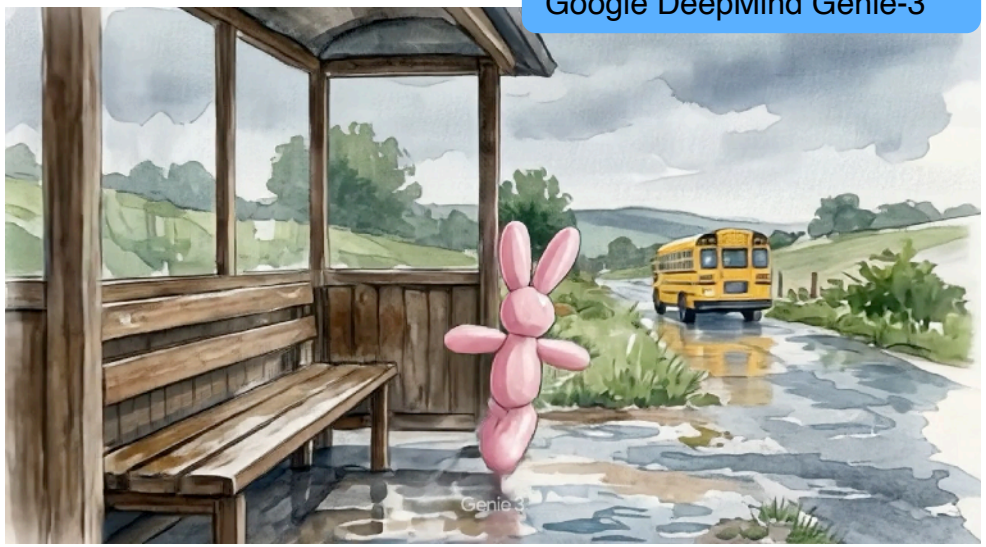

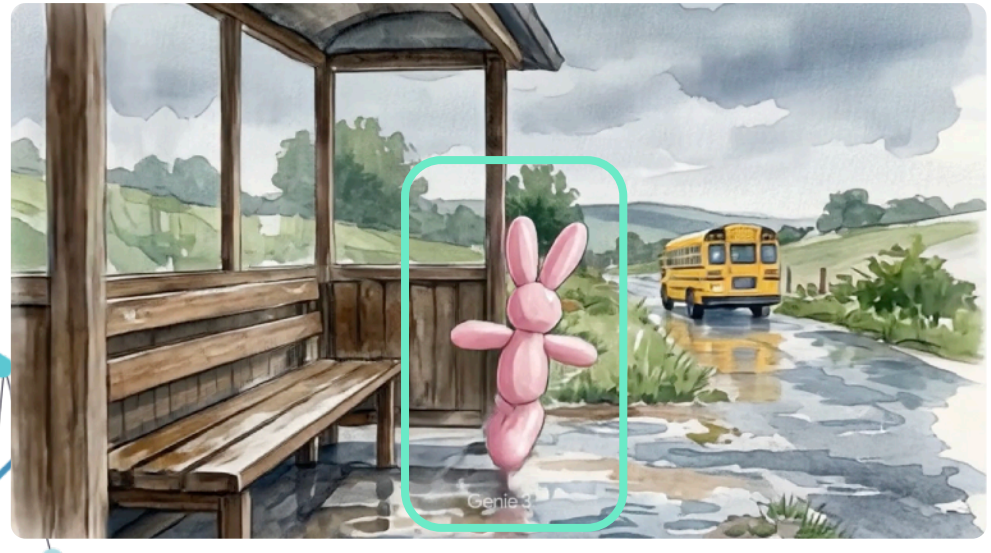

Больше колес

Изменился стиль

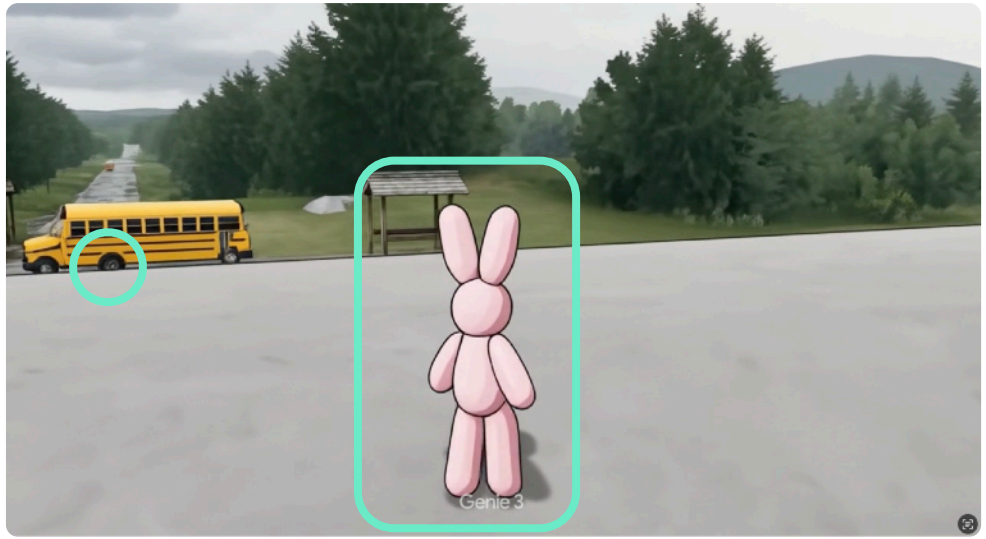

Odyssey-3

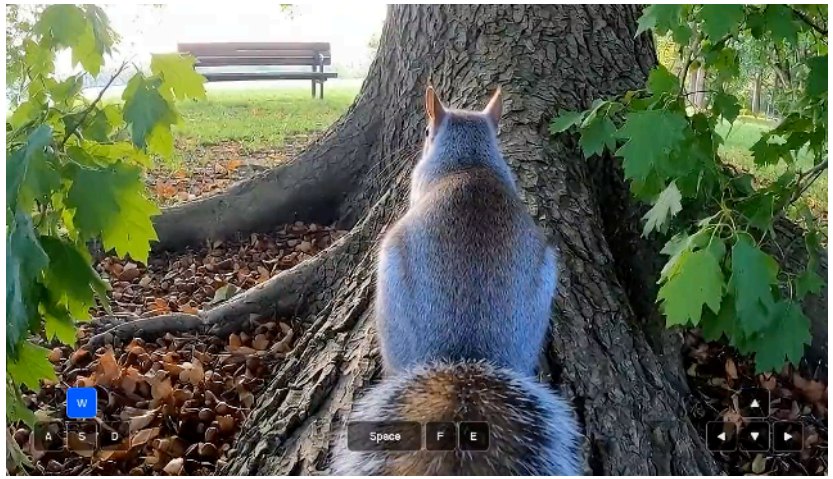

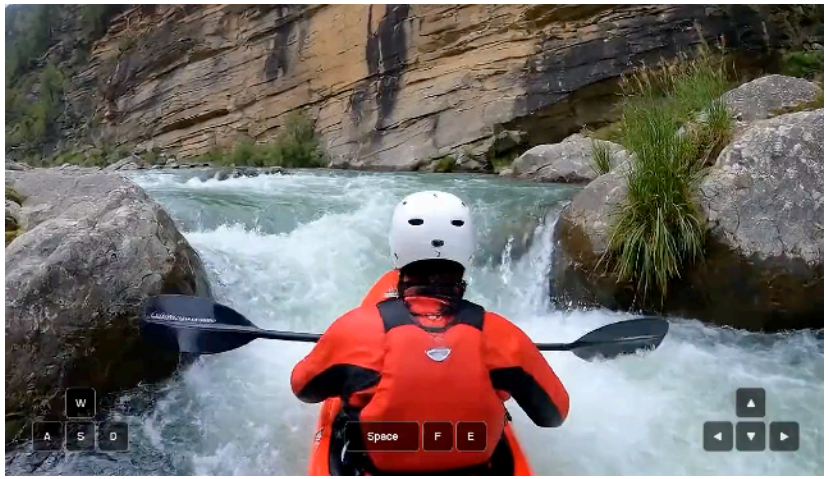

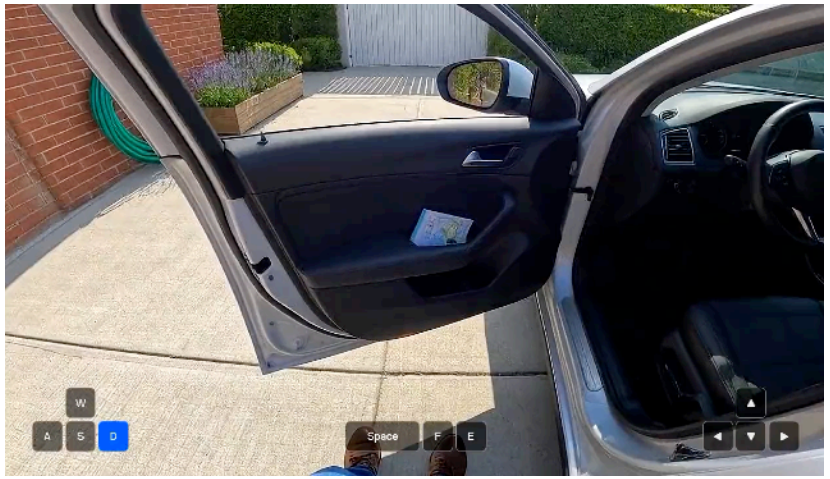

Управление

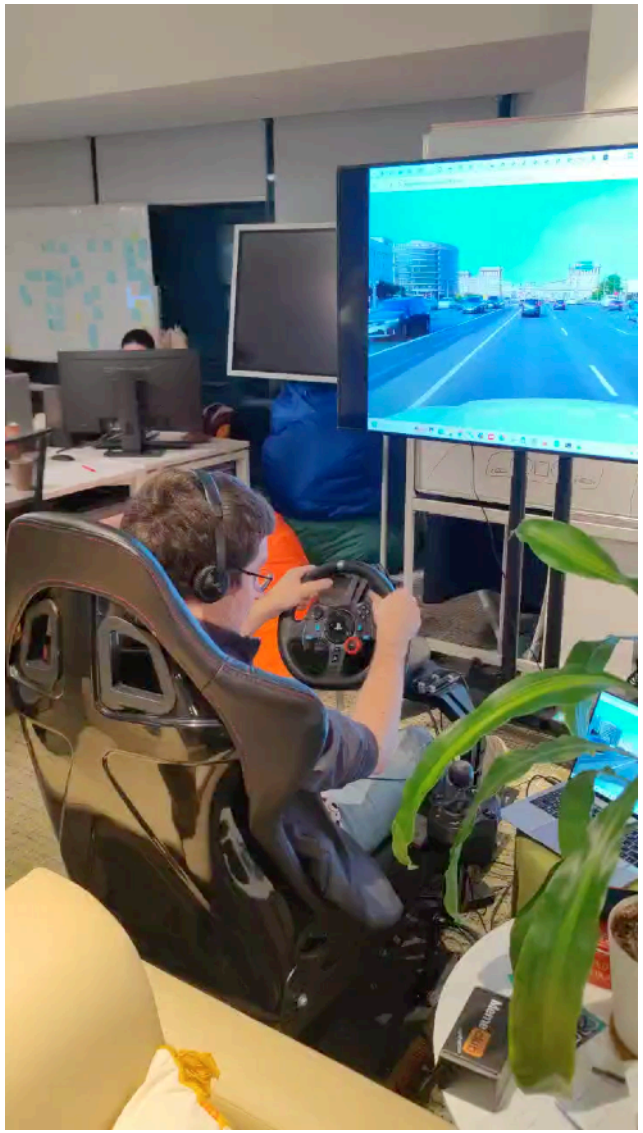

Управление очень условное, не следование управляющему сигналу, а скорее «по мотивам сигнала». Например, нельзя врезаться.

Серьезные проблемы с глобальным и локальным контекстом.

Жесткий кондишон на начальный контекст.

MIRA

Они обучили (from a scratch) encoder + DiT ровно на 1 игре.

В результате получился даже мультиплеерный режим

Ширина домена

Чем уже домен, тем проще в нём что-то выучить.
Тут очень важно найти баланс между шириной домена и требуемой обобщающей способностью

PAI (Physical AI) Bench

Rank	Model	Overall	Domain	Quality	SC	BC	MS	AQ	IQ	OC	IS	IB	CS	AV	RO	IN	PH	HU
1	Cosmos3-Super	83.9	89.5	78.2	92.7	94.1	99.2	52.7	70.8	20.5	97.7	98.1	94.4	77.5	90.0	90.7	95.0	87.6
2	Cosmos3-Nano	83.7	89.4	78.1	92.3	93.8	99.2	52.7	70.1	20.4	97.9	98.3	95.0	75.4	90.2	89.7	94.5	88.0
3	Veo-3	82.1	86.7	77.6	91.4	93.1	99.2	51.9	69.8	21.7	97.0	96.9	94.4	68.7	86.9	89.7	91.6	84.4
4	**Kandinsky WM 1.0**	**81.7**	**86.0**	**77.4**	**91.8**	**94.1**	**99.0**	**53.2**	**64.9**	**21.6**	**97.2**	**97.7**	**93.6**	**72.6**	**82.1**	**88.0**	**90.7**	**86.0**
5	**k5 Lite FT**	**81.4**	**85.8**	**77.1**	**91.3**	**93.9**	**98.7**	**52.7**	**64.3**	**21.7**	**96.6**	**97.3**	**92.9**	**72.6**	**82.1**	**87.7**	**88.8**	**86.4**
6	Cosmos-Predict2.5-14B	81.0	83.8	78.1	93.4	94.8	99.1	52.5	70.0	20.1	97.2	97.9	94.2	67.8	79.9	87.7	93.5	80.0
7	Cosmos-Predict2.5-2B	81.0	84.0	77.9	92.5	94.2	99.1	52.4	70.8	20.1	96.6	97.4	94.1	66.1	80.8	87.8	93.9	81.4
8	Wan2.2-I2V-A14B	80.6	84.1	77.2	91.6	93.7	98.3	51.2	69.6	20.4	96.0	96.6	93.2	66.3	81.7	89.2	91.8	82.1
9	**K5 Lite**	**80.5**	**83.0**	**77.9**	**91.7**	**94.4**	**99.3**	**54.1**	**65.6**	**21.7**	**98.1**	**98.6**	**89.2**	**66.3**	**77.3**	**86.3**	**87.2**	**84.6**
10	Wan2.2-TI2V-5B	80.4	83.4	77.4	91.8	93.7	98.8	51.9	69.9	20.3	95.9	96.7	93.1	65.2	79.3	88.4	91.5	83.0

Разные задачи Physical AI

Хорошая модель может решать не одну доменно-специфичную задачу, а достаточно **много разных**, возможно из разных доменов.

Atlas

Заявлена генерация видео до 1 минуты в 1440p с управлением камерой.

Смена ракурса — «bullet time»

Сцена снята несколькими камерами.
Atlas позволяет сменить ракурс и остановить время.

Роботизированная манипуляция

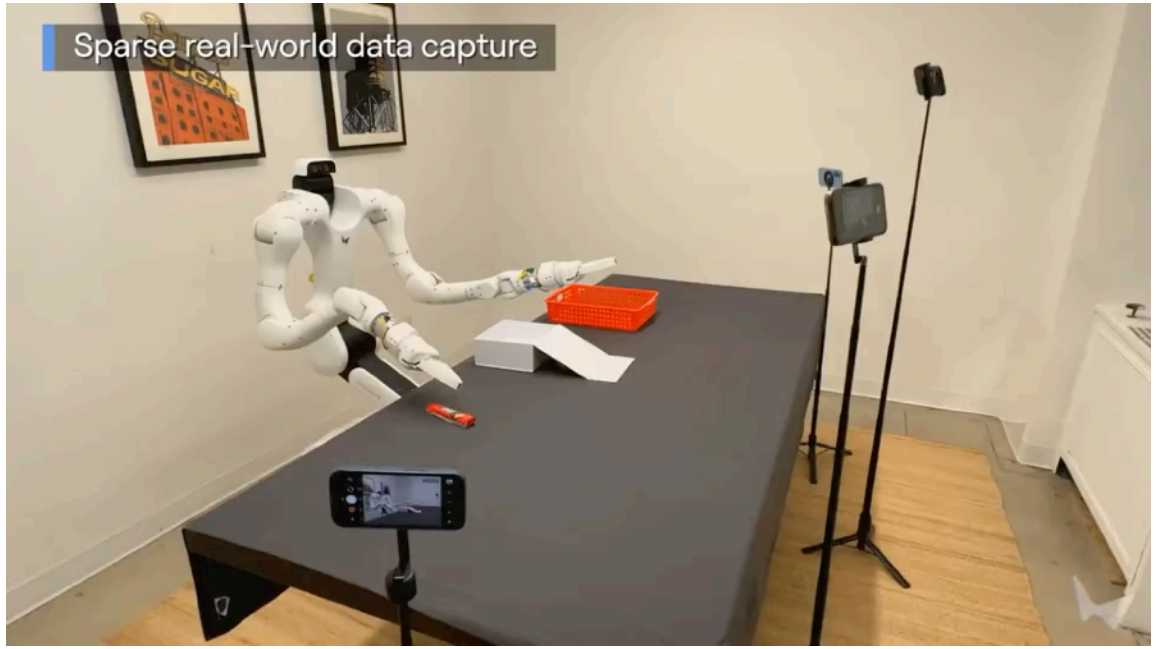

Из реальных записей строится симуляция.
Можно менять объекты, освещение и окружение.

Расплата за красивое 3D

Реконструкция в 3D (например гауссовы сплаты) позволяет сделать хорошую память, чёткую картинку, менять позицию и т.д.

Но 3D реконструкция статична, мы теряем динамику... и смысл.

Общие проблемы

- Физичность
- Память
- Управление
- Длина видео
- Скорость генерации

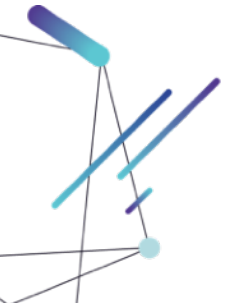

Улучшение физичности: данные

Можно обучить претрейн модели на таких данных чтобы модель из коробки была более физичной и правильной.

- Nvidia Cosmos - только индустриальные/промышленные и автомобильные видео
- JEPA WM - только робо-видео
- Выходят новые датасеты для улучшения физичности как на базе реальных данных (WISA, PhyVidGen) так и полностью синтетические:

Робо-видео

Авто-видео

WISA

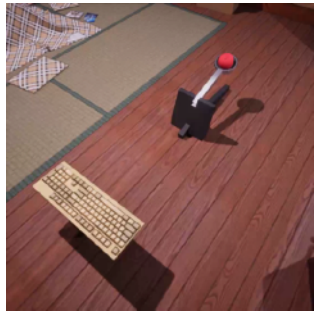

PhysInOne

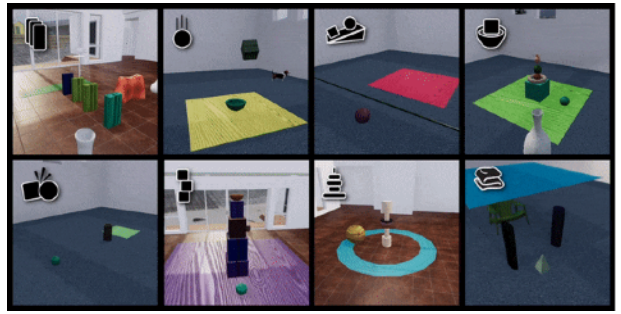

Physion

Улучшение физичности: пост-трейн

- SFT (+адаптеры)
- RL (DRAFT, DPO, GRPO)
- Инференс скейлинг
- Harness и ризонинг
- Выравнивание внутренних представлений модели с эмбеддингами физичных моделей (типа V-JEPA)

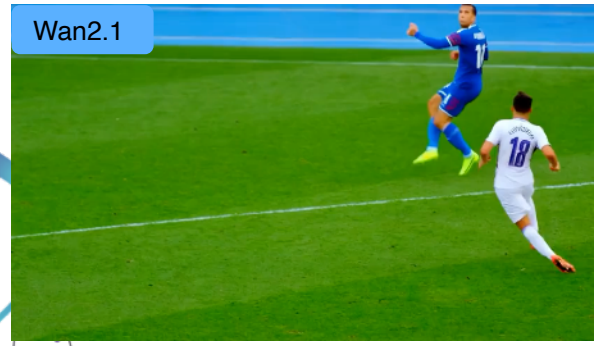

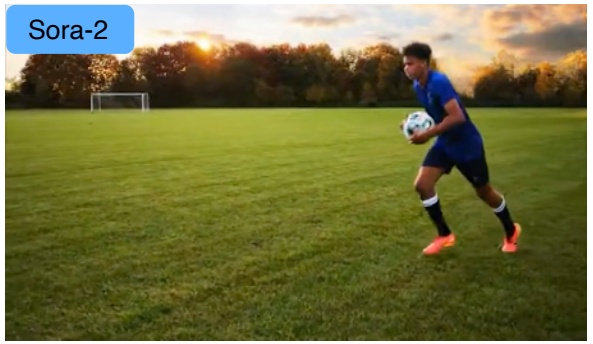

Улучшение физичности: inference scaling

Self-Refining Video Generation + WMReward: усиливаем физичность на этапе inference

Self-Refining Video Generation

Итеративный refinement на inference

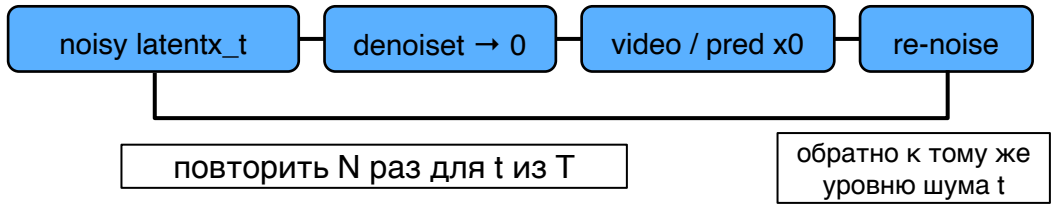

Улучшение качества генераций без дополнительного обучения за счет увеличения NFE

WMReward

Выбор лучшего из N кандидатов

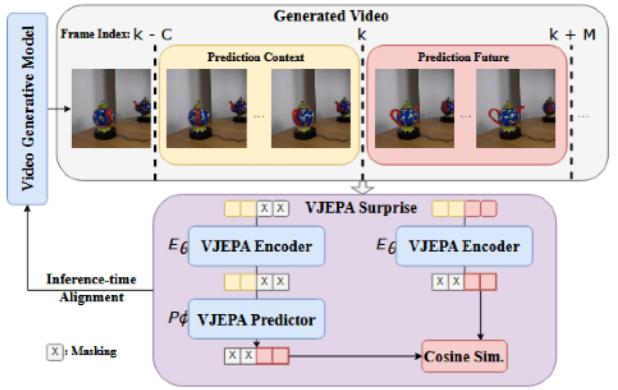

Ключевая идея

Используем latent world model(VJEPA-2) как reward: у кого выше значение — того и выбираем

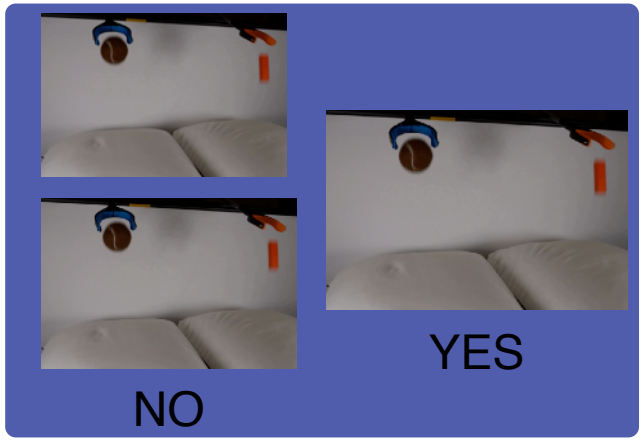

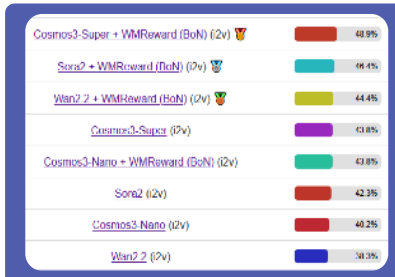

Демонстрирует значимое улучшение на всех моделях от Wan 2.2 до Cosmos 3

Улучшение физичности: добавление настоящей физики

Можно добавить кастомный лосс
на какой-то конкретный физ. процесс.
(например, на закон Ньютона)

Плюс: этот процесс будет работать
сильно лучше.

Минус: иногда для этого могут
потребоваться какие-то конкретные
данные, которые ранее не требовались
(например, знание массы объекта).

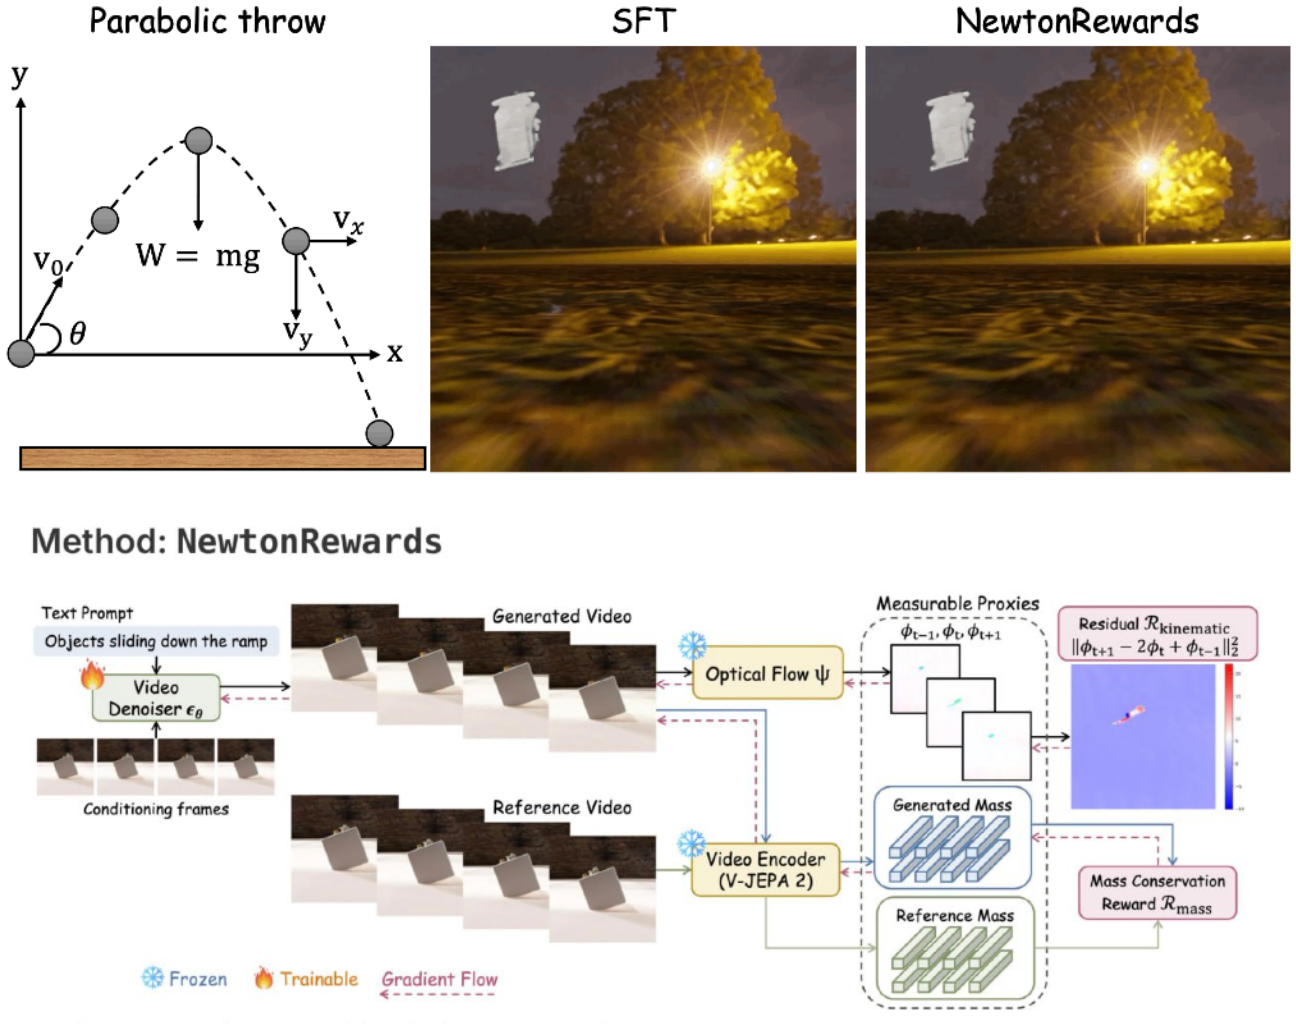

Управление

Может быть разным:

- Управление кнопками/мышкой
- Передача команд текстом
- Описание изменения состояния (робота)

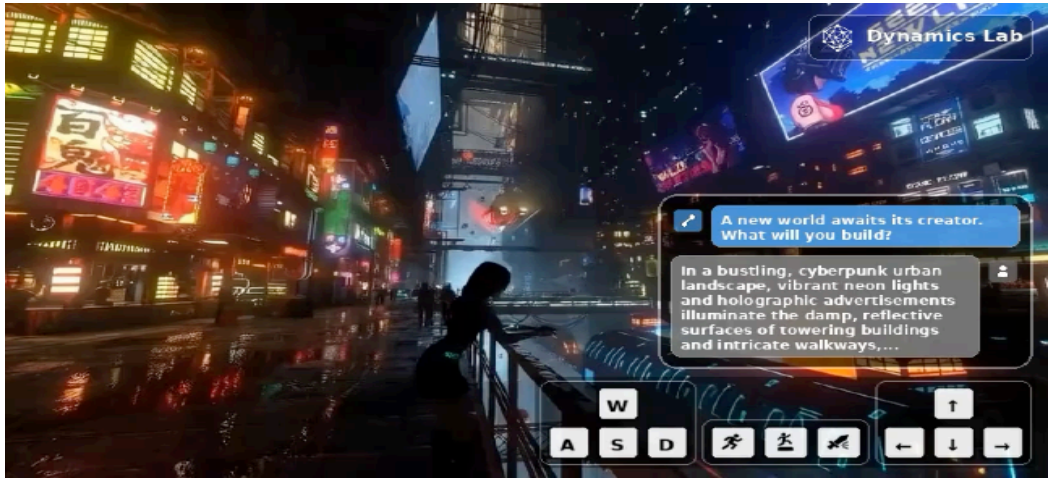

Авторегрессия

Классическая схема расшумления:

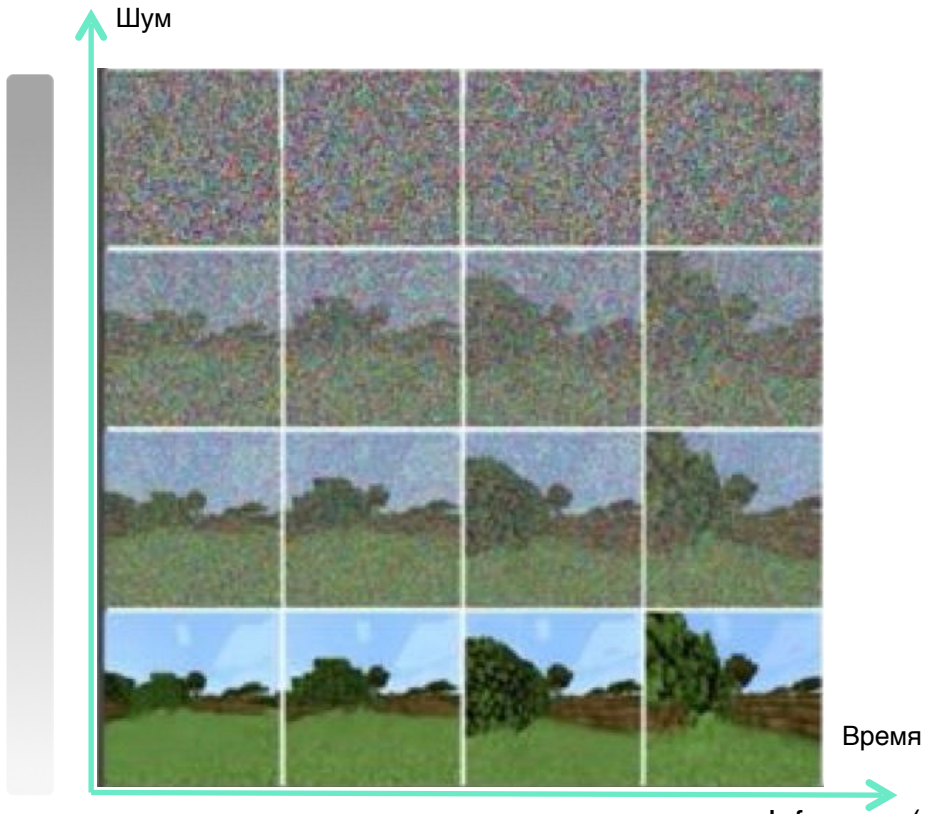

~O(N^2t^2)

Авторегрессионная схема расшумления:

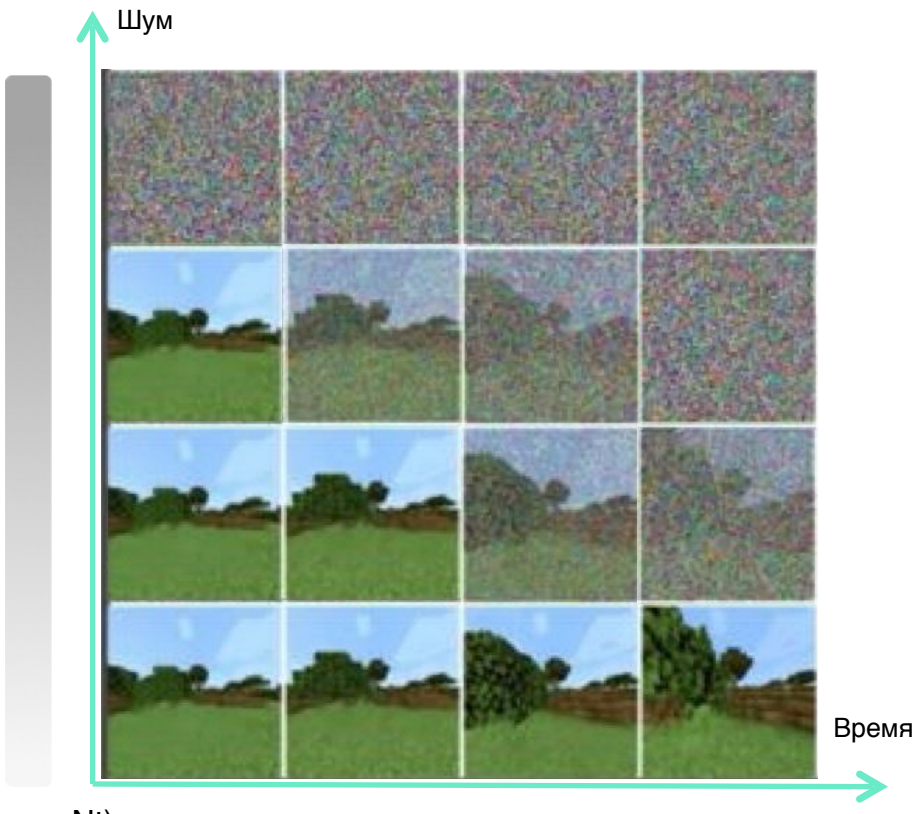

~O(Nt^2)

Inference (видео длины Nt)

Авторегрессионные модели

Генерировать не все видео целиком за раз, а кусочками

- Длинные видео
- Real-time скорость
- Возможность менять condition «на лету» — контроль

Nvidia Lyra

Genie 3

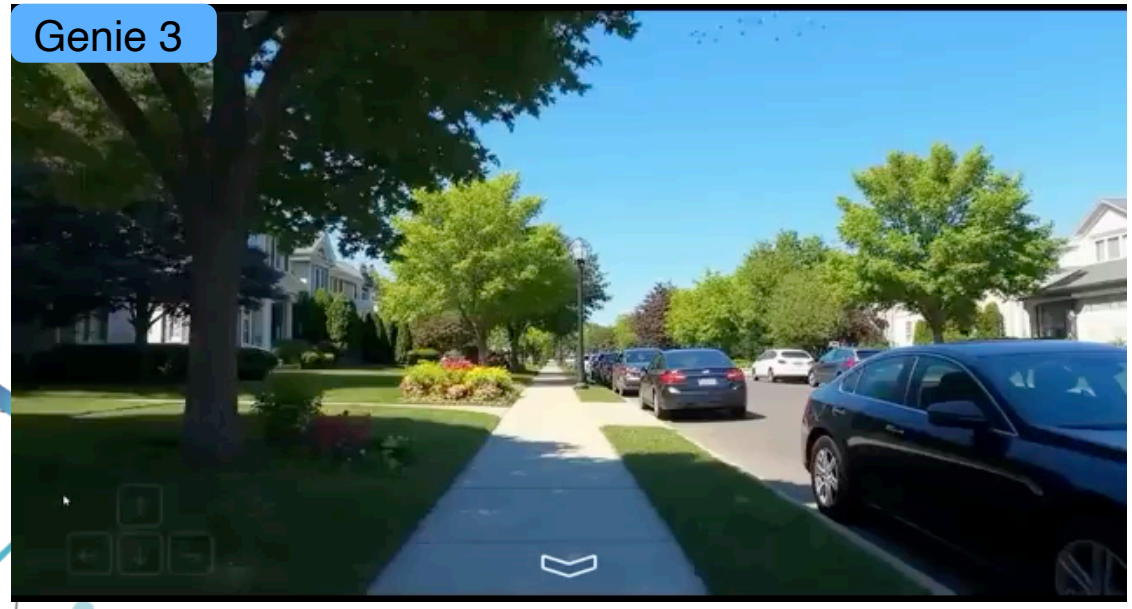

GWM-1

Построение модели мира на базе видеогенерации. Примерный рецепт

01	02	03	04	05
Базовая модель видеогенерации	Физичность	Управление	Авторегрессия	Память
Ну, например, Kandi, уже умеем красиво t2v и i2v	Нужно сделать не только красиво, но еще и правильно	Учитывая сценарий (роботы, авто, игра), добавить соответствующее управление	Нужно сделать длинное видео быстро, с управлением почанково	Из-за длинности видео мы больше не можем помнить всё

DLS

А как это всё измерить и сравнить?

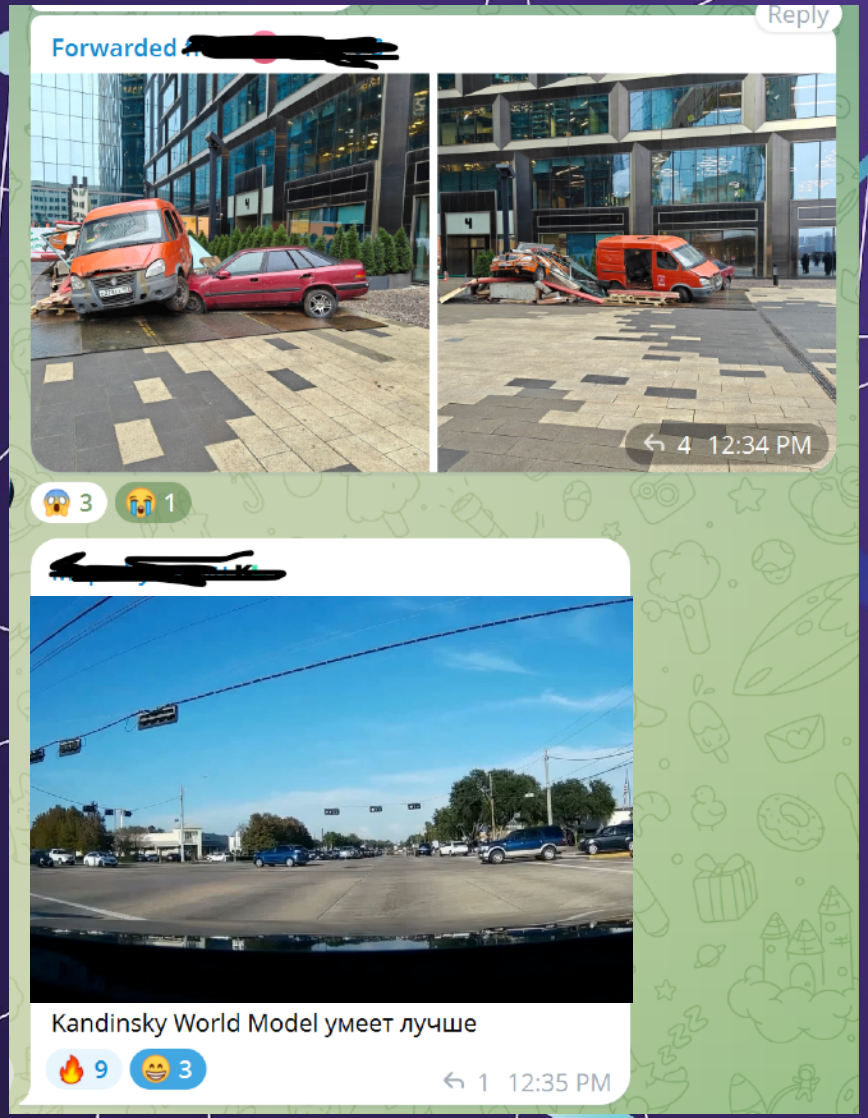

Перед тем как сравнивать... сравним

Nvidia Cosmos-3	Genie-3
Physical AI	Игровой
8 сек	1 мин
Омнимодальный	ta2v, ia2v
Не реал тайм	реал-тайм

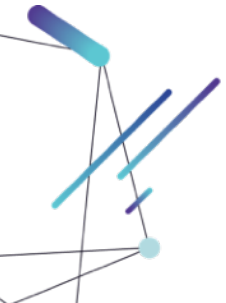

Да, они оба с претензией на общий домен, и оба хорошо работают, но грубо говоря, их сравнивать нельзя... но очень хочется

Арены

video A / video B → human vote

Все видео в стиле «повернись туда, повернись обратно».

Нужно выбрать лучшего:

- консистентность
- управление
- натуральность динамики
- реализм

...

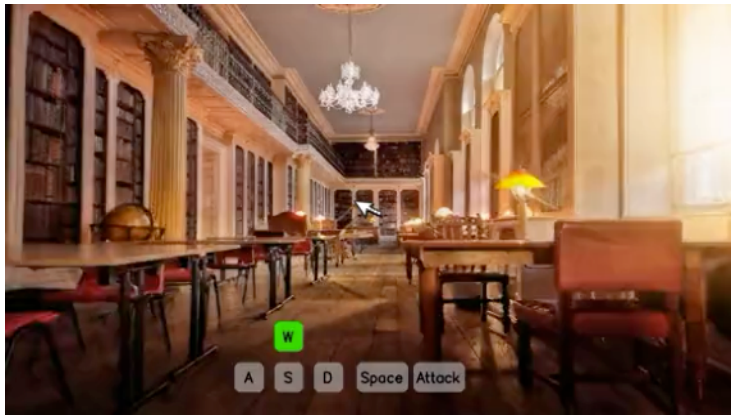

warena.ai

Бенчмарки с VLM-as-a-judge

Rise-Video

Models	RA	TC	PR	VQ	W.Score	Accuracy
Hailuo2.3	76.6%	87.2%	71.0%	92.0%	79.4%	22.5%
Veo3.1	64.9%	86.0%	78.9%	91.9%	76.4%	22.3%
Sora-2	64.0%	92.2%	76.3%	92.2%	77.0%	21.3%
Wan2.6	70.0%	88.8%	72.5%	94.5%	77.8%	21.3%
Kling2.6	53.7%	86.4%	78.0%	95.1%	72.1%	19.5%
Seedance1.5-pro	61.2%	81.1%	70.7%	96.2%	72.0%	17.6%
Kandinsky-5.0-I2V-Pro	46.0%	76.7%	74.3%	93.3%	65.5%	14.8%
Wan2.2-I2V-A14B	39.5%	79.2%	75.4%	94.0%	63.9%	11.4%
HunyuanVideo-1.5-720P-I2V	38.1%	75.0%	68.4%	92.6%	60.4%	8.6%
Kandinsky-5.0-I2V-Lite	44.6%	64.6%	66.3%	87.3%	59.3%	7.5%
HunyuanVideo-1.5-720P-I2V-cfg-distill	38.9%	74.0%	65.8%	92.9%	59.9%	7.3%
Wan2.2-TI2V-5B	32.6%	70.5%	72.8%	89.7%	57.8%	5.4%
CogVideoX1.5-5B	30.7%	62.3%	56.7%	74.5%	49.5%	1.9%

RA: Reasoning alignment
PR: Physical Rationality

TC: Temporal consistency
VQ: Visual Quality

Примеры: RiseVideo, VBench-2.0, PhyGenBench, PBench

prompt / image → VideoGen → video → VLM → score

Show the process of a pair of hands crumpling it into a ball.

"Are a pair of hands squeezing the paper, causing it to deform?"
"Is the paper crumpled into a ball, with multiple creases and wrinkles creating a rough and uneven texture?"

Show how it changes as many people walk on it.

"Are there many people walking in the snow?",
"Are there footprints in the snow after someone walked by?"

Show the process of a hammer striking it.

"Is there a hammer hitting a vase?",
"Does the vase break?"

Бенчмарки формальные

Physics-IQ Verified

Rank	Model	Score
1	Cosmos3-Super-Image2Video	39.5 ± 0.8
2	Grok Imagine Video	34.8 ± 0.6
3	Hunyuan Video 1.5	33.4 ± 0.8
4	Wan 2.2	32.2 ± 0.6
5	**Kandinsky WM 1.0**	**30.8 ± 0.5**
6	Cosmos3-Nano	30.3 ± 0.6
7	Sora 2	26.5 ± 0.8
8	**K5 Lite FT**	**25.8 ± 1.7**
9	P-Video	25.3 ± 1.8
10	**K5 Lite**	**16.0 ± 1.2**

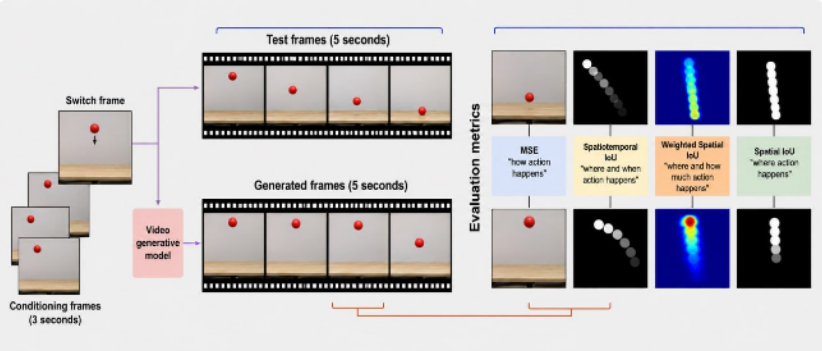

По всяческим IoU сравнивает с оригинальным видео

HumanScore

Rank	Model	Availability	Anatomy	Kinematic	Kinetic	Overall
1	Seedance 1.0 Pro fast	Proprietary	93.9	84.7	94.3	**91.1**
1	HunyuanVideo 1.5	Open source	**95.3**	83.0	94.9	**91.1**
3	KlingAI 2.5 Turbo Pro	Proprietary	91.0	**86.4**	**95.1**	90.8
4	Ray 3.0	Proprietary	86.7	82.5	93.8	87.7
5	Kandinsky 5.0 pro	Open source	86.7	80.7	92.1	86.5
6	Sora-2	Proprietary	90.8	78.2	89.4	86.1
6	Wan 2.2	Open source	94.0	78.8	85.6	86.1
8	Veo 3.1 fast	Proprietary	84.6	79.8	93.3	85.9
9	Hailuo 02	Proprietary	89.1	77.1	91.2	85.8
10	PixVerse 5.5	Proprietary	87.0	78.6	91.0	85.5

Parkour

HumanScore: 62.53

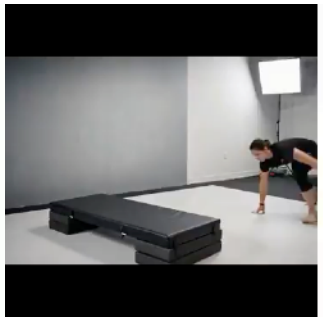

Playing squash or racquetball

HumanScore: 99.26

По точкам переводит человека в скелет, и оценивает анатомичность и правильность движений

Бенчмарки гибридные

RBench (QWEN-based)

VLM / VQA + формальные проверки = hybrid score

Rank	Model	Avg.	Common manip.	Spatial relation	Multi-entity collab.	Long-horizon planning	Visual reasoning	Single arm	Dual arm	Quad	Humanoid
1	Veo 3	0.784	0.896	0.740	0.924	0.854	0.750	0.742	0.708	0.726	0.716
2	Wan 2.5	0.780	0.887	0.825	0.915	0.719	0.737	0.742	0.744	0.711	0.742
3	Hailuo v2	0.761	0.843	0.840	0.892	0.705	0.820	0.695	0.706	0.631	0.719
4	Seedance 1.0	0.755	0.856	0.665	0.898	0.715	0.789	0.707	0.730	0.674	0.759
5	Wan2.2_A14B	0.698	0.708	0.660	0.920	0.680	0.550	0.688	0.678	0.670	0.727
6	**Kandinsky WM 1.0**	**0.651**	**0.836**	**0.685**	**0.846**	**0.657**	**0.523**	**0.509**	**0.568**	**0.578**	**0.656**
7	Cosmos 2.5-14B	0.632	0.687	0.512	0.768	0.596	0.506	0.646	0.646	0.639	0.688
8	**K5 Lite FT**	**0.628**	**0.714**	**0.715**	**0.819**	**0.545**	**0.514**	**0.540**	**0.559**	**0.581**	**0.667**
9	LongCat-Video	0.608	0.677	0.465	0.814	0.489	0.354	0.698	0.602	0.666	0.710
10	**K5 Lite**	**0.608**	**0.737**	**0.483**	**0.833**	**0.636**	**0.397**	**0.551**	**0.603**	**0.573**	**0.661**
11	DreamGen(gr1)	0.575	0.507	0.500	0.848	0.353	0.404	0.660	0.632	0.611	0.656
12	Wan2.2_5B	0.550	0.597	0.402	0.721	0.449	0.420	0.511	0.534	0.637	0.681
13	Wan2.1_14B	0.541	0.687	0.400	0.702	0.465	0.269	0.519	0.562	0.604	0.664

Разные виды роботов.

Столкнулись с генерацией роботов от третьего лица

DLS

Что же мы делаем в Kandinsky?

Наши вводные: K5.

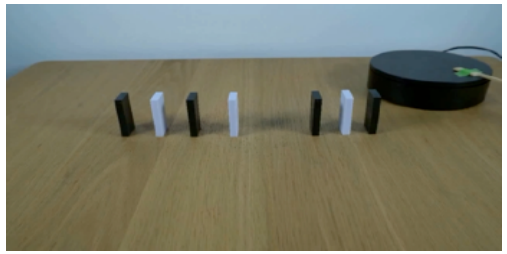

Физика

Мультивью

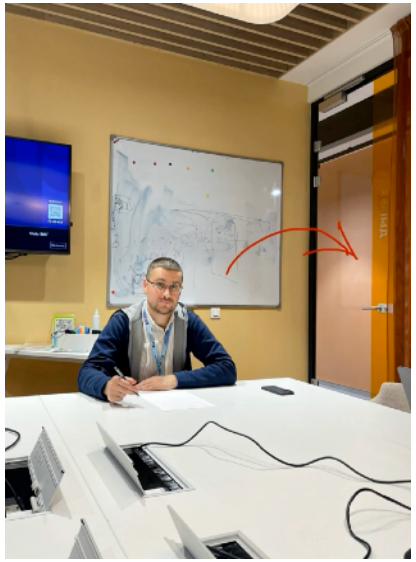

Управление

Память

Скорость

Следование промпту

Фильтр физичности

На претрейне оверсемплим данные, которые должны исправить существующие проблемы.
Добираем данные о физике, роботах, автомобилях, промышленности из различных источников.

Что исправляем?	Почему так получилось?	Этап фильтра	Инструмент
	Недостаточно примеров сложной динамики	Динамика + качество	структурная динамика + VideoMAE v2 + Q-Align
	В претрейне CGI, игры, тяжёлые спецэффекты	SFX / games / CGI	CLIP embeddings + классификатор
	В претрейне есть склейки и монтаж внутри клипов	Склейки	жёсткие пороги TransNet / OmniShotCut
	В претрейне есть Slow motion / неестественная динамика	Slow motion	фильтр скорости на основе VJEPA-2
	В претрейне мало интересных сценариев	Сценарная ценность	caption → Qwen 3.5 + LLM-правила отбора

Инференс скейлинг

Учитывая, что мы метим в реал-тайм, эти трюки хоть и дают прирост по качеству, всё же должны считаться контрпродуктивными

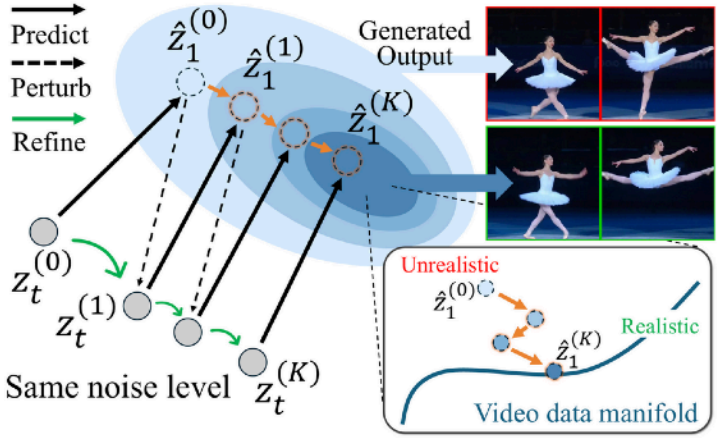

По оценке QWEN 30B-3A: 4.46 -> 4.72

Kandinsky

Kandinsky+Refine

Kandinsky

Kandinsky+Refine

Пост-трейн трюки

SOAR: коррекция траектории

Модель учится исправлять собственные ошибки денойзинга.

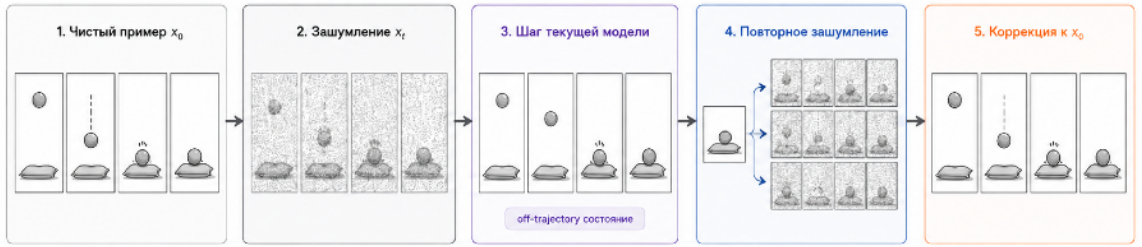

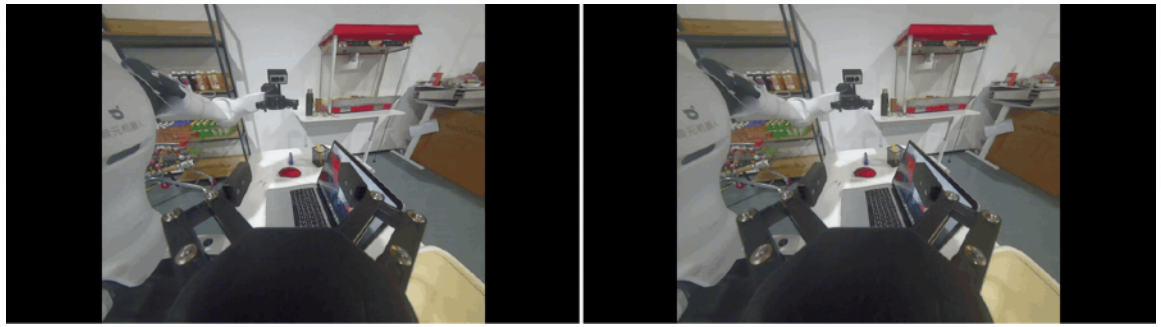

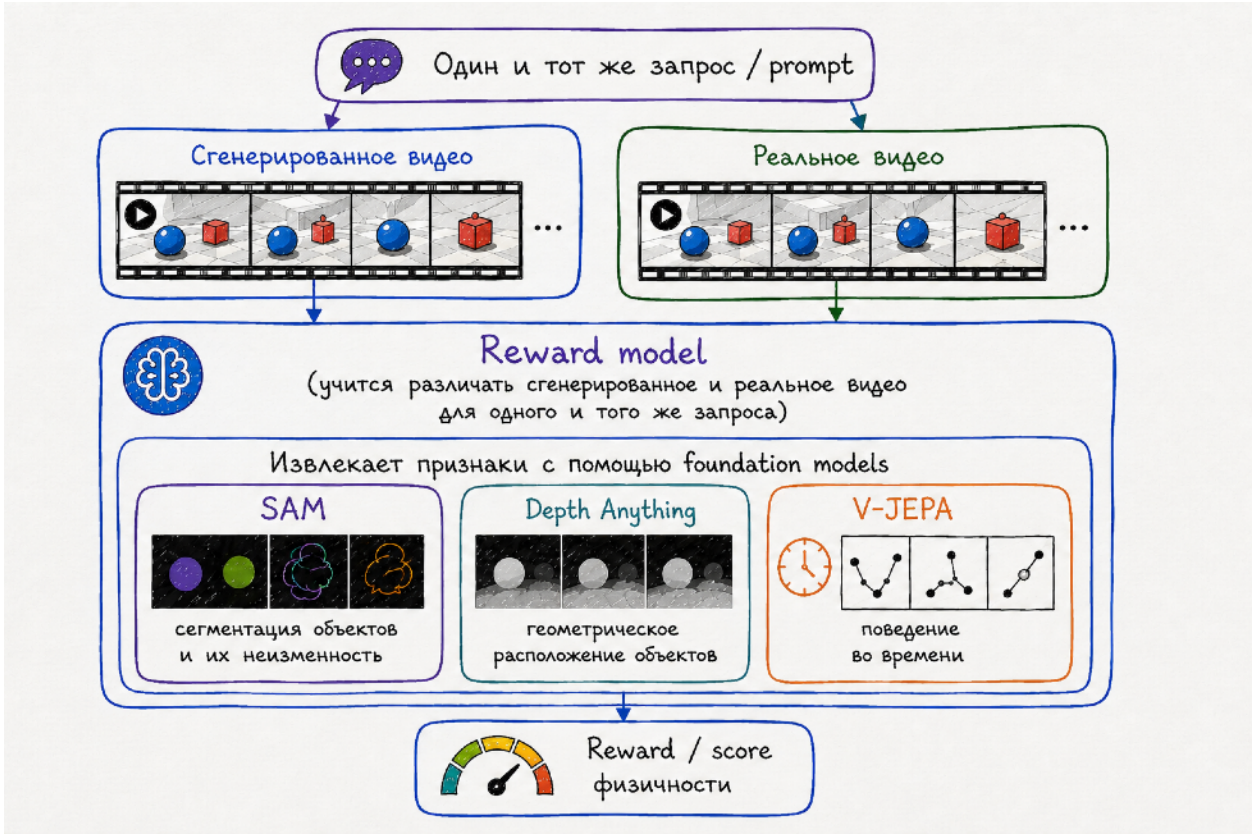

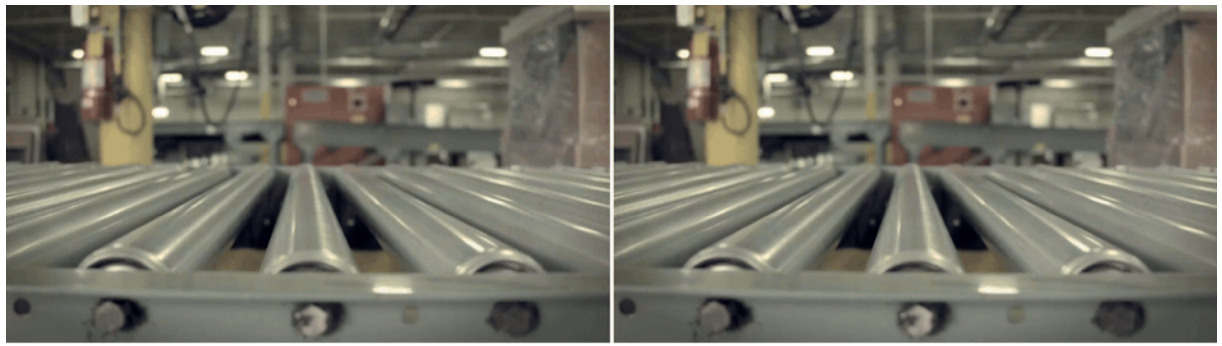

Time Adapter

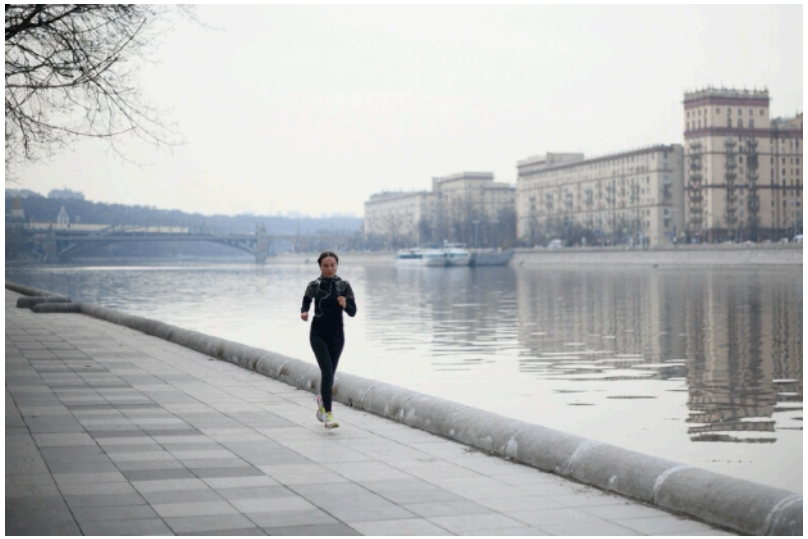

15 FPS

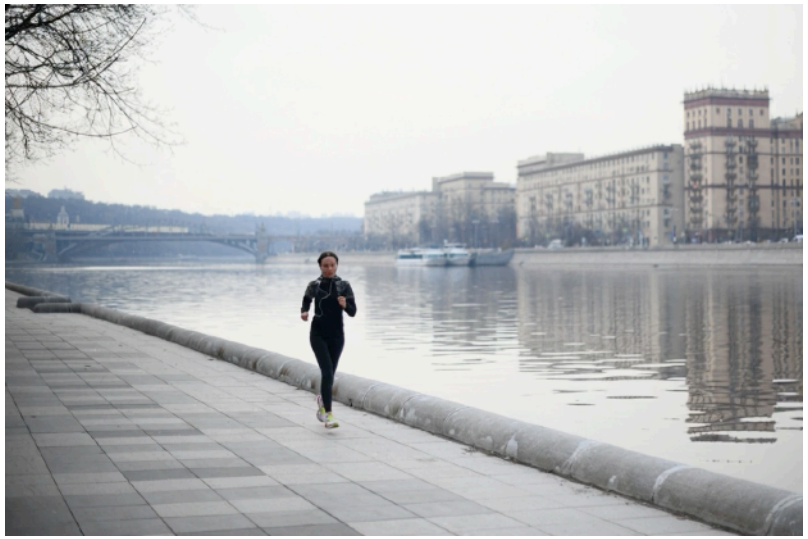

30 FPS

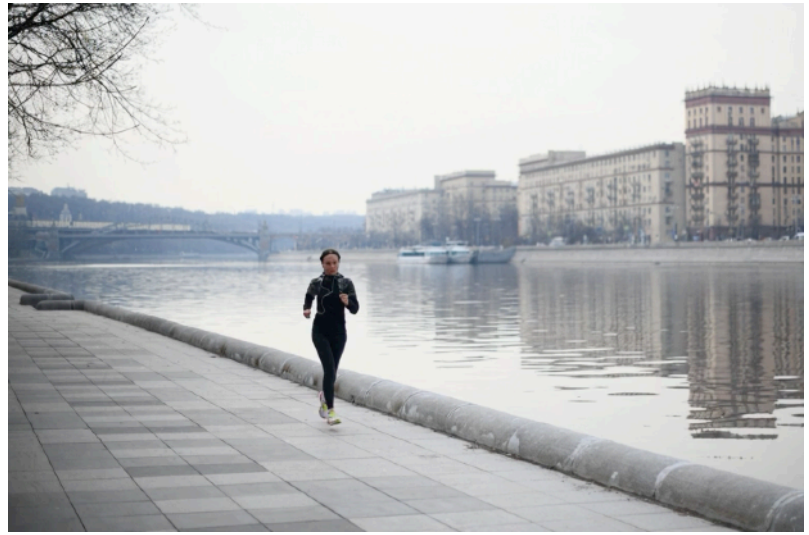

60 FPS

Сделали управление темпоральной динамикой (прокинули кондишон на FPS), представили на ICML.

Управление

Камерой

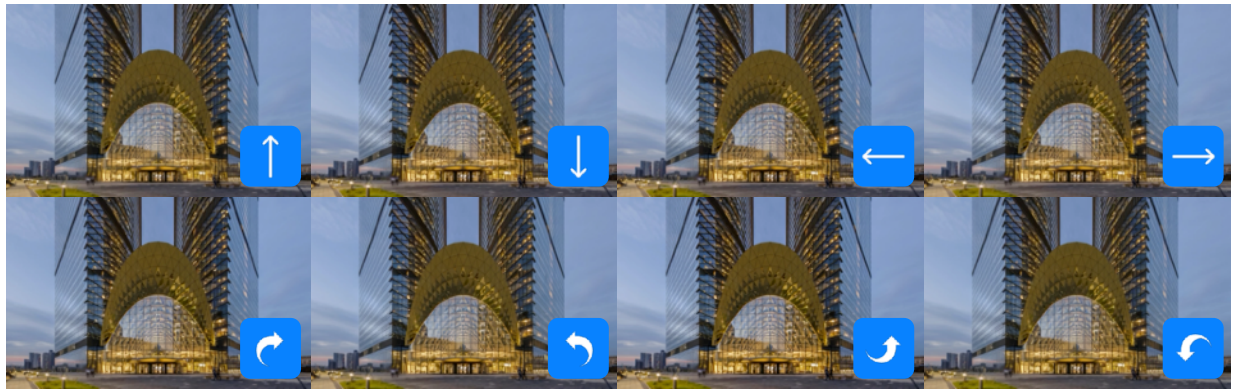

Агентом

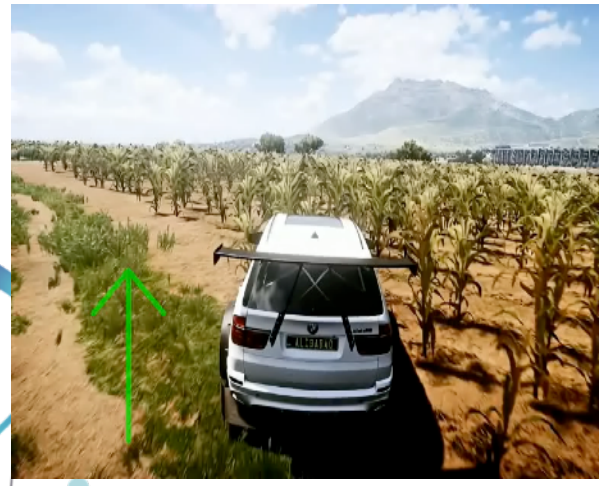

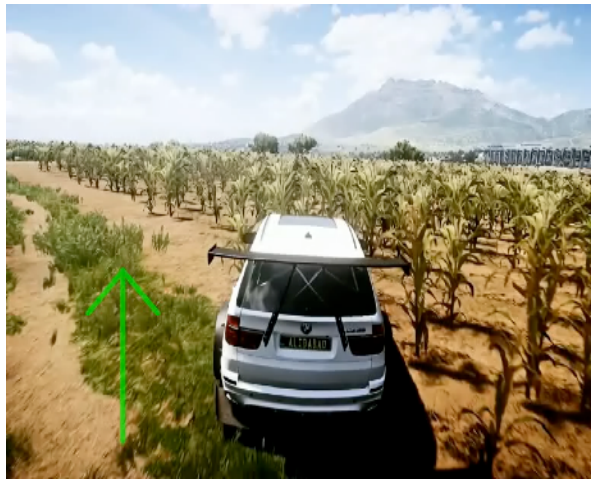

Роботом (при помощи action maps)

Стартовая картинка

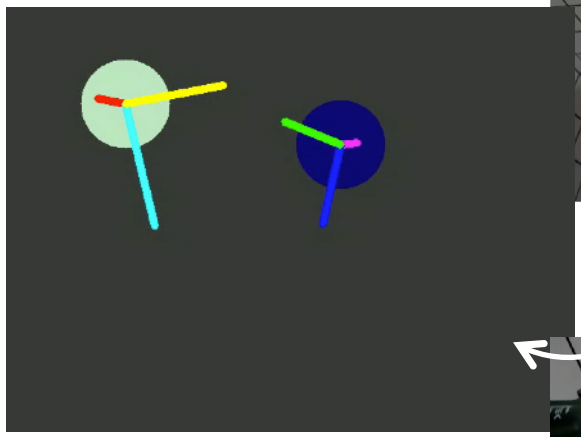

Action Map

Сгенерированное видео

Управляемая генерация

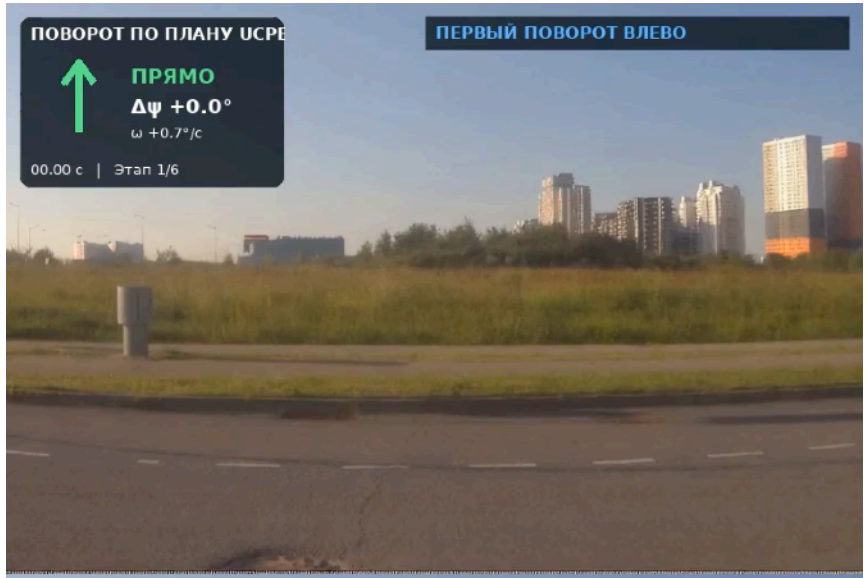

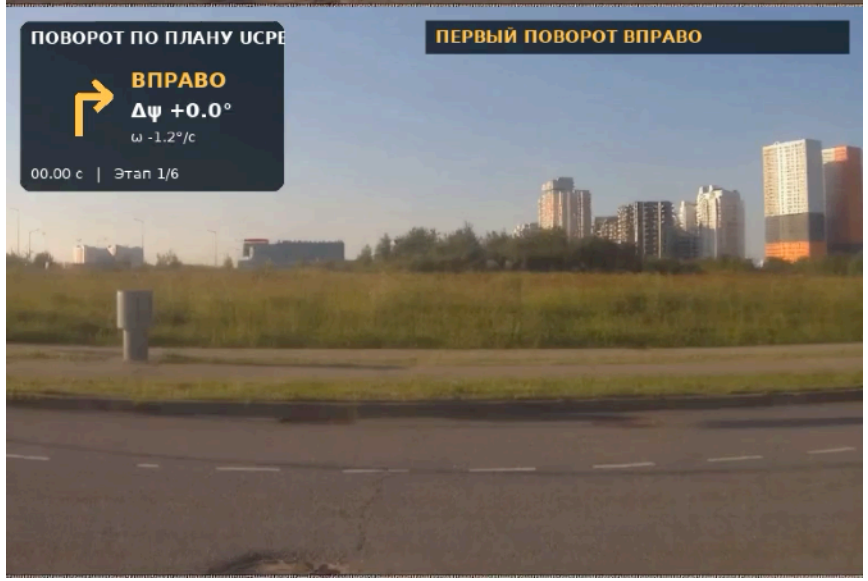

Сколтех (Navio данные)

Кутуза

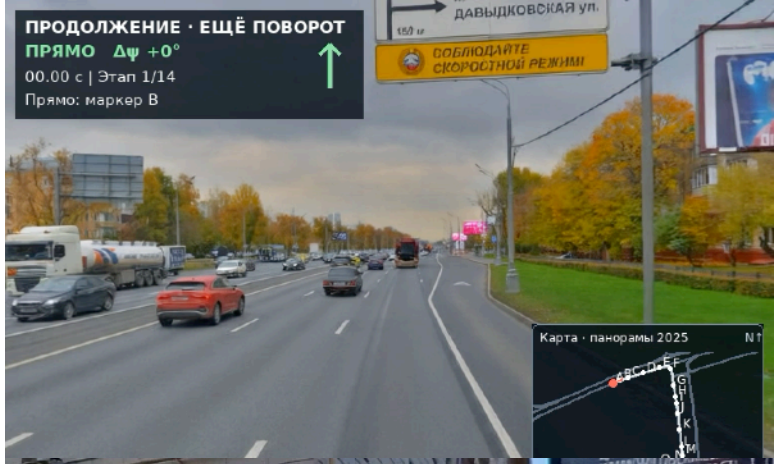

Смоленка

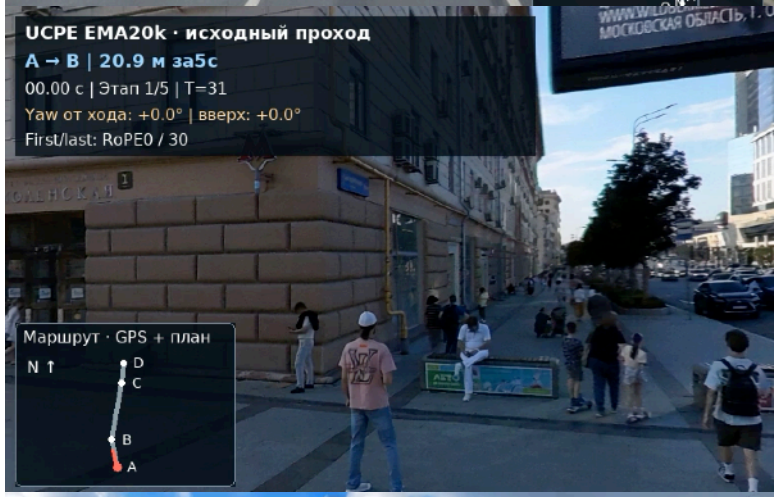

Садовое

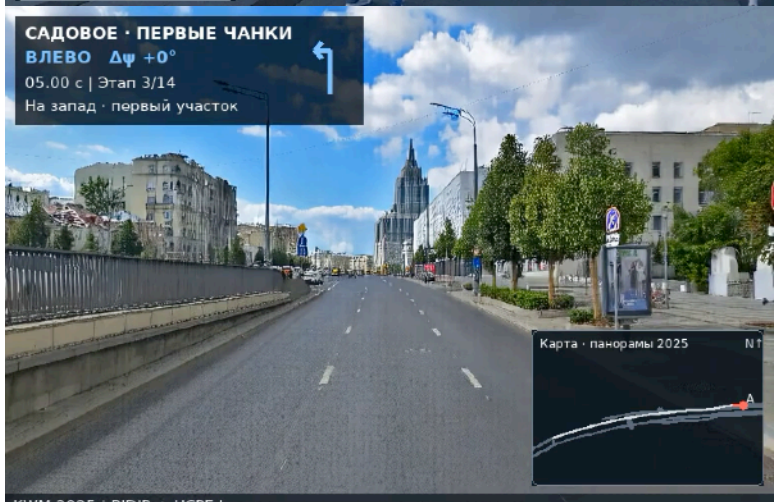

Управляемая реал-тайм генерация

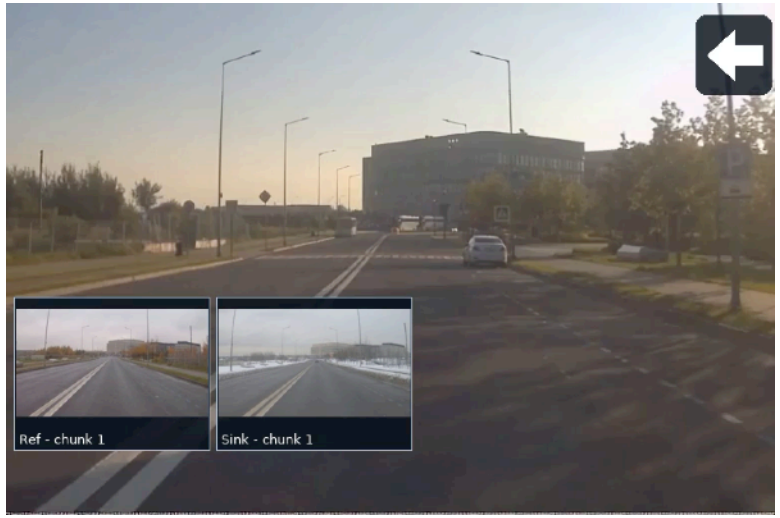

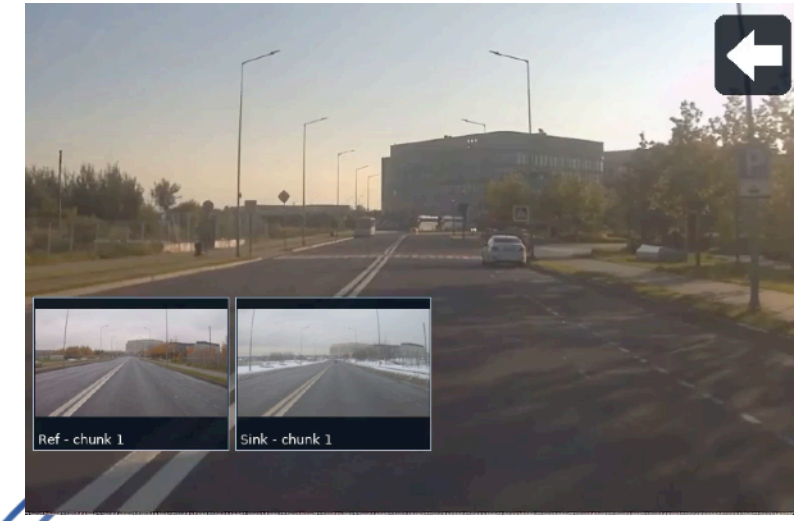

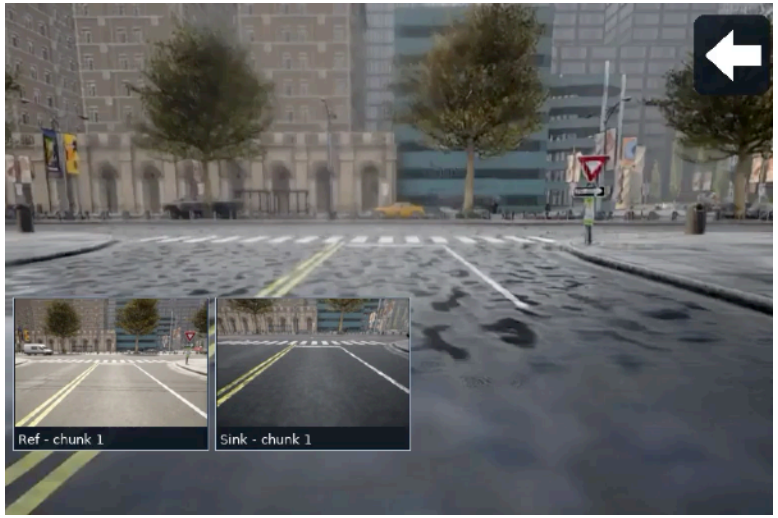

На NAVIO данных

На Carla данных

Работает на кокпите от NAVIO

Мультивью

Оказалось, можно сделать мультивью на базе видео модели (без 3D, реконструкций и тд)

Мультивью аугментация

Baseline scenario Prompt:
Nighttime drive on a multi-lane road.
Left: Building with illuminated windows, parked white box truck, yellow fire hydrant, pedestrian crossing sign.
Right: Same building, fire hydrant, bicycle lane symbol, pedestrian crosswalk markings.
Ahead: Red traffic light, oncoming vehicle headlights, double yellow center lines.
Behind: Crosswalk "XING/PED" road markings, trees.
All vehicles maintain steady speed; no pedestrians or other cars visible. Consistent dim lighting, streetlights, and building exteriors. Road surface shows clear lane markings.

Baseline (K5 Lite i2v)

+ Red car passing from the left side.

+ Big red tractor passing from the left side.

Авторегрессия

Узкий домен

Очень узкий домен

Латентные действия

KWM-1.0 примеры

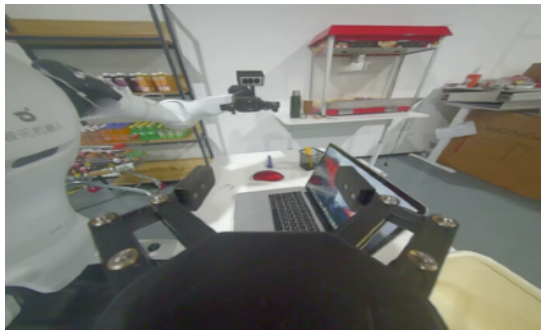

DLS

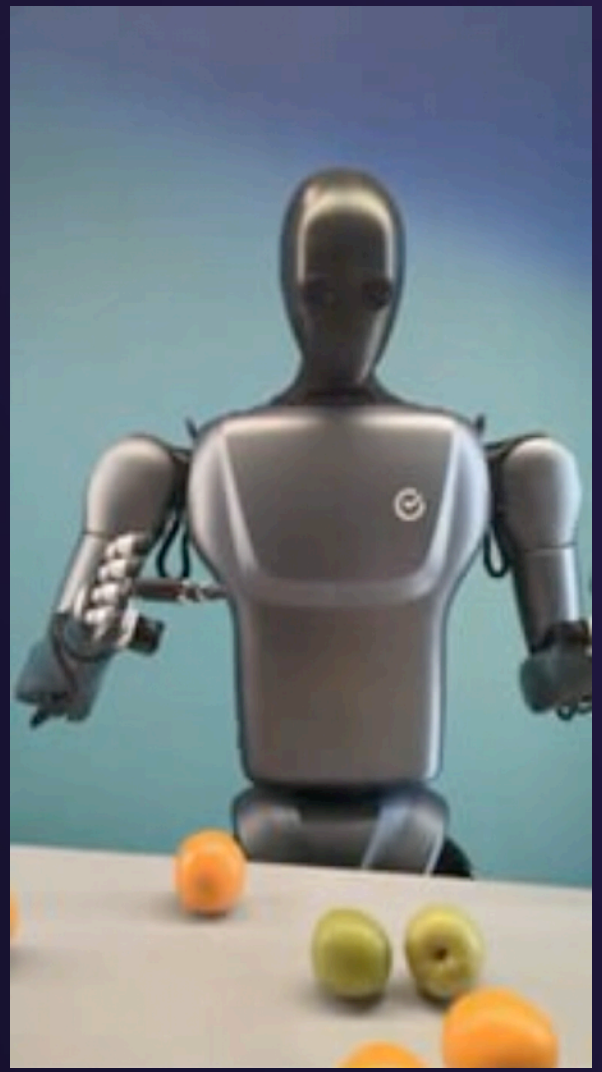

Спасибо за внимание!